Economic Data Analysis

Notes of the course 'Analisi dei Dati Economici' at the University od Naples L'Orientale

Prof. Lucio Palazzo

2026-10-09

Indice

Prefazione 3

1 Introduzione 4

2 Statistica descrittiva 5
- 2.0.1 Frequenze e distribuzioni . . . 5
- 2.0.2 Valori mancanti: assenza di informazione, non valore zero . . . 8
- 2.1 Dove si concentra la distribuzione . . . 8
  - 2.1.1 Media, mediana e moda . . . 8
  - 2.1.2 Media ponderata . . . 9
- 2.2 Quanto sono dispersi i dati . . . 10
  - 2.2.1 Campo di variazione, quantili e intervallo interquartile . . . 10
  - 2.2.2 Varianza e deviazione standard . . . 11
- 2.3 Forma della distribuzione e valori anomali . . . 12
  - 2.3.1 Istogramma e boxplot . . . 13
- 2.4 Confrontare variabili su scale diverse . . . 14
- 2.5 Associazione tra due variabili . . . 15
  - 2.5.1 Diagramma di dispersione e correlazione . . . 16
  - 2.5.2 Tabelle doppie e percentuali condizionate . . . 18
- 2.6 Rappresentare correttamente tempo e territorio . . . 19
  - 2.6.1 Leggere criticamente un grafico . . . 20
- 2.7 Una procedura di analisi descrittiva . . . 21

3 Rappresentazioni grafiche 22
- 3.1 Dal quesito al grafico . . . 22
  - 3.1.1 Gli elementi minimi . . . 23
- 3.2 Un insieme di dati per gli esempi . . . 23
- 3.3 Grafici univariati . . . 26
  - 3.3.1 Diagramma a barre . . . 26
  - 3.3.2 Istogramma . . . 27
  - 3.3.3 Funzione di ripartizione empirica e boxplot . . . 28
- 3.4 Grafici bivariati . . . 30
  - 3.4.1 Due variabili quantitative: lo scatterplot . . . 30
  - 3.4.2 Una variabile quantitativa e una qualitativa . . . 32
  - 3.4.3 Due variabili qualitative . . . 33

3.5 Serie temporali . . . 35
3.6 Rappresentazioni territoriali . . . 36
3.7 Grafici corretti e grafici fuorvianti . . . 37
3.7.1 Scale e assi . . . 37
3.7.2 Dimensioni e decorazioni . . . 37
3.7.3 Doppi assi . . . 37
3.7.4 Colori e accessibilità . . . 38
3.7.5 Dati mancanti e incertezza . . . 38
3.8 Costruire un grafico: una procedura essenziale . . . 38

4 Le serie storiche **39**
4.1 Osservare un fenomeno nel tempo . . . 39
4.1.1 Serie storiche e dati trasversali . . . 40
4.1.2 Frequenza, calendario e natura della misura . . . 40
4.2 Un esempio mensile simulato . . . 41
4.3 Le componenti di una serie storica . . . 42
4.3.1 Decomposizione additiva e moltiplicativa . . . 43
4.3.2 Una decomposizione con R . . . 43
4.4 Stazionarietà: una base relativamente stabile . . . 45
4.4.1 Differenze e trasformazioni . . . 45
4.5 Autocorrelazione e memoria temporale . . . 48
4.5.1 Rumore bianco . . . 49
4.6 Modelli AR, MA e ARMA . . . 50
4.6.1 Modello autoregressivo . . . 50
4.6.2 Modello a media mobile . . . 50
4.6.3 Modello ARMA . . . 51
4.6.4 Simulare e stimare un AR(1) . . . 51
4.6.5 Diagnostica dei residui . . . 52
4.7 Da ARMA ad ARIMA e SARIMA . . . 54
4.8 Prevedere non significa indovinare . . . 55
4.8.1 Previsioni dal modello AR(1) . . . 55
4.8.2 Metodi di riferimento . . . 56
4.9 Shock, valori anomali e cambiamenti strutturali . . . 58
4.10 Quando i dati non sono gaussiani . . . 59
4.11 Una procedura per l'analisi delle serie storiche . . . 59

5 Trasformazioni di serie storiche **60**
5.1 Dal livello alla variazione . . . 61
5.1.1 Variazione assoluta . . . 61
5.1.2 Variazione relativa e percentuale . . . 62
5.1.3 Crescite successive e crescita media . . . 63
5.2 Logaritmi e tassi di crescita . . . 65
5.3 Correggere per gli effetti di calendario . . . 66

5.4 Stagionalità e destagionalizzazione . . . 66
5.4.1 Differenza stagionale o destagionalizzazione? . . . 67
5.5 Smussare una serie per leggere il segnale . . . 67
5.6 Valori anomali e cambiamenti strutturali . . . 69
5.7 Come scegliere una trasformazione . . . 70

6 Indici temporali **72**
6.1 Prima degli indici: scegliere il denominatore . . . 72
6.2 Numeri indice semplici . . . 74
6.3 Base mobile . . . 75
6.4 Scegliere e cambiare la base . . . 76
6.5 Concatenare gli indici . . . 78
6.6 Caso reale: indici sintetici di prezzi, quantità e valori . . . 79
6.6.1 Indici delle quantità e dei valori . . . 82
6.7 Pesi, panieri e rappresentatività . . . 83
6.8 Errori frequenti nella lettura degli indici . . . 84
6.9 Attualizzare valori monetari rispetto all'inflazione . . . 85
6.10 Una procedura per lavorare con gli indici . . . 88

7 Modelli di regressione **89**
7.1 Dallo scatterplot a un modello . . . 89
7.2 La regressione lineare semplice . . . 92
7.2.1 Stima con i minimi quadrati . . . 93
7.3 Adattamento e incertezza . . . 96
7.3.1 Il coefficiente di determinazione . . . 96
7.3.2 Intervalli e test . . . 96
7.4 Regressione lineare multipla . . . 97
7.4.1 Variabili qualitative e categoria di riferimento . . . 97
7.4.2 Quando le pendenze differiscono tra gruppi . . . 99
7.5 Prevedere con la regressione . . . 99
7.6 Trasformazioni e interpretazione dei coefficienti . . . 100
7.7 Ipotesi e diagnostica essenziale . . . 101
7.8 Selezione delle variabili e sovradattamento . . . 103
7.9 Associazione, previsione e causalità . . . 103
7.10 Quando il modello lineare richiede un'estensione . . . 104
7.11 Una procedura per l'analisi di regressione . . . 104

8 Analisi multivariata **106**
8.1 Dalle variabili alla struttura multivariata . . . 106
8.1.1 Un esempio territoriale simulato . . . 107
8.2 Correlazioni e ridondanza informativa . . . 108
8.3 Perché standardizzare . . . 109
8.4 L'intuizione dell'ACP . . . 110

8.5 Calcolare l'ACP con R . . . 110
8.6 Quanta informazione conserva ogni componente . . . 111
8.7 Leggere i loadings . . . 113
8.8 Leggere gli scores . . . 114
8.9 Costruire un indicatore sintetico . . . 116
8.10 Quante componenti conservare . . . 117
8.11 Valori mancanti, outlier e qualità dei dati . . . 118
8.12 Analisi delle corrispondenze multiple . . . 118
8.13 Errori interpretativi frequenti . . . 119
8.14 Una procedura per l'analisi multivariata . . . 119

9 Modelli per dati spaziali **121**
9.1 Dalla tabella alla struttura spaziale . . . 121
9.2 Definire i vicini . . . 122
9.2.1 Un territorio simulato . . . 123
9.3 Autocorrelazione spaziale e indice di Moran . . . 126
9.3.1 Il diagramma di Moran . . . 128
9.4 Dalla descrizione alla regressione spaziale . . . 129
9.5 Il modello autoregressivo spaziale SAR . . . 130
9.6 Il modello spaziale degli errori SEM . . . 133
9.7 SAR o SEM? . . . 135
9.8 Indicatori sintetici e dipendenza spaziale . . . 135
9.9 Problemi specifici dei dati territoriali . . . 136
9.9.1 Unità territoriali modificabili . . . 136
9.9.2 Eterogeneità spaziale . . . 136
9.9.3 Isole, bordi e distanze . . . 136
9.9.4 Tempi e confini . . . 136
9.10 Errori interpretativi frequenti . . . 137
9.11 Una procedura per l'analisi spaziale . . . 137

10 Case Studies **139**

Riferimenti Bibliografici **140**

Prefazione

Work in progress

1 Introduzione

Work in Progress

2 Statistica descrittiva

Una tabella con migliaia di osservazioni non risponde, da sola, a domande come: qual è il reddito tipico di un territorio? Quanto differiscono i comuni tra loro? La disoccupazione è più elevata proprio dove il reddito è più basso? La **statistica descrittiva** raccoglie strumenti per ordinare, sintetizzare e rappresentare i dati, senza perdere di vista la domanda che ha motivato la raccolta.

Questi strumenti costituiscono il primo passaggio di quasi ogni analisi economica. Permettono di individuare errori, valori anomali e differenze rilevanti prima di applicare modelli più complessi. Servono anche a comunicare i risultati in modo comprensibile. L'analisi descrittiva riassume le osservazioni disponibili; l'**inferenza statistica**, invece, usa un campione per formulare conclusioni più generali su una popolazione, tenendo conto dell'incertezza. Descrivere, inoltre, non significa spiegare: una regolarità osservata nei dati può suggerire nuove domande, ma non dimostra da sola un rapporto causale.

2.0.1 Frequenze e distribuzioni

La **distribuzione** descrive quali valori assume una variabile e con quale frequenza. Per una variabile qualitativa, la frequenza assoluta n_j è il numero di osservazioni appartenenti alla modalità j. La frequenza relativa è

$$f_j = \frac{n_j}{n},$$

dove n è il numero totale di osservazioni. La somma delle frequenze assolute è n, mentre la somma delle frequenze relative è 1. Moltiplicando f_j per 100 si ottiene la percentuale. Le frequenze relative consentono di confrontare gruppi di diversa numerosità: 200 disoccupati hanno un significato diverso in un comune di 1.000 residenti e in uno di 100.000.

Quando le modalità sono ordinabili, si può calcolare anche la **frequenza relativa cumulata**:

$$F_j = \sum_{h=1}^{j} f_h.$$

Il simbolo F_j indica la quota di osservazioni che assume una modalità non superiore alla modalità j. Se, per esempio, $F_j = 0{,}70$ in corrispondenza di un reddito di 25 mila euro, il 70%

delle unità osservate ha un reddito non superiore a quella soglia. Non ha invece senso cumulare categorie nominali come provincia, religione o partito, perché il risultato dipenderebbe da un ordinamento arbitrario.

Per una variabile quantitativa si possono elencare tutti i valori oppure raggrupparli in **classi**, cioè intervalli che non si sovrappongono. Il raggruppamento rende leggibile una grande quantità di dati, ma nasconde parte del dettaglio; intervalli scelti in modo diverso possono produrre impressioni visive diverse. Se la classe j ha ampiezza a_j, la sua densità di frequenza relativa è $D_j = f_j / a_j$. Questa distinzione diventa essenziale quando le classi hanno ampiezze diverse: nell'istogramma è l'area del rettangolo, non la sola altezza, a dover essere proporzionale alla frequenza.

Nel seguito useremo un campione ipotetico di dodici comuni. I dati sono **simulati a scopo didattico** e non descrivono territori reali. Il reddito è espresso in migliaia di euro per residente, la disoccupazione in percentuale e la popolazione in migliaia di residenti.

```
# Dati simulati: ogni riga rappresenta un comune
set.seed(2026)

comuni <- data.frame(
  comune = c("Roma", "Napoli", "Milano", "Torino", "Bologna", "Firenze",
             "Palermo", "Genova", "Venezia", "Verona", "Cagliari", "L'Aquila"),
  area = rep(c("Area Metropolitana", "Città"), each = 6),
  reddito = c(18.2, 19.5, 20.1, 21.0, 21.4, 22.0,
              22.6, 23.1, 23.8, 24.5, 25.2, 39.0),
  disoccupazione = c(15.2, 14.1, 13.8, 12.9, 12.4, 11.8,
                     11.1, 10.7, 10.0, 9.4, 8.8, 7.5),
  popolazione = c(18, 25, 14, 32, 21, 29, 17, 23, 26, 19, 31, 15)
)

comuni |> knitr::kable(
  caption = "Dati simulati per dodici comuni",
  col.names = c("Comune", "Area", "Reddito (migliaia di euro)",
                "Disoccupazione (%)", "Popolazione (migliaia)")
)
```

Tabella 2.1: Dati simulati per dodici comuni

Comune	Area	Reddito (migliaia di euro)	Disoccupazione (%)	Popolazione (migliaia)
Roma	Area Metropolitana	18.2	15.2	18

Comune	Area	Reddito (migliaia di euro)	Disoccupazione (%)	Popolazione (migliaia)
Napoli	Area Metropolitana	19.5	14.1	25
Milano	Area Metropolitana	20.1	13.8	14
Torino	Area Metropolitana	21.0	12.9	32
Bologna	Area Metropolitana	21.4	12.4	21
Firenze	Area Metropolitana	22.0	11.8	29
Palermo	Città	22.6	11.1	17
Genova	Città	23.1	10.7	23
Venezia	Città	23.8	10.0	26
Verona	Città	24.5	9.4	19
Cagliari	Città	25.2	8.8	31
L'Aquila	Città	39.0	7.5	15

```r
# In una cross-section l'ordine delle righe non contiene informazione.
# Il seme rende riproducibile anche questo ordinamento casuale.
comuni <- comuni[sample(seq_len(nrow(comuni))), ]
row.names(comuni) <- NULL

# Frequenze assolute e percentuali per area
frequenze_area <- table(comuni$area)
percentuali_area <- prop.table(frequenze_area) * 100

frequenze_area
```

```
Area Metropolitana             Città
                 6                 6
```

```r
round(percentuali_area, 1)
```

```
Area Metropolitana             Città
                50                50
```

I due gruppi contengono sei comuni ciascuno e rappresentano quindi il 50% delle osservazioni. Questa percentuale riguarda i **comuni**, non i residenti: poiché le popolazioni comunali sono diverse, non possiamo concludere che metà dei residenti viva in ciascuna area. Il denominatore deve essere sempre coerente con la domanda.

2.0.2 Valori mancanti: assenza di informazione, non valore zero

Un valore può mancare perché un comune non ha trasmesso il dato, perché una domanda non era applicabile o perché si è verificato un errore. In R un valore mancante è normalmente indicato con `NA`. Sostituirlo automaticamente con zero è quasi sempre scorretto: "reddito non disponibile" non significa "reddito nullo".

Molte funzioni di R restituiscono `NA` quando il vettore contiene valori mancanti. L'argomento `na.rm = TRUE` permette di calcolare, per esempio, `mean(x, na.rm = TRUE)` sulle sole osservazioni disponibili. Questa scelta non risolve il problema: cambia il campione effettivamente analizzato. Se la probabilità che un dato manchi è collegata al fenomeno studiato, anche la sintesi calcolata sui casi completi può essere distorta. Occorre quindi riportare quanti valori mancano, motivare il criterio adottato e controllare il denominatore di ogni percentuale.

2.1 Dove si concentra la distribuzione

Gli indici di posizione riassumono dove si collocano i dati. Nessun indice è "il centro" in ogni situazione: la scelta dipende dal tipo di variabile e dalla forma della distribuzione.

2.1.1 Media, mediana e moda

Per n osservazioni quantitative $x_1, x_2, \dots, x_n$, la **media aritmetica** è

$$\bar{x} = \frac{1}{n} \sum_{i=1}^{n} x_i.$$

Il simbolo x_i indica il valore osservato per l'unità i, n il numero di unità e $\bar{x}$ la media. La media utilizza tutte le osservazioni e può essere letta come il valore che ciascuna unità avrebbe se il totale fosse distribuito in parti uguali. Proprio perché usa tutti i valori, risente molto di osservazioni estreme.

La **mediana** è invece il valore che, dopo avere ordinato i dati, lascia il 50% delle osservazioni al di sotto e il 50% al di sopra. Se n è pari, è la media dei due valori centrali. È meno sensibile ai valori estremi ed è spesso più rappresentativa per redditi, patrimoni e prezzi immobiliari, le cui distribuzioni tendono a essere asimmetriche.

La **moda** è il valore o la modalità più frequente. Può essere usata anche per variabili qualitative, ma può non esistere oppure essere multipla. Nel piccolo esempio ogni reddito compare una sola volta: indicare una moda non sarebbe informativo.

```
indici_posizione <- c(
  media = mean(comuni$reddito),
  mediana = median(comuni$reddito),
  minimo = min(comuni$reddito),
  massimo = max(comuni$reddito)
)

round(indici_posizione, 2)
```

```
  media mediana  minimo massimo
  23.37   22.30   18.20   39.00
```

Il reddito medio è 23,37 mila euro, mentre la mediana è 22,30 mila. La differenza è dovuta soprattutto al valore di 39 mila euro del comune L: essendo molto elevato rispetto agli altri, sposta la media verso l'alto. In questo caso la mediana descrive meglio il comune "centrale", mentre la media resta utile per ricostruire il reddito complessivo per residente medio soltanto se si usano pesi adeguati.

2.1.2 Media ponderata

Una media semplice attribuisce lo stesso peso a ogni riga. Se vogliamo stimare il reddito medio del **residente** e i comuni hanno popolazioni differenti, dobbiamo invece ponderare il reddito comunale per la popolazione:

$$\bar{x}_w = \frac{\sum_{i=1}^{n} w_i x_i}{\sum_{i=1}^{n} w_i},$$

dove w_i è il peso attribuito all'unità i. Nel nostro esempio w_i è la popolazione del comune i.

```
reddito_medio_residente <- weighted.mean(
  x = comuni$reddito,
  w = comuni$popolazione
)

round(reddito_medio_residente, 2)
```

```
[1] 23.04
```

La media ponderata è 23,04 mila euro, inferiore alla media semplice di 23,37. Il comune con reddito più alto ha infatti una popolazione relativamente piccola. La media semplice risponde alla domanda "qual è il reddito medio dei comuni?", dando a ogni comune lo stesso peso; la media ponderata risponde alla domanda "qual è il reddito medio dei residenti?", sotto l'ipotesi semplificatrice che il reddito comunale riportato sia applicabile ai residenti del comune.

> ⚠ Un errore frequente: confondere unità e persone
>
> Una media di valori comunali non coincide necessariamente con la media individuale. Il passaggio da dati aggregati a conclusioni sugli individui richiede pesi corretti e informazioni compatibili. Inoltre, una relazione osservata tra comuni non implica che la stessa relazione valga tra gli individui: questa conclusione indebita è nota come **fallacia ecologica**.

2.2 Quanto sono dispersi i dati

Due distribuzioni possono avere la stessa media ma essere molto diverse. Un reddito medio di 25 mila euro può derivare da valori tutti vicini a 25 oppure da una forte distanza tra territori ricchi e poveri. Gli indici di dispersione misurano questa eterogeneità.

2.2.1 Campo di variazione, quantili e intervallo interquartile

Il **campo di variazione** (*range*) è la differenza tra massimo e minimo. È immediato, ma dipende soltanto da due osservazioni e risente molto dei valori estremi.

Un **quantile** di ordine p è un valore che lascia una proporzione p delle osservazioni al di sotto o in corrispondenza di esso. I tre quartili dividono i dati ordinati in quattro parti: il primo quartile Q_1 corrisponde al 25%, il secondo alla mediana e il terzo Q_3 al 75%. L'**intervallo interquartile** è

$$IQR = Q_3 - Q_1.$$

Esso misura l'ampiezza della metà centrale dei dati ed è poco influenzato dai valori estremi. Esistono diversi metodi di interpolazione per calcolare i quantili; con campioni piccoli software diversi possono quindi restituire risultati leggermente differenti.

2.2.2 Varianza e deviazione standard

La deviazione di un'osservazione dalla media è $x_i - \bar{x}$. Poiché le deviazioni positive e negative si compensano, le eleviamo al quadrato. La **varianza campionaria** è

$$s^2 = \frac{1}{n-1} \sum_{i=1}^{n} (x_i - \bar{x})^2,$$

dove s^2 indica la varianza e $n-1$ è il denominatore usato quando i dati sono considerati un campione. Se le unità osservate costituiscono invece l'intera popolazione di interesse, la varianza descrittiva si indica spesso con σ^2 e si divide per la numerosità N della popolazione:

$$\sigma^2 = \frac{1}{N} \sum_{i=1}^{N} (x_i - \mu)^2,$$

dove μ è la media della popolazione. La distinzione fra $n-1$ e N non è un dettaglio puramente formale: dipende dal ruolo attribuito ai dati. La funzione `var()` di R, usata più avanti, calcola la varianza campionaria con denominatore $n-1$.

La varianza è espressa nell'unità di misura al quadrato, quindi è poco intuitiva. La **deviazione standard campionaria** è la sua radice quadrata,

$$s = \sqrt{s^2},$$

e torna all'unità di misura originaria. Per la popolazione si usa analogamente $\sigma = \sqrt{\sigma^2}$. Un valore elevato segnala che le osservazioni sono, nel complesso, lontane dalla media. Non significa che ogni osservazione disti esattamente s dalla media.

Quando si confronta la variabilità di grandezze positive con scale diverse, può essere utile il **coefficiente di variazione**:

$$CV = \frac{s}{\bar{x}} \times 100.$$

Il CV esprime la deviazione standard come percentuale della media. Non è appropriato quando la media è nulla, prossima a zero o quando lo zero della scala è convenzionale, come per la temperatura in gradi Celsius.

```r
indici_dispersione <- c(
  campo = diff(range(comuni$reddito)),
  IQR = IQR(comuni$reddito),
  varianza = var(comuni$reddito),
  deviazione_standard = sd(comuni$reddito),
  coefficiente_variazione = sd(comuni$reddito) /
    mean(comuni$reddito) * 100
)

round(indici_dispersione, 2)
```

```
                campo                   IQR              varianza
                20.80                  3.20                 28.50
deviazione_standard coefficiente_variazione
                 5.34                 22.85
```

I redditi coprono un campo di 20,80 mila euro. L'IQR è però soltanto 3,20 mila euro: la metà centrale dei comuni è relativamente concentrata, mentre il campo è ampliato dal comune L. La deviazione standard è 5,34 mila euro, pari al 22,85% della media. Gli indici raccontano aspetti diversi e vanno letti congiuntamente, non scelti in base a quello che sostiene meglio una tesi.

2.3 Forma della distribuzione e valori anomali

Una distribuzione è **simmetrica** quando la parte a sinistra e quella a destra del centro hanno forma simile. È **asimmetrica a destra** quando pochi valori elevati formano una coda lunga verso destra, come spesso accade per redditi e patrimoni; in tal caso la media tende a superare la mediana. L'asimmetria a sinistra presenta la situazione opposta.

Un **valore anomalo** (*outlier*) è un'osservazione insolitamente lontana dalle altre. Può derivare da un errore di inserimento, da una diversa unità di misura oppure da un caso reale e sostantivamente importante. Il boxplot usa spesso una regola operativa: segnala i valori inferiori a $Q_1 - 1{,}5\,IQR$ o superiori a $Q_3 + 1{,}5\,IQR$.

Questa regola è uno strumento diagnostico, non una definizione universale. Un comune molto ricco non è necessariamente un errore; eliminarlo automaticamente potrebbe cancellare proprio il fenomeno che vogliamo studiare. Prima di intervenire occorre controllare la fonte, la definizione della variabile e il contesto.

2.3.1 Istogramma e boxplot

L'**istogramma** divide l'asse dei valori in intervalli adiacenti ed è adatto a variabili quantitative. L'area di ciascun rettangolo rappresenta la frequenza della classe. Se tutte le classi hanno uguale ampiezza, anche le altezze sono proporzionali alle frequenze; con classi diseguali, invece, sull'asse verticale occorre riportare la densità. La forma del grafico dipende quindi dalla scelta degli intervalli. Un grafico a barre rappresenta invece categorie distinte: le barre sono separate, hanno uguale larghezza e soltanto la loro altezza esprime la frequenza.

Il **boxplot** mostra la mediana, i quartili, l'IQR e gli eventuali valori segnalati come anomali. È compatto e utile per confrontare gruppi, ma non mostra bene distribuzioni con più addensamenti e, con pochissime osservazioni, va interpretato con cautela.

```
par(mfrow = c(1, 2), mar = c(4, 4, 2, 1))

hist(
  comuni$reddito,
  breaks = 6,
  col = "grey80",
  border = "white",
  main = "Istogramma",
  xlab = "Reddito (migliaia di euro)"
)

boxplot(
  comuni$reddito,
  horizontal = TRUE,
  col = "grey80",
  main = "Boxplot",
  xlab = "Reddito (migliaia di euro)"
)
```

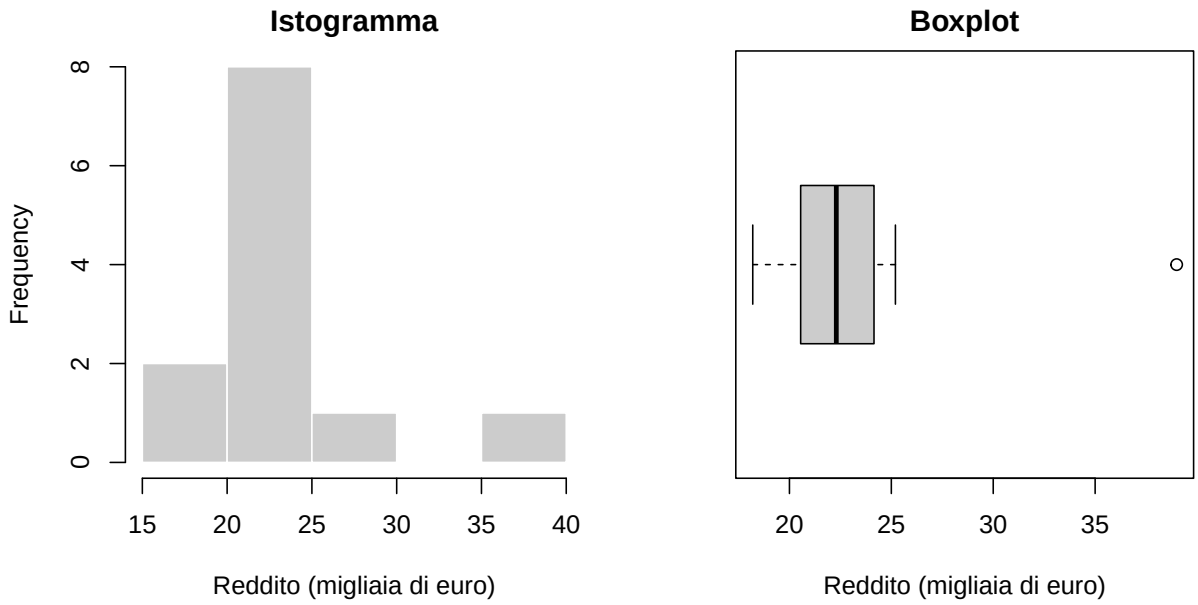


Figura 2.1: Distribuzione dei redditi nei dodici comuni simulati: istogramma e boxplot.

```
par(mfrow = c(1, 1))
```

L'istogramma mostra che quasi tutti i comuni si concentrano tra 18 e 26 mila euro, mentre uno è molto più in alto. Il boxplot segnala il valore di 39 come anomalo secondo la regola di 1,5 IQR. I grafici non stabiliscono se il dato sia errato: indicano dove approfondire il controllo.

2.4 Confrontare variabili su scale diverse

Non è sensato confrontare direttamente una differenza di 5 mila euro di reddito con una differenza di 5 punti percentuali di disoccupazione. La **standardizzazione** colloca una variabile su una scala priva di unità di misura. Per l'osservazione i, lo *z-score* è

$$z_i = \frac{x_i - \bar{x}}{s},$$

dove x_i è il valore originale, $\bar{x}$ la media e s la deviazione standard. Uno z-score positivo indica un valore sopra la media; uno negativo indica un valore sotto la media. Il valore assoluto esprime la distanza dalla media in deviazioni standard.

```r
comuni$z_reddito <- as.numeric(scale(comuni$reddito))

valori_standardizzati <- comuni[
  match(c("A", "F", "L"), comuni$comune),
  c("comune", "reddito", "z_reddito")
]
valori_standardizzati$z_reddito <- round(
  valori_standardizzati$z_reddito,
  2
)

valori_standardizzati
```

```
     comune reddito z_reddito
NA      <NA>      NA        NA
NA.1    <NA>      NA        NA
NA.2    <NA>      NA        NA
```

Il comune A ha uno z-score di circa -0,97: il suo reddito è quasi una deviazione standard sotto la media. Il comune L ha uno z-score di circa 2,93, quindi si trova quasi tre deviazioni standard sopra la media. Lo z-score descrive una posizione relativa, non una probabilità e non implica automaticamente che il dato sia impossibile.

La standardizzazione è utile quando si costruiscono indicatori sintetici o si applicano metodi sensibili alla scala. Non rende però confrontabili concetti privi di un significato comune e non corregge asimmetrie, errori o qualità scadente dei dati.

2.5 Associazione tra due variabili

Finora abbiamo descritto una variabile alla volta. Spesso la domanda riguarda invece il modo in cui due caratteristiche variano insieme: nei comuni con reddito più alto la disoccupazione tende a essere più bassa?

Per due variabili quantitative X e Y, la **covarianza campionaria** è

$$s_{xy} = \frac{1}{n-1}\sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y}),$$

dove x_i e y_i sono i valori delle due variabili per l'unità i, mentre $\bar{x}$ e $\bar{y}$ sono le rispettive medie. Una covarianza positiva indica che valori sopra la media tendono a presentarsi insieme; una covarianza negativa indica che valori sopra la media di una variabile tendono ad accompagnarsi

a valori sotto la media dell'altra. La sua grandezza dipende dalle unità di misura e non è quindi facile da confrontare.

Il **coefficiente di correlazione lineare di Pearson** standardizza la covarianza:

$$r_{xy} = \frac{s_{xy}}{s_x s_y},$$

dove s_x e s_y sono le deviazioni standard di X e Y. Il coefficiente varia tra -1 e 1. Il segno indica la direzione dell'associazione lineare; il valore assoluto ne indica l'intensità. Valori vicini a zero segnalano assenza di associazione **lineare**, ma non escludono una relazione non lineare.

2.5.1 Diagramma di dispersione e correlazione

Il **diagramma di dispersione** (*scatterplot*) rappresenta ogni unità con un punto. Deve essere esaminato prima di interpretare la correlazione, perché rende visibili forma, gruppi e osservazioni influenti che un singolo numero nasconde.

```
plot(
  comuni$reddito,
  comuni$disoccupazione,
  pch = 19,
  col = "#2C7FB8",
  xlab = "Reddito (migliaia di euro)",
  ylab = "Disoccupazione (%)"
)
text(
  comuni$reddito,
  comuni$disoccupazione,
  labels = comuni$comune,
  pos = 3,
  cex = 0.8
)
```

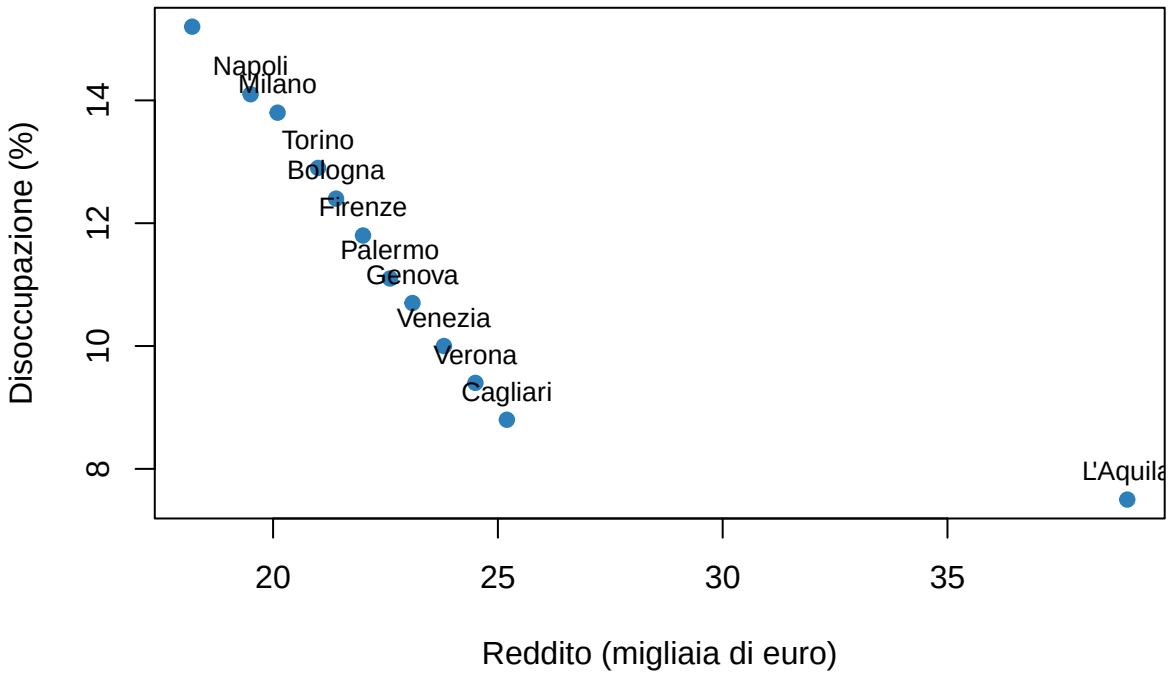


Figura 2.2: Reddito e disoccupazione nei dodici comuni simulati.

```
correlazione <- cor(comuni$reddito, comuni$disoccupazione)
round(correlazione, 2)
```

```
[1] -0.82
```

La correlazione è -0,82: nel campione simulato, i comuni con reddito più alto tendono ad avere una disoccupazione più bassa e l'associazione lineare è forte. Non possiamo concludere che un aumento del reddito **causi** una riduzione della disoccupazione. Entrambe le variabili potrebbero dipendere, per esempio, dalla struttura produttiva, dalla composizione demografica o dal livello di istruzione. Inoltre, con sole dodici unità, ogni osservazione può incidere molto sul risultato.

> ⚠ Tre errori frequenti sulla correlazione
>
> 1. Una correlazione elevata non dimostra un nesso causale.
> 2. Una correlazione vicina a zero non esclude relazioni curve o differenze tra gruppi.
> 3. Un valore anomalo può rafforzare, indebolire o persino invertire la correlazione; il grafico è indispensabile.

2.5.2 Tabelle doppie e percentuali condizionate

Per due variabili qualitative si usa una **tabella di contingenza**, o tabella doppia, che conta quante unità presentano ciascuna combinazione di modalità. Le frequenze all'interno della tabella formano la distribuzione congiunta; i totali di riga e di colonna sono le distribuzioni marginali.

Per confrontare gruppi di diversa numerosità sono particolarmente utili i **profili condizionati**. Se n_{ij} è il numero di unità nella cella che incrocia la modalità i della variabile di riga e la modalità j della variabile di colonna, e n_{i+} è il totale della riga i, la percentuale condizionata di riga è

$$f_{j|i} = \frac{n_{ij}}{n_{i+}}.$$

Il simbolo $j \mid i$ si legge "modalità j dato il gruppo i". Il denominatore cambia da una riga all'altra: per questo tali percentuali rispondono alla domanda "come si distribuisce la variabile di colonna all'interno di ciascun gruppo?".

Nel campione simulato dividiamo i comuni in due classi di disoccupazione usando, soltanto a fini didattici, la soglia del 12%.

```
comuni$classe_disoccupazione <- ifelse(
  comuni$disoccupazione >= 12,
  "Almeno 12%",
  "Meno del 12%"
)

tabella_area <- table(
  Area = comuni$area,
  Disoccupazione = comuni$classe_disoccupazione
)

tabella_area
```

```
                    Disoccupazione
Area                 Almeno 12% Meno del 12%
  Area Metropolitana          5            1
  Città                       0            6
```

```
round(prop.table(tabella_area, margin = 1) * 100, 1)
```

```
                    Disoccupazione
Area                 Almeno 12% Meno del 12%
  Area Metropolitana       83.3         16.7
  Città                     0.0        100.0
```

Cinque dei sei comuni del Centro, cioè l'83,3%, appartengono alla classe con disoccupazione almeno pari al 12%; nessuno dei sei comuni della Periferia vi appartiene. Il confronto usa percentuali di riga, quindi il denominatore è il numero di comuni in ciascuna area. Il risultato descrive questi dodici casi simulati: non dimostra che l'area determini la disoccupazione. Inoltre, una soglia diversa produrrebbe una tabella diversa e la trasformazione in due classi perde le differenze osservate all'interno di ciascuna classe.

2.6 Rappresentare correttamente tempo e territorio

La scelta del grafico dipende dalla struttura dei dati e dalla domanda:

- un grafico a barre confronta frequenze o valori tra categorie;
- un istogramma descrive la distribuzione di una variabile quantitativa;
- un boxplot confronta posizione e dispersione tra gruppi;
- uno scatterplot studia l'associazione tra due variabili quantitative;
- un grafico a linee segue una variabile ordinata nel tempo.

In una serie storica i punti consecutivi sono collegati perché il loro ordine ha significato. Collegare con una linea comuni disposti alfabeticamente suggerirebbe invece una continuità inesistente. Una carta tematica può mostrare la distribuzione territoriale, ma aree più grandi attirano visivamente l'attenzione anche quando hanno poca popolazione; colori e classi devono quindi essere scelti e descritti con cura.

Il grafico seguente usa una seconda serie simulata: il tasso di occupazione mensile cresce nel corso dell'anno, con alcune oscillazioni. L'obiettivo è mostrare la forma corretta di una rappresentazione temporale, non documentare un andamento reale.

```r
occupazione <- data.frame(
  mese = as.Date(sprintf("2025-%02d-01", 1:12)),
  tasso = c(57.8, 58.0, 58.1, 58.0, 58.4, 58.7,
            58.9, 58.8, 59.1, 59.3, 59.2, 59.5)
)

plot(
  occupazione$mese,
  occupazione$tasso,
  type = "o",
```

```
  pch = 19,
  col = "#2C7FB8",
  xlab = "Mese",
  ylab = "Tasso di occupazione (%)",
  ylim = c(55, 61)
)
```

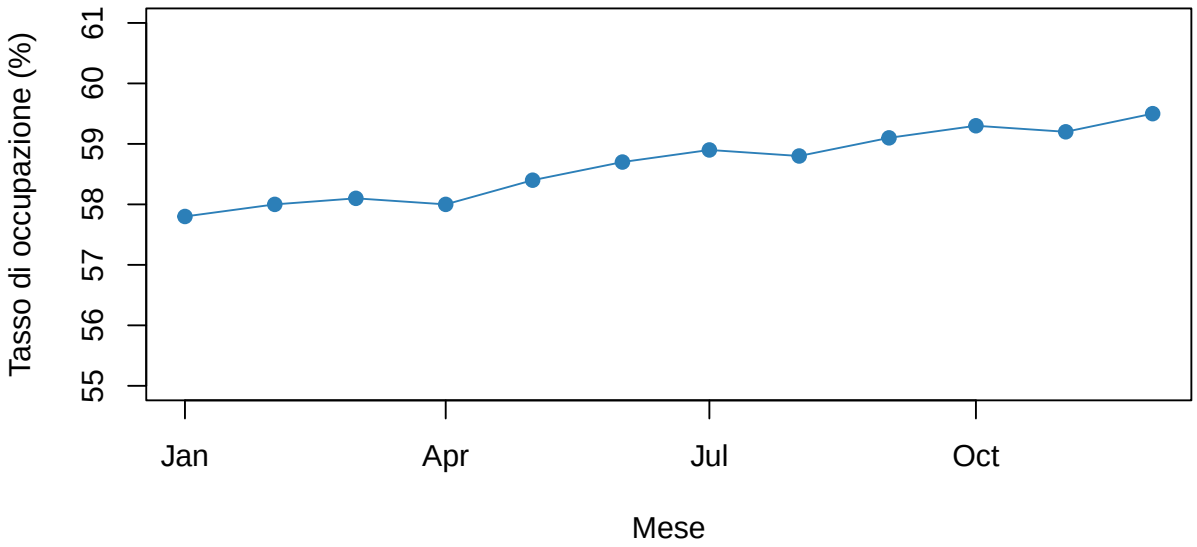


Figura 2.3: Tasso di occupazione mensile simulato.

Il tasso simulato passa dal 57,8% al 59,5%, un aumento di 1,7 **punti percentuali**. Non è corretto chiamarlo aumento dell'1,7%: la variazione relativa è circa il 2,9% rispetto al valore iniziale. Il capitolo sulle trasformazioni delle serie storiche approfondirà questa distinzione.

2.6.1 Leggere criticamente un grafico

Prima di accettare il messaggio visivo di un grafico è utile controllare:

1. **Fonte e popolazione di riferimento.** Chi è incluso e in quale periodo?
2. **Unità di misura e denominatore.** Si mostrano euro, percentuali, punti percentuali o valori pro capite?
3. **Scala degli assi.** Un asse verticale troncato può amplificare piccole differenze; un asse troppo ampio può nasconderle.
4. **Classi e colori.** Negli istogrammi e nelle carte, soglie diverse possono cambiare l'impressione complessiva.
5. **Valori mancanti.** Un'area senza dati non equivale a un valore pari a zero.

6. **Confrontabilità.** Definizioni, prezzi, popolazioni e confini territoriali sono rimasti coerenti?
7. **Incertezza.** Se i valori sono stime campionarie, il grafico mostra l'incertezza associata?

Nel grafico temporale precedente l'asse verticale è limitato tra 55 e 61 per rendere leggibili le variazioni. La scelta è dichiarata e i valori sono espressi chiaramente, ma una scala così ristretta accentua visivamente un cambiamento di soli 1,7 punti. Forma grafica e interpretazione numerica devono procedere insieme.

2.7 Una procedura di analisi descrittiva

Una buona analisi descrittiva non consiste nel produrre automaticamente tutti gli indici disponibili. Una sequenza ragionata è la seguente:

1. formulare la domanda e identificare unità di analisi, periodo e popolazione;
2. controllare definizioni, unità di misura, duplicati e valori mancanti;
3. distinguere variabili qualitative e quantitative e riconoscere la struttura dei dati;
4. esaminare frequenze e grafici prima di affidarsi a una singola sintesi;
5. scegliere indici di posizione e dispersione coerenti con la distribuzione;
6. verificare valori anomali senza eliminarli automaticamente;
7. studiare le associazioni con grafici e misure appropriate;
8. comunicare sempre il denominatore e interpretare i risultati nel loro contesto.

Nel nostro esempio, la media da sola avrebbe suggerito un reddito comunale tipico di 23,37 mila euro. Mediana, IQR e boxplot hanno mostrato una realtà più precisa: la metà centrale è concentrata attorno a 22,30 mila euro e un comune molto ricco influenza sensibilmente alcune sintesi. Lo scatterplot e la correlazione hanno poi evidenziato un'associazione negativa tra reddito e disoccupazione, che resta descrittiva e non causale. È questo il valore della statistica descrittiva: trasformare una tabella in un insieme controllabile di evidenze, mantenendo espliciti i limiti di ciò che i dati consentono di affermare.

3 Rappresentazioni grafiche

Un grafico ben costruito rende visibili regolarità che una tabella può nascondere. Può mostrare, per esempio, che la disoccupazione è più elevata in alcuni gruppi di comuni, che una distribuzione presenta una lunga coda verso destra o che una serie economica cambia bruscamente dopo uno shock. Un grafico, tuttavia, non è una decorazione e non è una fotografia neutrale dei dati: la scelta delle variabili, della scala, dei colori e del periodo determina ciò che il lettore riesce a vedere.

Nell'analisi dei dati economici le rappresentazioni grafiche hanno almeno tre funzioni. Aiutano a **esplorare** i dati prima di applicare un modello, a **controllare** errori e osservazioni insolite e a **comunicare** un risultato. Lo stesso grafico può svolgere più funzioni, ma deve sempre essere collegato a una domanda precisa.

3.1 Dal quesito al grafico

Prima di scegliere un tipo di grafico conviene completare una frase: "Voglio mostrare…". Se la frase è "come si distribuisce il reddito tra i comuni", la variabile principale è quantitativa e un istogramma può essere adatto. Se è "come cambia la disoccupazione nel tempo", l'ordine temporale è essenziale e sarà preferibile un grafico a linee. Se è "come reddito e disoccupazione variano insieme", occorre rappresentare entrambe le variabili con uno scatterplot.

La scelta può essere riassunta così:

Domanda	Variabili o struttura	Grafico utile
Quali categorie sono più frequenti?	Una qualitativa	Barre
Come si distribuiscono i valori?	Una quantitativa	Istogramma, funzione cumulata o boxplot
Due gruppi hanno distribuzioni diverse?	Una quantitativa e una qualitativa	Boxplot paralleli
Due misure variano insieme?	Due quantitative	Scatterplot
La composizione cambia tra gruppi?	Due qualitative	Barre raggruppate o al 100%
Come evolve un indicatore?	Serie temporale	Linee

Domanda	Variabili o struttura	Grafico utile
Dove si concentra un fenomeno?	Dati territoriali	Carta tematica

Queste associazioni non sono regole meccaniche. La numerosità dei dati, il pubblico e il messaggio sostantivo possono suggerire soluzioni diverse. Una tabella resta spesso preferibile quando servono pochi valori esatti; un grafico è più efficace quando interessano forma, confronto e andamento.

3.1.1 Gli elementi minimi

Un grafico interpretabile dovrebbe indicare:

- che cosa rappresentano gli assi e in quale unità di misura;
- la popolazione, il territorio e il periodo di riferimento;
- se i valori sono conteggi, percentuali, tassi o indici;
- la fonte dei dati e le eventuali trasformazioni;
- il significato di colori, simboli e linee;
- quando rilevante, il numero di osservazioni e l'incertezza delle stime.

Il titolo dovrebbe esprimere il contenuto del grafico, non limitarsi a "Grafico 1". Anche il denominatore deve essere evidente: "disoccupati" e "tasso di disoccupazione" non descrivono la stessa grandezza.

3.2 Un insieme di dati per gli esempi

Useremo un campione simulato di 72 comuni, suddivisi in tre aree. Ogni riga rappresenta un comune. Il reddito è espresso in migliaia di euro per residente, disoccupazione e partecipazione elettorale in percentuale. La valutazione dei servizi è una variabile qualitativa ordinale. I dati sono costruiti esclusivamente a scopo didattico e non descrivono territori reali.

```
set.seed(2026)

numero_comuni <- c(Nord = 24, Centro = 18, Sud = 30)
area <- factor(
  rep(names(numero_comuni), times = numero_comuni),
  levels = c("Nord", "Centro", "Sud")
)
```

```r
reddito <- round(
  rnorm(
    n = length(area),
    mean = c(Nord = 29, Centro = 25, Sud = 21)[as.character(area)],
    sd = 2.3
  ),
  1
)
reddito[1] <- 42

effetto_area <- c(Nord = -1, Centro = 0, Sud = 1.2)[as.character(area)]
disoccupazione <- round(
  20 - 0.38 * reddito + effetto_area +
    rnorm(length(area), mean = 0, sd = 0.9),
  1
)

partecipazione <- round(
  pmin(
    85,
    pmax(
      35,
      75 - 0.9 * disoccupazione +
        rnorm(length(area), mean = 0, sd = 3)
    )
  ),
  1
)

probabilita_servizi <- list(
  Nord = c(0.15, 0.45, 0.40),
  Centro = c(0.25, 0.50, 0.25),
  Sud = c(0.50, 0.40, 0.10)
)

servizi <- unlist(
  lapply(names(numero_comuni), function(zona) {
    sample(
      c("Insufficiente", "Adeguata", "Buona"),
      size = numero_comuni[zona],
      replace = TRUE,
      prob = probabilita_servizi[[zona]]
```

```
    )
  }),
  use.names = FALSE
)

dati_comuni <- data.frame(
  area = area,
  reddito = reddito,
  disoccupazione = disoccupazione,
  partecipazione = partecipazione,
  servizi = factor(
    servizi,
    levels = c("Insufficiente", "Adeguata", "Buona"),
    ordered = TRUE
  )
)

dati_comuni |>
  head() |>
  knitr::kable(
  caption = "Campione simulato di comuni con reddito, disoccupazione, partecipazione e valuta
  digits = c(0, 1, 1, 1, NA)
)
```

Tabella 3.1: Campione simulato di comuni con reddito, disoccupazione, partecipazione e valutazione dei servizi.

area	reddito	disoccupazione	partecipazione	servizi
Nord	42.0	4.3	74.6	Buona
Nord	26.5	8.2	64.9	Adeguata
Nord	29.3	8.3	68.5	Insufficiente
Nord	28.8	7.2	70.8	Buona
Nord	27.5	10.5	66.3	Insufficiente
Nord	23.2	10.8	60.6	Adeguata

La simulazione incorpora differenze territoriali e associazioni tra variabili per rendere leggibili i grafici. Tali relazioni fanno parte del meccanismo con cui abbiamo costruito l'esempio: non costituiscono risultati empirici.

3.3 Grafici univariati

Un grafico univariato descrive una sola variabile. La forma appropriata dipende soprattutto dal fatto che la variabile sia qualitativa o quantitativa.

3.3.1 Diagramma a barre

Il **diagramma a barre** rappresenta le modalità di una variabile qualitativa, oppure i pochi valori distinti di una variabile quantitativa discreta. Ogni modalità occupa una posizione sull'asse orizzontale; l'altezza della barra rappresenta la frequenza assoluta o relativa. Le barre sono separate perché le categorie sono distinte. La loro larghezza non contiene informazione e dovrebbe rimanere uguale.

```
percentuali_servizi <- prop.table(table(dati_comuni$servizi)) * 100

barplot(
  percentuali_servizi,
  col = c("#D95F0E", "#FEC44F", "#238B45"),
  border = NA,
  ylim = c(0, 60),
  ylab = "Comuni (%)",
  xlab = "Valutazione dei servizi"
)
```

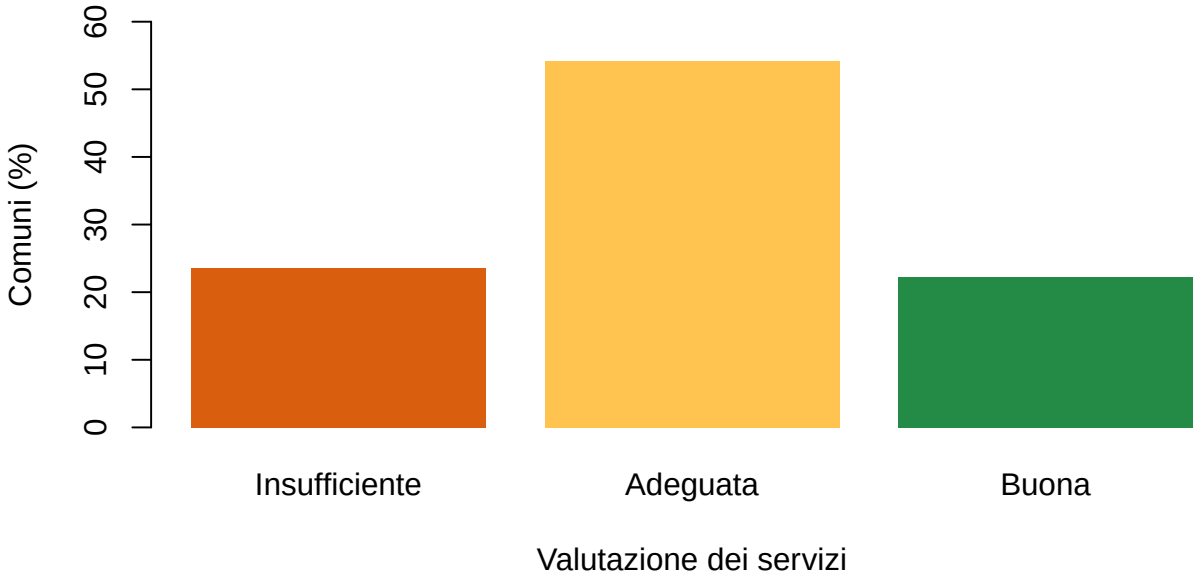


Figura 3.1: Distribuzione percentuale della valutazione dei servizi nei comuni simulati.

Nel campione simulato la modalità “Adeguata” è la più frequente. L’asse verticale riporta percentuali di comuni, non percentuali di residenti: ogni comune pesa allo stesso modo, indipendentemente dalla popolazione.

Le barre possono essere ordinate secondo la sequenza naturale di una variabile ordinale oppure, per una variabile nominale, per frequenza decrescente. Il secondo ordinamento facilita l’individuazione delle categorie più comuni ed è alla base del diagramma di Pareto. Un grafico a torta comunica anch’esso una composizione, ma rende difficile confrontare spicchi simili e diventa rapidamente illeggibile con molte categorie; in genere le barre consentono confronti più precisi.

> ⚠ Conteggi o percentuali?
>
> I conteggi rispondono alla domanda “quante unità?”. Le percentuali rispondono alla domanda “quale quota del gruppo?”. Per confrontare campioni di diversa numerosità, i conteggi possono essere fuorvianti e sono spesso preferibili frequenze relative o percentuali.

3.3.2 Istogramma

L’**istogramma** descrive la distribuzione di una variabile quantitativa suddividendone i valori in classi adiacenti. Come visto nel capitolo precedente, l’area di ogni rettangolo deve essere proporzionale alla frequenza della classe. Quando le classi hanno ampiezza diversa, l’altezza corretta è quindi una densità, non il semplice conteggio.

La scelta delle classi modifica il livello di dettaglio. Classi molto ampie possono nascondere code o più addensamenti; classi troppo strette possono far apparire come struttura ciò che è soltanto irregolarità campionaria. È utile provare più suddivisioni e verificare che la conclusione principale non dipenda da una sola scelta.

```
par(mfrow = c(1, 2), mar = c(4, 4, 2, 1))

hist(
  dati_comuni$reddito,
  breaks = seq(15, 45, by = 5),
  freq = FALSE,
  col = "#9ECAE1",
  border = "white",
  main = "Classi più ampie",
  xlab = "Reddito (migliaia di euro)",
  ylab = "Densità"
)
```

```r
hist(
  dati_comuni$reddito,
  breaks = seq(15, 45, by = 2.5),
  freq = FALSE,
  col = "#9ECAE1",
  border = "white",
  main = "Classi più strette",
  xlab = "Reddito (migliaia di euro)",
  ylab = "Densità"
)
```

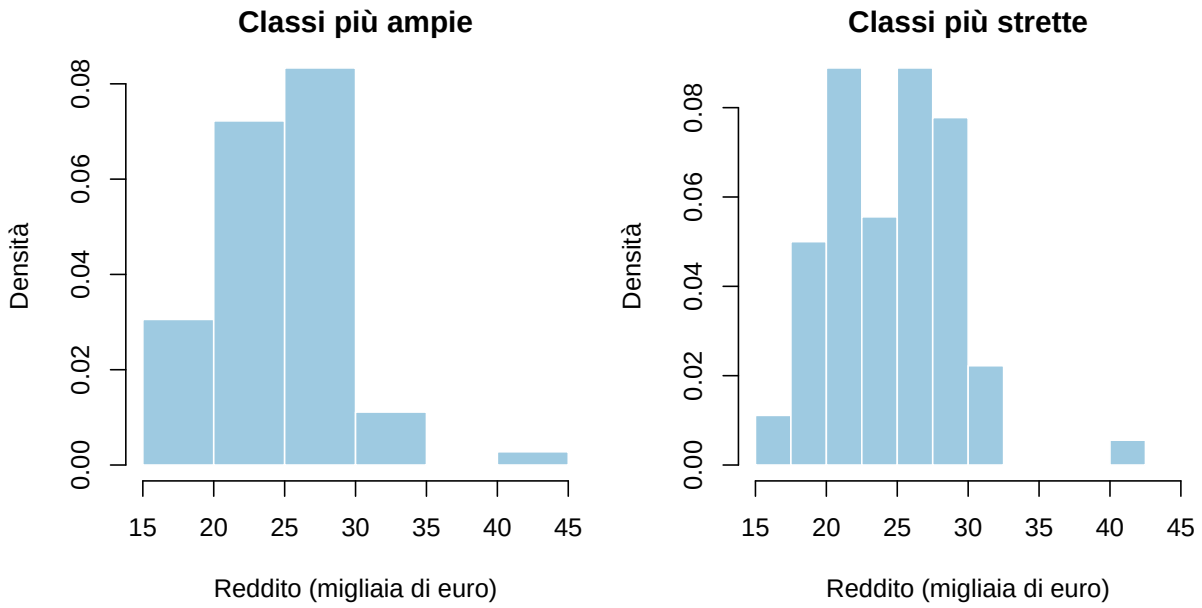


Figura 3.2: La distribuzione simulata del reddito con due diverse suddivisioni in classi.

```r
par(mfrow = c(1, 1))
```

Entrambe le versioni mostrano che la maggior parte dei comuni ha un reddito compreso approssimativamente tra 19 e 31 mila euro. Il valore di 42 mila euro produce una coda verso destra. La posizione precisa delle barre cambia, ma questa conclusione rimane visibile in entrambe le suddivisioni.

3.3.3 Funzione di ripartizione empirica e boxplot

La **funzione di ripartizione empirica** mostra, per ogni valore x, la quota di osservazioni non superiore a x. Indicandola con $F_n(x)$,

$$F_n(x) = \frac{\text{numero di osservazioni con valore non superiore a } x}{n},$$

dove n è il numero totale di osservazioni. La funzione cresce a gradini da 0 a 1 ed è utile per leggere percentili o confrontare soglie rilevanti. Non richiede la scelta delle classi dell'istogramma.

Il **boxplot** sintetizza invece mediana, primo e terzo quartile, intervallo interquartile e valori segnalati come anomali. È molto compatto, ma nasconde dettagli come addensamenti multipli e dimensione dei gruppi.

```r
par(mfrow = c(1, 2), mar = c(4, 4, 2, 1))

plot(
  ecdf(dati_comuni$reddito),
  verticals = TRUE,
  do.points = FALSE,
  main = "Frequenza cumulata",
  xlab = "Reddito (migliaia di euro)",
  ylab = "Quota cumulata"
)
abline(v = 25, lty = 2, col = "grey40")

boxplot(
  dati_comuni$reddito,
  horizontal = TRUE,
  col = "#9ECAE1",
  main = "Boxplot",
  xlab = "Reddito (migliaia di euro)"
)
```

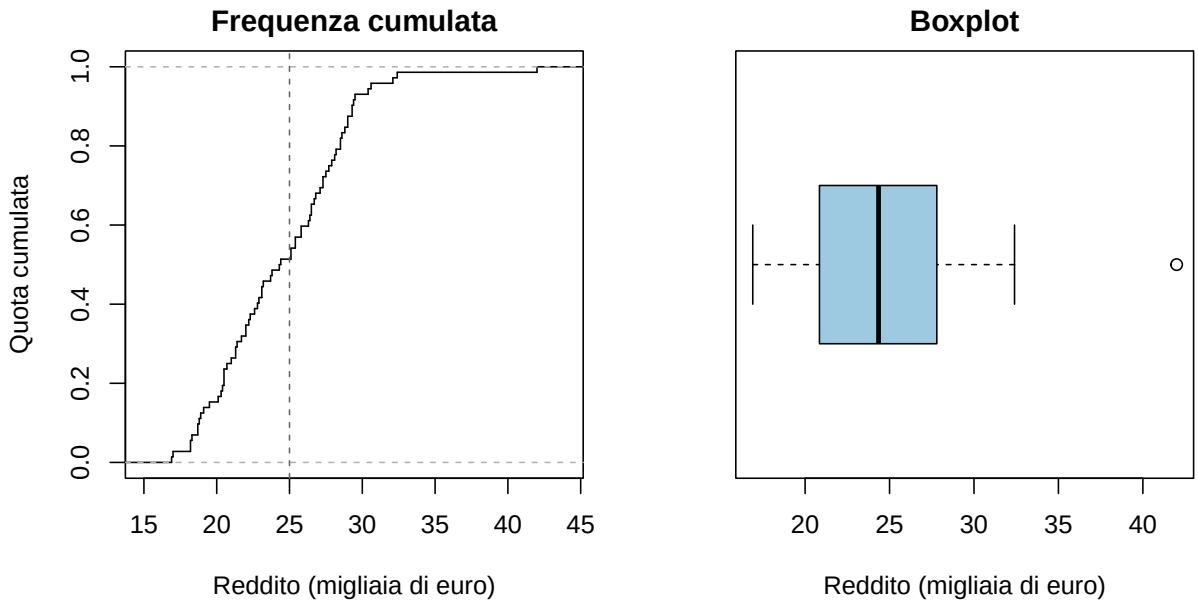


Figura 3.3: Funzione di ripartizione empirica e boxplot del reddito simulato.

```
par(mfrow = c(1, 1))
```

Il 51,4% dei comuni ha un reddito non superiore a 25 mila euro. Il boxplot individua 42 mila euro come valore anomalo secondo la regola di 1,5 intervalli interquartili. Il punto non deve essere cancellato automaticamente: il grafico segnala un caso da verificare, non stabilisce che si tratti di un errore.

3.4 Grafici bivariati

Un grafico bivariato studia due variabili congiuntamente. La domanda può riguardare un'associazione tra misure quantitative, un confronto tra gruppi o la composizione di categorie diverse.

3.4.1 Due variabili quantitative: lo scatterplot

In uno **scatterplot** ogni unità i è rappresentata dal punto di coordinate (x_i, y_i). Il valore x_i si legge sull'asse orizzontale e y_i su quello verticale. Il grafico permette di osservare direzione, forma e intensità dell'associazione, oltre a gruppi e osservazioni insolite.

```r
colori_area <- c(Nord = "#1B9E77", Centro = "#7570B3", Sud = "#D95F02")

plot(
  dati_comuni$reddito,
  dati_comuni$disoccupazione,
  pch = 19,
  col = colori_area[dati_comuni$area],
  xlab = "Reddito (migliaia di euro)",
  ylab = "Disoccupazione (%)"
)
legend(
  "topright",
  legend = names(colori_area),
  col = colori_area,
  pch = 19,
  bty = "n"
)
```

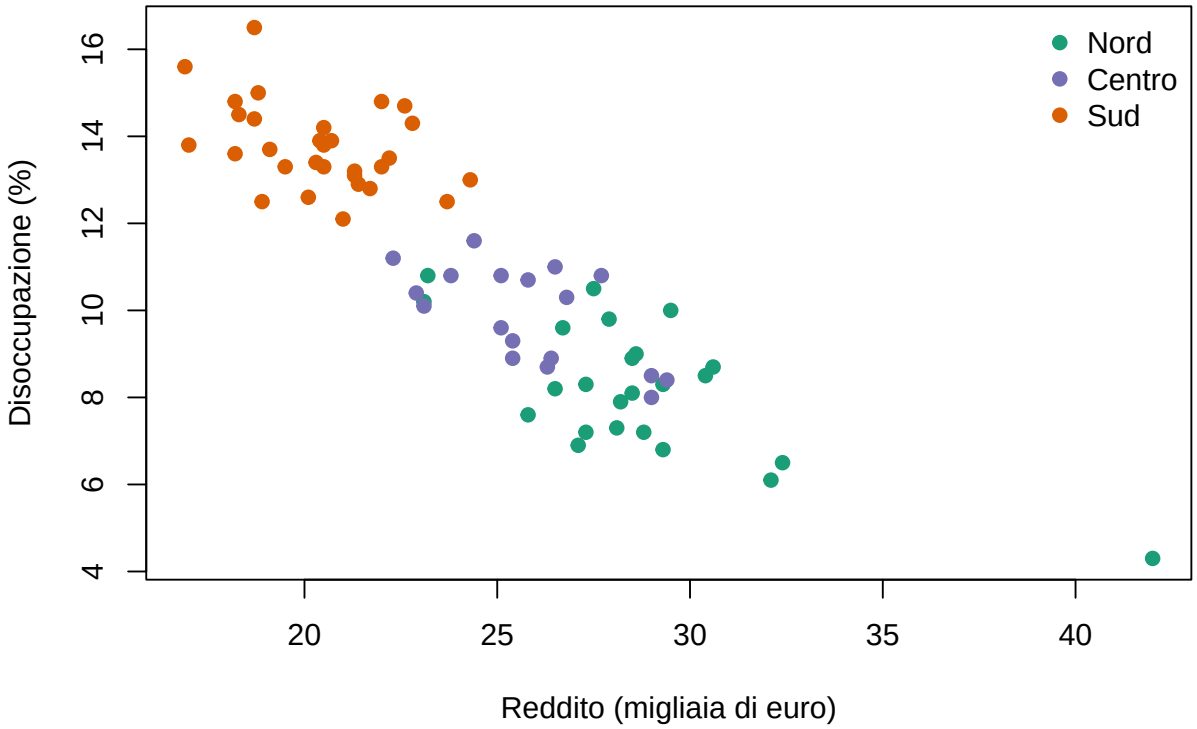


Figura 3.4: Reddito e disoccupazione nei comuni simulati, distinti per area.

La correlazione lineare nei dati simulati è -0,89. I punti indicano che i comuni con reddito

più elevato tendono ad avere una disoccupazione più bassa. I colori mostrano anche una separazione parziale tra aree: ignorare questa struttura nasconderebbe informazioni rilevanti. Il grafico descrive un'associazione costruita nella simulazione e non dimostra che il reddito causi la riduzione della disoccupazione.

Prima di riassumere uno scatterplot con una correlazione occorre controllare se la relazione è approssimativamente lineare, se sono presenti gruppi e se pochi punti dominano il risultato. Una correlazione vicina a zero non esclude una relazione curva.

3.4.2 Una variabile quantitativa e una qualitativa

I boxplot paralleli confrontano la distribuzione di una variabile quantitativa tra le modalità di una variabile qualitativa. Per un confronto corretto gli assi devono essere gli stessi. È utile indicare anche la numerosità dei gruppi, perché il boxplot non la rende immediatamente visibile.

```
etichette_area <- paste0(
  levels(dati_comuni$area),
  " (n=",
  as.vector(table(dati_comuni$area)),
  ")"
)

boxplot(
  reddito ~ area,
  data = dati_comuni,
  names = etichette_area,
  col = unname(colori_area),
  border = "grey30",
  xlab = "Area",
  ylab = "Reddito (migliaia di euro)"
)
```

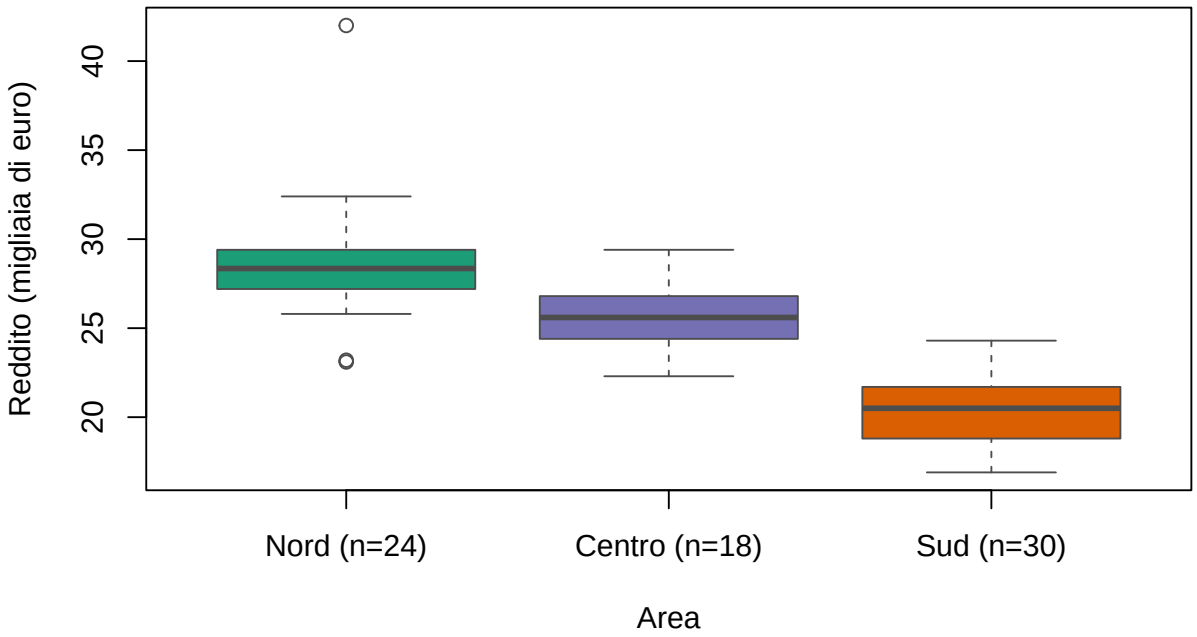


Figura 3.5: Distribuzione del reddito simulato per area; tra parentesi è riportato il numero di comuni.

Le mediane sono 28,35 mila euro al Nord, 25,60 al Centro e 20,50 al Sud. Queste differenze descrivono il campione simulato. Il grafico non separa l'effetto dell'area da composizione demografica, struttura produttiva o altre caratteristiche dei comuni e non autorizza quindi un'interpretazione causale.

3.4.3 Due variabili qualitative

Per confrontare una variabile qualitativa tra gruppi si possono usare barre affiancate o barre impilate al 100%. Le prime facilitano il confronto di una singola categoria; le seconde mostrano la composizione interna di ciascun gruppo. Le barre al 100% devono essere costruite con percentuali condizionate allo stesso denominatore di gruppo.

```
tabella_servizi <- table(dati_comuni$area, dati_comuni$servizi)
profili_area <- prop.table(tabella_servizi, margin = 1) * 100

barplot(
  t(profili_area),
  col = c("#D95F0E", "#FEC44F", "#238B45"),
  border = NA,
  ylab = "Comuni nell'area (%)",
```

```
  xlab = "Area",
  ylim = c(0, 115)
)
legend(
  "top",
  legend = colnames(profili_area),
  fill = c("#D95F0E", "#FEC44F", "#238B45"),
  horiz = TRUE,
  bty = "n",
  cex = 0.8
)
```

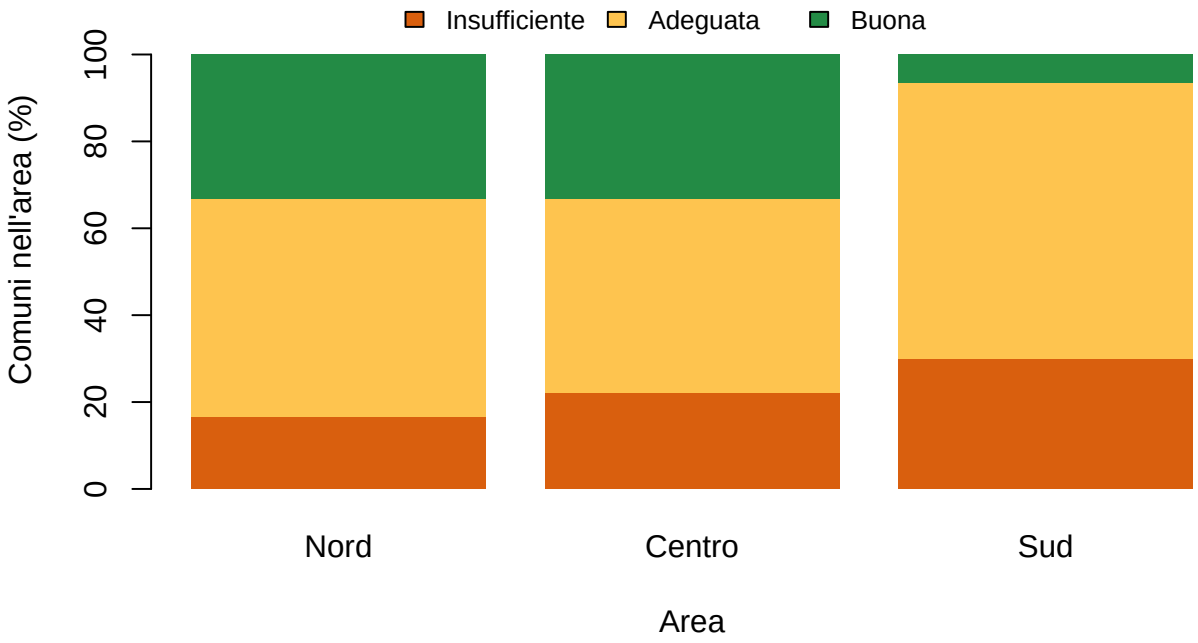


Figura 3.6: Composizione percentuale della valutazione dei servizi all'interno di ciascuna area simulata.

La valutazione "Buona" riguarda il 33,3% dei comuni del Nord e del Centro, ma soltanto il 6,7% di quelli del Sud. Le percentuali sono calcolate separatamente entro ciascuna area e sommano a 100 per ogni barra. Poiché i dati sono simulati e i gruppi hanno numerosità diversa, il grafico non rappresenta quote di popolazione residente e non misura la qualità effettiva dei servizi.

3.5 Serie temporali

In un grafico temporale l'asse orizzontale deve rispettare l'ordine e la distanza tra i periodi. Collegare i punti con una linea è sensato perché un'osservazione segue la precedente nel tempo. La stessa linea sarebbe ingannevole tra comuni ordinati alfabeticamente, dove non esiste continuità.

Il seguente indice simulato della spesa sociale pone il 2016 uguale a 100. Un valore di 112,5 significa che la spesa è del 12,5% superiore al livello dell'anno base, non che ammonta a 112,5 euro.

```
spesa_sociale <- data.frame(
  anno = 2016:2025,
  indice = c(100, 101.2, 102.4, 104.0, 103.5,
             108.8, 112.5, 115.1, 116.7, 118.3)
)

plot(
  spesa_sociale$anno,
  spesa_sociale$indice,
  type = "o",
  pch = 19,
  col = "#2C7FB8",
  xlab = "Anno",
  ylab = "Indice della spesa sociale (2016=100)",
  ylim = c(95, 125)
)
abline(h = 100, lty = 2, col = "grey50")
```

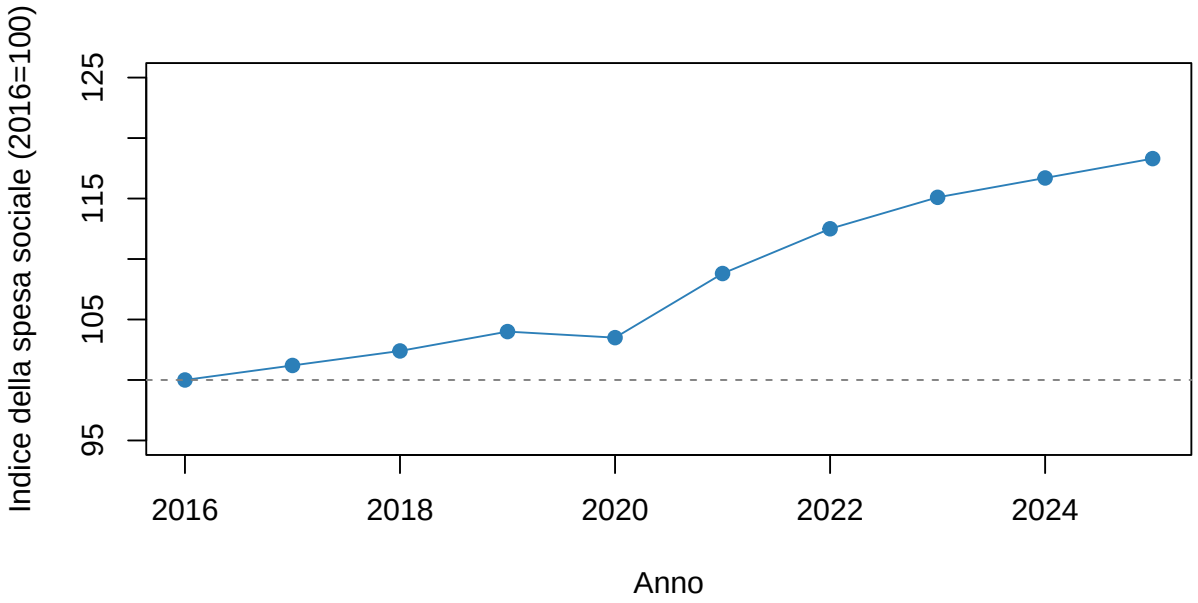


Figura 3.7: Indice simulato della spesa sociale, 2016=100.

Tra il 2016 e il 2025 l'indice cresce da 100 a 118,3, cioè del 18,3% rispetto all'anno base. Nel 2020 si osserva una lieve diminuzione e nel 2021 un incremento più marcato. Il grafico non identifica le cause di questi cambiamenti: per attribuirli a una politica o a uno shock servirebbero informazioni e un disegno di analisi ulteriori.

L'intervallo temporale scelto deve essere dichiarato. Selezionare soltanto gli anni favorevoli a una tesi può cambiare il messaggio. Anche la frequenza è importante: valori annuali possono nascondere stagionalità mensile o trimestrale, mentre dati ad alta frequenza possono enfatizzare oscillazioni di breve periodo.

3.6 Rappresentazioni territoriali

Una **carta tematica** associa valori o categorie ad aree geografiche. Nelle carte coropletiche ogni territorio è colorato in base a una variabile, per esempio il tasso di disoccupazione provinciale. Queste carte sono efficaci per individuare continuità, divari e raggruppamenti spaziali, ma richiedono alcune precauzioni:

- per confrontare territori di popolazione diversa sono normalmente preferibili tassi, quote o valori pro capite ai conteggi assoluti;
- territori più estesi occupano più spazio visivo, anche se contengono poche persone;
- numero e soglie delle classi cromatiche possono modificare la percezione dei divari;
- una categoria specifica deve distinguere i dati mancanti dai valori pari a zero;

- confini e unità territoriali devono essere coerenti con periodo e domanda di ricerca.

Una mappa mostra **dove** si osserva un fenomeno, non perché si verifichi. Territori vicini possono avere valori simili perché condividono istituzioni, infrastrutture o mercati del lavoro, ma la sola prossimità visiva non prova alcun meccanismo. I capitoli sui dati spaziali introdurranno strumenti specifici per studiare queste dipendenze.

3.7 Grafici corretti e grafici fuorvianti

Un grafico può contenere valori esatti e trasmettere comunque un'impressione distorta. Prima di interpretarlo conviene controllare i seguenti aspetti.

3.7.1 Scale e assi

Nei diagrammi a barre, troncare l'asse verticale può far apparire enorme una differenza modesta perché la lunghezza della barra viene letta rispetto allo zero. Per linee e scatterplot un asse ristretto può invece essere utile a mostrare variazioni piccole, purché i limiti siano visibili e non si esageri il messaggio. Scale logaritmiche possono rendere confrontabili crescite proporzionali, ma devono essere dichiarate e spiegate.

3.7.2 Dimensioni e decorazioni

Se un valore doppio viene rappresentato da un cerchio, deve raddoppiare l'area del simbolo, non il raggio. Grafici tridimensionali, prospettive e decorazioni possono alterare il confronto senza aggiungere informazione. La soluzione più semplice è spesso la più leggibile.

3.7.3 Doppi assi

Due scale verticali diverse permettono di far apparire quasi parallele o divergenti due serie modificando soltanto i limiti degli assi. Quando possibile è preferibile usare pannelli separati, indici con la stessa base o variazioni percentuali confrontabili. Un andamento comune non dimostra comunque che una serie determini l'altra.

3.7.4 Colori e accessibilità

Il colore dovrebbe codificare informazione. Per valori ordinati è adatta una scala progressiva dal chiaro allo scuro; per scostamenti positivi e negativi può essere utile una scala divergente con un punto centrale esplicito. Troppe tonalità, combinazioni rosso–verde o colori privi di legenda rendono il grafico meno accessibile. Il significato non dovrebbe dipendere soltanto dal colore quando simboli, etichette o tipi di linea possono aiutare.

3.7.5 Dati mancanti e incertezza

Una linea interrotta può segnalare un dato mancante; collegare automaticamente i punti suggerisce invece un andamento mai osservato. Quando i valori sono stime campionarie, intervalli di confidenza o bande d'incertezza aiutano a non trattare piccole differenze come certe. L'assenza di una barra o di un territorio colorato non deve essere interpretata come valore zero.

⚠ Una sequenza per la lettura critica

1. Leggere titolo, fonte, popolazione e periodo.
2. Identificare unità di analisi, variabili e unità di misura.
3. Controllare denominatori, assi, scale, classi e valori mancanti.
4. Descrivere ciò che il grafico mostra senza attribuire subito una causa.
5. Chiedersi quali scelte grafiche alternative potrebbero cambiare l'impressione.

3.8 Costruire un grafico: una procedura essenziale

Una procedura utile per l'analisi economica è:

1. formulare la domanda e identificare il confronto rilevante;
2. verificare tipo delle variabili, unità di analisi, periodo e qualità dei dati;
3. scegliere il grafico coerente con la struttura delle osservazioni;
4. costruire una prima versione semplice e controllare valori anomali o mancanti;
5. aggiungere titolo, assi, unità, legenda, fonte e numerosità quando necessaria;
6. verificare che scale e denominatori non alterino il confronto;
7. accompagnare il grafico con una breve interpretazione e con i suoi limiti.

Un buon grafico riduce il lavoro del lettore senza ridurre la complessità sostantiva del fenomeno. Deve permettere di distinguere ciò che è osservato da ciò che è ipotizzato e rendere trasparenti le scelte necessarie per passare dai dati a un messaggio.

4 Le serie storiche

Il tasso di disoccupazione di questo mese non è un'osservazione isolata. Assume significato quando viene confrontato con i mesi precedenti, con lo stesso mese degli anni passati e con la traiettoria di lungo periodo. Una **serie storica** è una sequenza di osservazioni dello stesso fenomeno ordinate nel tempo. L'ordine non è un dettaglio: contiene informazione.

Le serie storiche sono centrali nell'analisi economica e sociale. Permettono di descrivere l'evoluzione del PIL, riconoscere la stagionalità dei flussi turistici, monitorare la spesa pubblica, individuare cambiamenti nel mercato del lavoro e formulare previsioni. Presentano però una difficoltà specifica: osservazioni vicine nel tempo sono spesso dipendenti. I metodi che trattano i dati come liberamente intercambiabili possono quindi produrre conclusioni eccessivamente sicure o del tutto fuorvianti.

Questo capitolo introduce la logica dei modelli temporali e della previsione. Le trasformazioni, le variazioni e i numeri indice sono approfonditi nei capitoli dedicati. L'impostazione generale segue il percorso classico dall'esplorazione grafica alla decomposizione, alla modellazione dell'autocorrelazione e alla verifica delle previsioni (Hyndman e Athanasopoulos 2014).

4.1 Osservare un fenomeno nel tempo

Indichiamo una serie osservata con

$$y_1, y_2, \cdots, y_T,$$

dove y_t è il valore rilevato al tempo t e T è il numero totale di osservazioni. L'indice t può rappresentare anni, trimestri, mesi, giorni o intervalli ancora più brevi. In questo capitolo considereremo tempi discreti e, salvo diversa indicazione, equidistanti.

La notazione maiuscola Y_t sarà usata quando parliamo del valore come variabile aleatoria, cioè prima di osservarlo. L'insieme $\{Y_t\}$ è un **processo stocastico**: una famiglia di variabili aleatorie ordinate nel tempo. La sequenza effettivamente osservata $\{y_t\}$ è una sua realizzazione. Questa distinzione permette di rappresentare l'incertezza sui valori futuri senza supporre che il passato si ripeta esattamente.

4.1.1 Serie storiche e dati trasversali

Una cross-section confronta più unità nello stesso periodo, per esempio il reddito di 100 famiglie nel 2025. In quel caso l'ordine delle righe non ha normalmente significato. Una serie storica segue invece la stessa unità o lo stesso aggregato in periodi successivi, per esempio il reddito medio nazionale dal 2000 al 2025. Riordinare casualmente le osservazioni distruggerebbe trend, stagionalità e dipendenza temporale.

Non è corretto affermare che tutte le osservazioni trasversali siano indipendenti o che ogni serie presenti dipendenza. Si tratta di proprietà da valutare. Nei dati territoriali, per esempio, unità vicine possono essere associate; una serie di rumore bianco, invece, non presenta autocorrelazione pur essendo ordinata nel tempo.

4.1.2 Frequenza, calendario e natura della misura

La **frequenza** indica quante osservazioni sono disponibili in un ciclo temporale di riferimento. Una serie annuale ha frequenza 1, una trimestrale 4 e una mensile 12. La frequenza determina quali strutture possono essere studiate: con dati annuali non possiamo identificare una stagionalità mensile.

Occorre anche distinguere:

- una variabile di **stock**, misurata in un istante, come il numero di disoccupati al 31 dicembre;
- una variabile di **flusso**, accumulata durante un intervallo, come la spesa pubblica sostenuta in un anno;
- una **media di periodo**, come il tasso medio mensile di inflazione.

Sommare dodici stock mensili non produce uno stock annuale. Al contrario, i flussi mensili possono essere sommati se definizioni e prezzi sono coerenti. Prima di modellare una serie bisogna quindi documentare frequenza, calendario, unità di misura, eventuale destagionalizzazione, prezzi correnti o costanti e revisioni dei dati.

> ⚠ Frequenze più alte non significano sempre più informazione
>
> Dati mensili o giornalieri contengono più osservazioni, ma anche rumore, effetti di calendario e dipendenze più complesse. Aggregare può nascondere eventi brevi; disaggregare senza dati reali può invece inventare una precisione inesistente.

4.2 Un esempio mensile simulato

Useremo una serie mensile simulata di accessi al trasporto pubblico, espressi in migliaia. La serie va da gennaio 2018 a dicembre 2025 e contiene un trend crescente, una struttura stagionale, una caduta temporanea nel 2020–2021 e un cambiamento di livello dal 2023. È costruita soltanto a fini didattici e non rappresenta una città reale.

```
set.seed(2026)

numero_periodi <- 96
tempo <- seq_len(numero_periodi)

profilo_stagionale <- c(
  -4, -2, 1, 3, 5, 7,
  10, 8, 4, 1, -1, -3
)

shock_temporaneo <- rep(0, numero_periodi)
shock_temporaneo[27:36] <- -30
shock_temporaneo[37:48] <- -15

cambio_livello <- ifelse(tempo >= 61, 6, 0)

accessi <- round(
  100 + 0.25 * tempo +
    rep(profilo_stagionale, times = 8) +
    shock_temporaneo + cambio_livello +
    rnorm(numero_periodi, mean = 0, sd = 2),
  1
)

accessi_ts <- ts(
  accessi,
  start = c(2018, 1),
  frequency = 12
)

head(accessi_ts, 12)
```

```
       Jan   Feb   Mar   Apr   May   Jun   Jul   Aug   Sep   Oct   Nov   Dec
2018  97.3  96.3 102.0 103.8 104.9 103.5 110.3 108.0 106.5 102.6 100.9  98.5
```

La funzione `ts()` conserva la frequenza e il periodo iniziale. R può così riconoscere che gennaio 2020 viene dodici osservazioni dopo gennaio 2019. Mostriamo soltanto il primo anno perché l'output completo sarebbe lungo; il grafico temporale è più informativo.

```
plot(
  accessi_ts,
  type = "l",
  lwd = 1.5,
  col = "#2C7FB8",
  xlab = "Anno",
  ylab = "Accessi mensili (migliaia)"
)
abline(v = c(2020 + 2 / 12, 2023), lty = 2, col = "grey50")
```

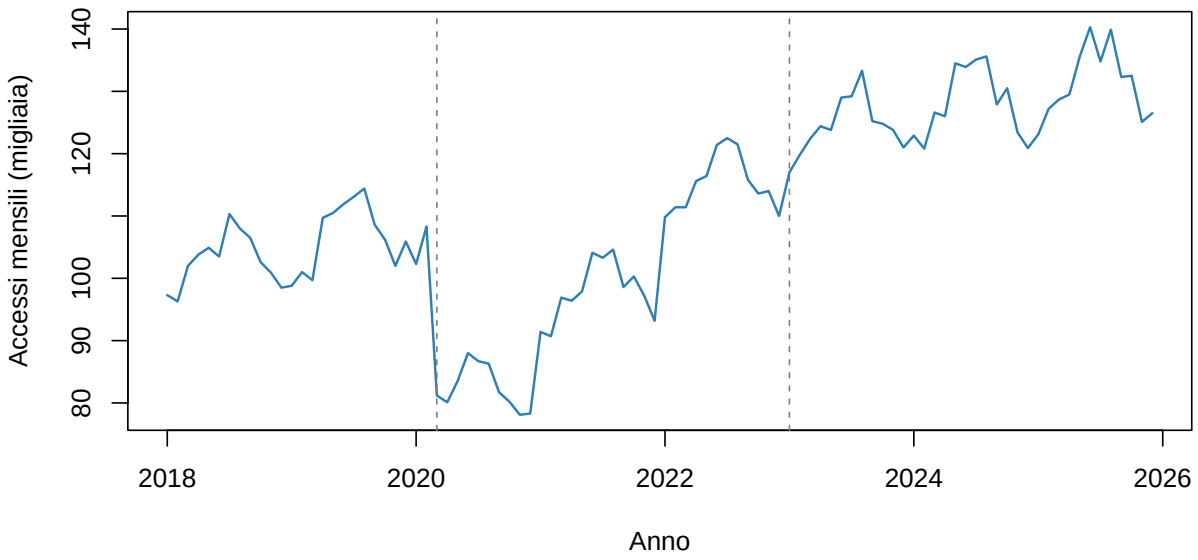


Figura 4.1: Accessi mensili simulati al trasporto pubblico, in migliaia.

La media mensile passa da 102,9 mila accessi nel 2018 a 131,3 mila nel 2025. Nel 2020 scende a 86,2 mila. Il grafico mostra inoltre picchi e minimi che tendono a ripetersi nello stesso periodo dell'anno. Questi risultati sono caratteristiche della simulazione, non stime di un fenomeno reale.

4.3 Le componenti di una serie storica

Separare idealmente una serie in componenti aiuta a distinguere movimenti persistenti, regolarità di calendario e variazioni inattese.

- Il **trend** rappresenta l'evoluzione di lungo periodo. Può crescere, diminuire o cambiare pendenza.
- La **stagionalità** è una variazione che si ripete con periodo noto e stabile, per esempio ogni dodici mesi o ogni quattro trimestri.
- Il **ciclo** comprende oscillazioni di durata non fissa, spesso più lunghe della stagione, come espansioni e recessioni economiche.
- La componente **irregolare** o resto raccoglie ciò che le altre componenti non spiegano: rumore, shock, errori di misura e strutture non modellate.

Stagione e ciclo non sono sinonimi. Agosto torna ogni dodici mesi, mentre una fase recessiva non ha una durata prestabilita. Inoltre, una decomposizione non è unica: ciò che appare come trend con un metodo può essere attribuito al ciclo con un altro.

4.3.1 Decomposizione additiva e moltiplicativa

Nel modello additivo la serie è rappresentata come

$$Y_t = T_t + S_t + C_t + I_t,$$

dove T_t è il trend, S_t la stagionalità, C_t il ciclo e I_t la componente irregolare al tempo t. La forma additiva è appropriata quando l'ampiezza delle oscillazioni stagionali rimane circa costante al variare del livello.

Nel modello moltiplicativo,

$$Y_t = T_t \times S_t \times C_t \times I_t,$$

le fluttuazioni sono proporzionali al livello della serie. È adatto soltanto a valori positivi. Applicando il logaritmo, i prodotti diventano somme: per esempio $\log(Y_t) = \log(T_t) + \log(S_t) + \log(C_t) + \log(I_t)$. Questa equivalenza collega la decomposizione moltiplicativa alle trasformazioni discusse nel capitolo successivo.

4.3.2 Una decomposizione con R

La procedura STL separa la serie in stagionalità, trend e resto. Non identifica una componente ciclica distinta: il ciclo viene assorbito soprattutto nel trend o nel resto. Impostiamo una stagione periodica e una stima robusta, meno sensibile a valori eccezionali.

```r
decomposizione_accessi <- stl(
  accessi_ts,
  s.window = "periodic",
  robust = TRUE
)

plot(decomposizione_accessi)
```

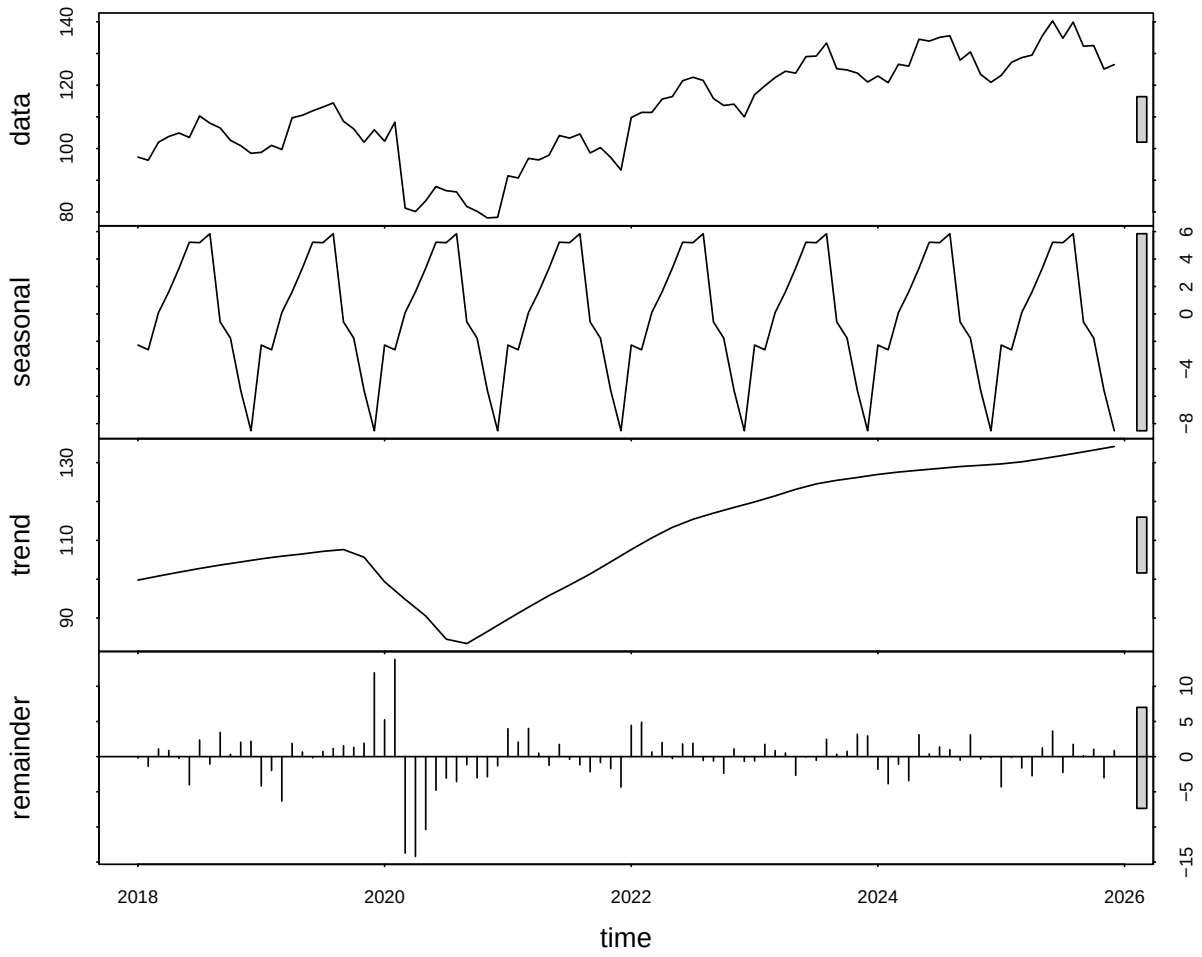


Figura 4.2: Decomposizione STL degli accessi simulati: dati, stagionalità, trend e resto.

La componente stagionale stimata è positiva tra la tarda primavera e l'estate e negativa soprattutto negli ultimi mesi dell'anno. La caduta del 2020 e la ripresa successiva compaiono nel trend e nel resto. Questo mostra un limite importante: uno shock prolungato può contaminare la stima delle componenti e non deve essere scambiato automaticamente per normale stagionalità.

4.4 Stazionarietà: una base relativamente stabile

Molti modelli temporali cercano regolarità che possano essere trasferite dal passato al futuro. Questo è più plausibile quando la serie oscilla attorno a un livello stabile e la sua variabilità non cambia sistematicamente.

In termini intuitivi, una serie è **stazionaria** se le sue proprietà statistiche non dipendono dal momento in cui viene osservata. Per la stazionarietà debole richiediamo:

$$E(Y_t) = \mu, \qquad Var(Y_t) = \sigma^2, \qquad Cov(Y_t, Y_{t-k}) = \gamma_k.$$

Il simbolo $E(Y_t)$ indica il valore medio teorico, costante e pari a μ; $Var(Y_t)$ è la varianza, costante e pari a σ^2; $Cov(Y_t, Y_{t-k})$ è la covarianza tra valori distanti k periodi e dipende dal ritardo k, non dalla data t. Non chiediamo che la serie sia piatta: può oscillare e presentare cicli non periodici. Trend, stagionalità regolare o varianza crescente sono invece segnali di non stazionarietà.

La stazionarietà non è una proprietà che un grafico possa certificare definitivamente. È un'ipotesi di lavoro da valutare con grafici, autocorrelazioni, conoscenza del fenomeno ed eventualmente test specifici. Un campione breve può rendere stazionaria una serie che, osservata più a lungo, presenta un cambiamento strutturale.

4.4.1 Differenze e trasformazioni

Una trasformazione può rendere più stabile una serie. La prima differenza è

$$\Delta Y_t = Y_t - Y_{t-1},$$

e misura il cambiamento assoluto tra due periodi consecutivi. Per dati mensili, la differenza stagionale

$$\Delta_{12} Y_t = Y_t - Y_{t-12}$$

confronta lo stesso mese in anni consecutivi. In generale, $\Delta_m Y_t = Y_t - Y_{t-m}$, dove m è il periodo stagionale. Differenziare può rimuovere trend o stagionalità, ma riduce il numero di osservazioni e cambia la domanda: non si modella più il livello, bensì la variazione.

```r
par(mfrow = c(3, 1), mar = c(3, 4, 2, 1))

plot(
  accessi_ts,
  type = "l",
  main = "Livello",
  xlab = "",
  ylab = "Accessi"
)
plot(
  diff(accessi_ts),
  type = "l",
  main = "Prima differenza",
  xlab = "",
  ylab = expression(Delta * Y[t])
)
plot(
  diff(accessi_ts, lag = 12),
  type = "l",
  main = "Differenza stagionale",
  xlab = "Anno",
  ylab = expression(Delta[12] * Y[t])
)
```

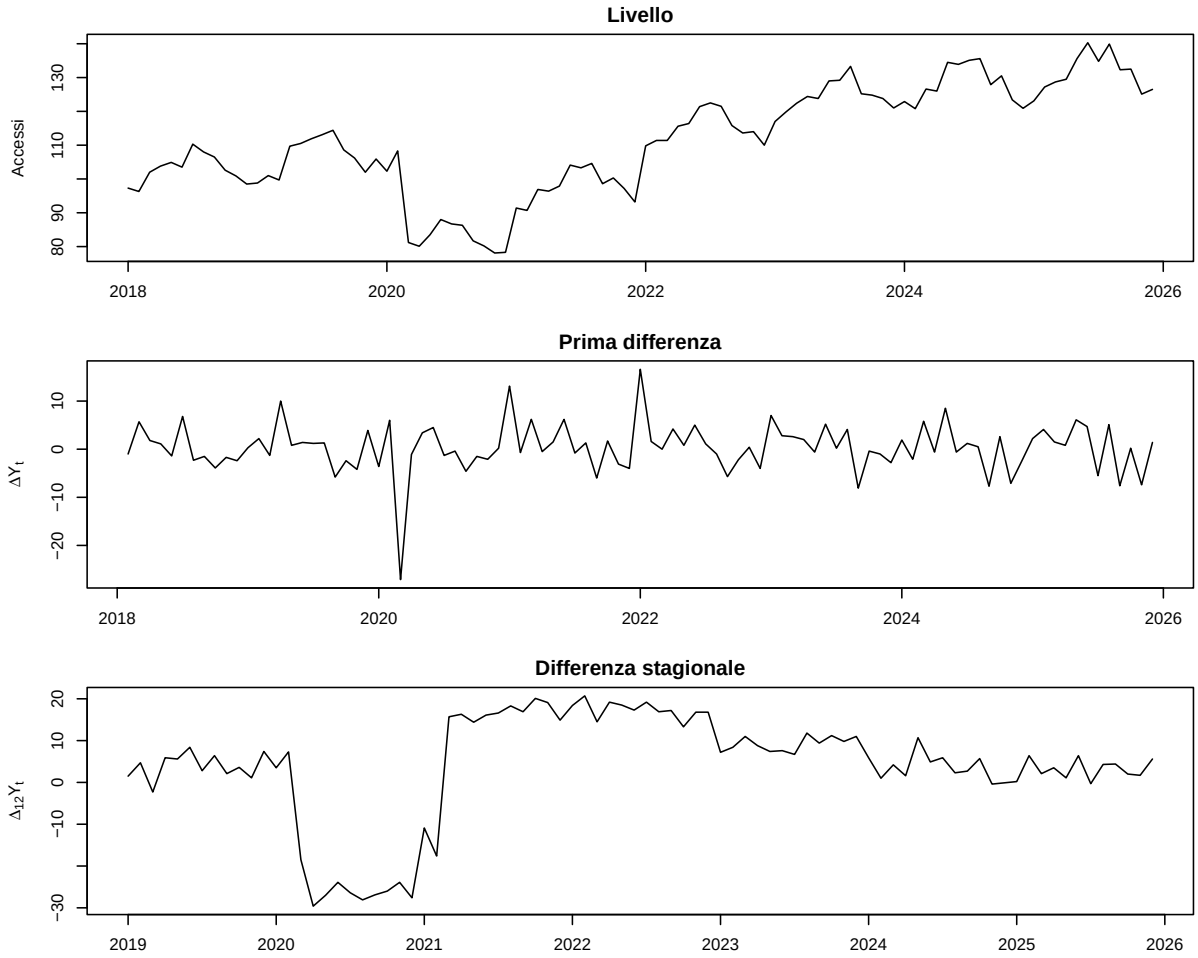


Figura 4.3: Serie simulata in livello, prima differenza e differenza stagionale.

```
par(mfrow = c(1, 1))
```

Le differenze attenuano il trend, ma gli shock generano variazioni molto grandi. La differenza stagionale conserva inoltre il cambiamento di livello e la ripresa graduale. Non esiste una trasformazione che renda innocui eventi sostantivamente importanti: questi devono essere riconosciuti e, se necessario, modellati esplicitamente.

> **Differenziare troppo**
>
> Applicare differenze ripetute finché il grafico “sembra casuale” può introdurre dipendenza artificiale e amplificare il rumore. Ogni differenza deve avere un’interpretazione: variazione sul periodo precedente oppure rispetto alla stessa stagione dell’anno passato.

4.5 Autocorrelazione e memoria temporale

L'**autocorrelazione** confronta una serie con una versione ritardata di sé stessa. L'autocorrelazione teorica al ritardo, o *lag*, k è

$$\rho_k = Corr(Y_t, Y_{t-k}) = \frac{Cov(Y_t, Y_{t-k})}{\sqrt{Var(Y_t)Var(Y_{t-k})}}.$$

Il coefficiente ρ_k varia tra -1 e 1. Un valore positivo indica che osservazioni sopra la media tendono a essere seguite, dopo k periodi, da osservazioni sopra la media; un valore negativo indica alternanza. Con dati mensili, un valore elevato a $k = 12$ può segnalare stagionalità annuale.

La **funzione di autocorrelazione** (ACF) raccoglie le autocorrelazioni per diversi ritardi. La **funzione di autocorrelazione parziale** (PACF) misura il legame tra Y_t e Y_{t-k} dopo avere tenuto conto dei ritardi intermedi $Y_{t-1}, \dots, Y_{t-k+1}$. La PACF sarà utile per distinguere alcune strutture autoregressive.

```
par(mfrow = c(1, 2), mar = c(4, 4, 2, 1))

acf(
  accessi_ts,
  lag.max = 36,
  main = "Serie in livello",
  xlab = "Ritardo (anni)"
)
acf(
  diff(accessi_ts),
  lag.max = 36,
  main = "Prima differenza",
  xlab = "Ritardo (anni)"
)
```

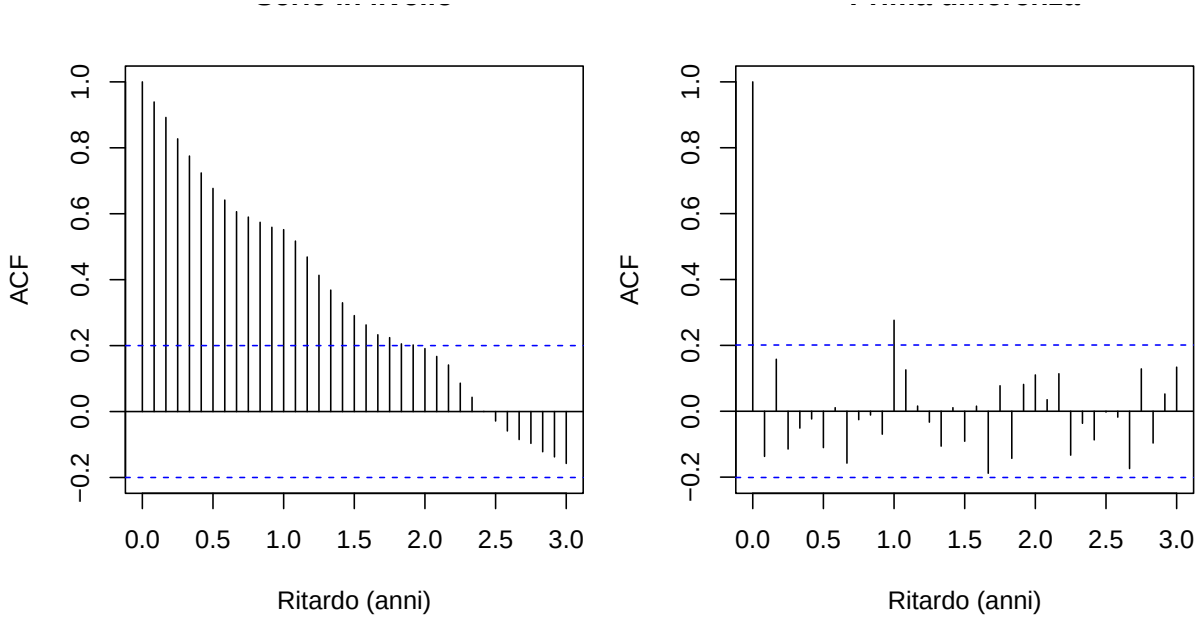


Figura 4.4: ACF degli accessi simulati in livello e dopo la prima differenza.

```
par(mfrow = c(1, 1))
```

In livello l'autocorrelazione al primo ritardo è circa 0,94 e decresce lentamente. Questo andamento riflette soprattutto trend, stagionalità e cambiamenti persistenti; non basta per concludere che esista un semplice meccanismo autoregressivo. Dopo la prima differenza, la dipendenza a breve si riduce, mentre rimangono tracce della struttura stagionale e degli shock.

Le linee tratteggiate dell'ACF sono limiti approssimativi calcolati sotto l'ipotesi di assenza di autocorrelazione. Un singolo picco appena oltre il limite può verificarsi per caso quando si osservano molti ritardi. Occorre interpretare l'insieme dei picchi e verificare i residui del modello, non selezionare soltanto il valore più appariscente.

4.5.1 Rumore bianco

Una serie $\{\varepsilon_t\}$ è **rumore bianco** se ha media zero, varianza costante e autocorrelazione nulla a ogni ritardo non nullo. Il simbolo ε_t rappresenta un'innovazione: una nuova componente non prevedibile usando il passato della serie.

Rumore bianco non significa necessariamente distribuzione normale. La normalità è un'ipotesi aggiuntiva, utile soprattutto per costruire intervalli di previsione. Se i residui di un modello presentano autocorrelazione, rimane informazione temporale non utilizzata e il modello può essere migliorato.

4.6 Modelli AR, MA e ARMA

Una volta ottenuta una serie approssimativamente stazionaria, possiamo rappresentarne la memoria con modelli parsimoniosi. L'obiettivo non è riprodurre ogni oscillazione, ma descrivere la parte prevedibile lasciando residui simili a rumore bianco.

4.6.1 Modello autoregressivo

Un modello autoregressivo di ordine p, abbreviato AR(p), usa i p valori precedenti della serie:

$$Y_t - \mu = \phi_1(Y_{t-1} - \mu) + \cdots + \phi_p(Y_{t-p} - \mu) + \varepsilon_t.$$

La costante μ è il livello medio della serie; $\phi_1, \ldots, \phi_p$ sono i coefficienti autoregressivi; p è il numero di ritardi inclusi; ε_t è rumore bianco. In un AR(1), un coefficiente $\phi_1 = 0{,}7$ indica che il 70% dello scostamento dal livello medio tende a persistere nel periodo successivo. Non significa che il valore aumenti del 70%.

Per un AR(1) stazionario deve valere $|\phi_1| < 1$. Se ϕ_1 è vicino a 1, gli shock si esauriscono lentamente; se è negativo, la serie tende ad alternarsi sopra e sotto la media. Per ordini maggiori le condizioni di stazionarietà sono più articolate e vengono gestite dal software.

4.6.2 Modello a media mobile

Un modello a media mobile di ordine q, MA(q), usa l'innovazione corrente e le q innovazioni precedenti:

$$Y_t = \mu + \varepsilon_t + \theta_1\varepsilon_{t-1} + \cdots + \theta_q\varepsilon_{t-q},$$

dove $\theta_1, \ldots, \theta_q$ misurano quanto gli shock passati incidono sul valore corrente. In un MA(1), uno shock ha un effetto diretto per due periodi: quello in cui avviene e il successivo.

Il modello MA non deve essere confuso con la **media mobile usata per lo smoothing**. Lo smoothing calcola medie di osservazioni passate per rendere visibile il trend; il modello MA combina innovazioni non osservate per rappresentare la dinamica probabilistica.

4.6.3 Modello ARMA

Un ARMA(p, q) combina le due strutture:

$$Y_t - \mu = \sum_{i=1}^{p} \phi_i (Y_{t-i} - \mu) + \varepsilon_t + \sum_{j=1}^{q} \theta_j \varepsilon_{t-j}.$$

Gli indici i e j contano rispettivamente i ritardi autoregressivi e quelli delle innovazioni. Il modello ARMA è pensato per serie stazionarie. In linea ideale, la PACF di un AR(p) si interrompe dopo il ritardo p, mentre l'ACF di un MA(q) si interrompe dopo q; nei modelli misti entrambe tendono a decadere. Nei campioni reali questi schemi sono raramente netti: ACF e PACF suggeriscono modelli candidati, ma non sostituiscono confronto e diagnostica.

4.6.4 Simulare e stimare un AR(1)

Simuliamo gli scostamenti mensili di un indicatore dalla propria media di lungo periodo. Il processo generatore ha coefficiente autoregressivo 0,65; nella pratica questo valore sarebbe ignoto e dovrebbe essere stimato.

```
set.seed(2027)

scostamenti <- arima.sim(
  model = list(ar = 0.65),
  n = 120,
  sd = 1.2
)

modello_ar1 <- arima(
  scostamenti,
  order = c(1, 0, 0),
  include.mean = TRUE,
  method = "ML"
)

stima_ar1 <- data.frame(
  parametro = c("phi_1", "media"),
  stima = round(coef(modello_ar1), 3),
  errore_standard = round(
    sqrt(diag(modello_ar1$var.coef)),
    3
  )
```

```
)

stima_ar1
```

```
          parametro stima errore_standard
ar1           phi_1 0.681           0.067
intercept     media 0.061           0.336
```

Il coefficiente stimato è 0,681, vicino al valore 0,65 usato nella simulazione. Uno scostamento di un punto nel mese corrente è associato, in media, a uno scostamento di circa 0,68 punti nello stesso verso il mese successivo. La media stimata è 0,061, coerente con una serie costruita per oscillare attorno a zero. L'errore standard quantifica la precisione campionaria della stima, non la variabilità futura dell'indicatore.

4.6.5 Diagnostica dei residui

Il residuo al tempo t è

$$e_t = y_t - \hat{y}_{t|t-1},$$

dove y_t è il valore osservato e $\hat{y}_{t|t-1}$ è la previsione di y_t costruita usando le informazioni disponibili fino a $t-1$. Un buon modello non deve lasciare nei residui un andamento prevedibile.

```
residui_ar1 <- residuals(modello_ar1)

par(mfrow = c(1, 2), mar = c(4, 4, 2, 1))

plot(
  residui_ar1,
  type = "l",
  main = "Residui nel tempo",
  xlab = "Mese",
  ylab = "Residuo"
)
abline(h = 0, lty = 2, col = "grey50")

acf(
  residui_ar1,
  lag.max = 24,
```

```
  main = "ACF dei residui"
)
```

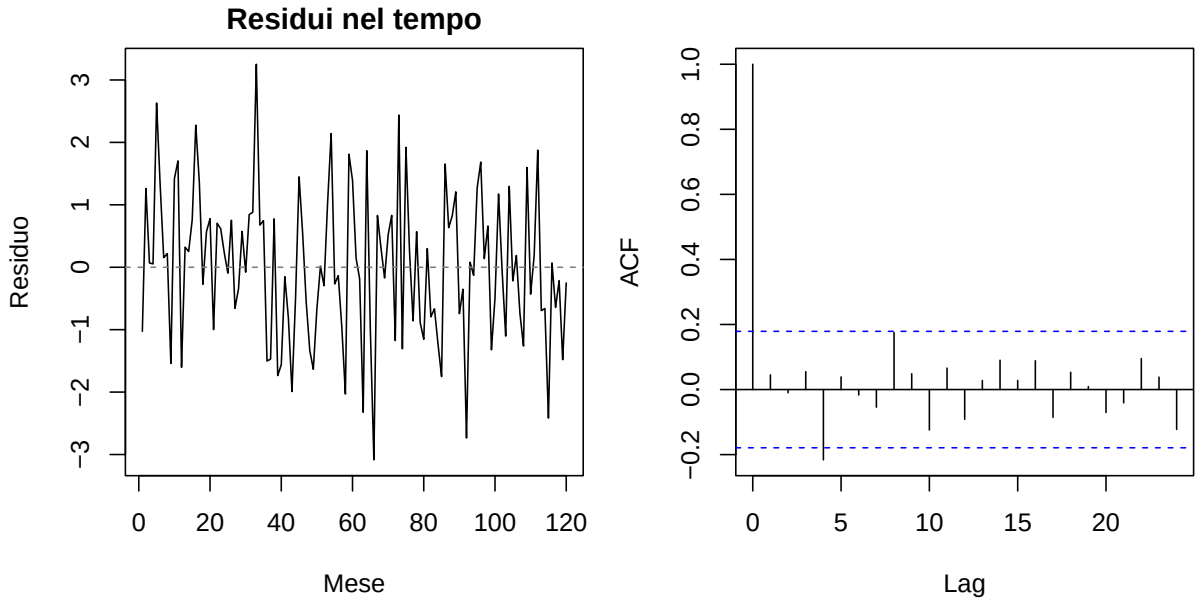


Figura 4.5: Residui e loro funzione di autocorrelazione per il modello AR(1) simulato.

```
par(mfrow = c(1, 1))
```

```
test_residui <- Box.test(
  residui_ar1,
  lag = 12,
  type = "Ljung-Box",
  fitdf = 1
)

round(
  c(
    statistica = unname(test_residui$statistic),
    p_value = test_residui$p.value
  ),
  3
)
```

```
statistica    p_value
    15.242      0.172
```

Il test di Ljung–Box esamina congiuntamente le autocorrelazioni residue fino al ritardo 12. Il *p-value* è 0,172: non emerge evidenza sufficiente per respingere l'ipotesi di assenza di autocorrelazione. Questo non prova che il modello sia vero; indica soltanto che questa diagnostica non rileva memoria residua rilevante. Vanno controllati anche stabilità della varianza, valori anomali e adeguatezza sostantiva.

4.7 Da ARMA ad ARIMA e SARIMA

Se la serie non è stazionaria, un modello ARMA può essere applicato a una sua versione differenziata. Un modello ARIMA(p, d, q) combina:

- p termini autoregressivi;
- d differenze ordinarie;
- q termini a media mobile.

La lettera I significa *integrated* e segnala che le differenze devono essere reintegrate per riportare le previsioni alla scala originale. Un ARIMA$(1, 1, 0)$, per esempio, applica un AR(1) alle prime differenze della serie.

Per una serie stagionale si può usare la notazione

$$ARIMA(p, d, q)(P, D, Q)_m,$$

dove (p, d, q) descrive la dinamica non stagionale, (P, D, Q) la dinamica stagionale e m il numero di osservazioni per ciclo, per esempio $m = 12$ per dati mensili. D indica il numero di differenze stagionali. Questi modelli sono spesso chiamati **SARIMA**.

L'ordine più complesso non è automaticamente migliore. Una procedura ragionevole consiste nel:

1. rappresentare la serie e documentare valori anomali o break;
2. applicare trasformazioni motivate;
3. differenziare soltanto quanto necessario;
4. usare ACF e PACF per individuare pochi modelli candidati;
5. confrontare criteri informativi e prestazioni previsive;
6. controllare che i residui siano compatibili con rumore bianco;
7. produrre previsioni con la relativa incertezza.

Una selezione automatica può aiutare nei passaggi centrali, ma non riconosce da sola errori di definizione, cambiamenti istituzionali o shock destinati a non ripetersi.

4.8 Prevedere non significa indovinare

Una previsione usa l'informazione disponibile fino al tempo T per stimare Y_{T+h}, dove h è l'**orizzonte di previsione**. Indichiamo la previsione puntuale con $\hat{y}_{T+h|T}$: il pedice significa "valore per $T+h$ previsto usando informazioni fino a T".

La previsione puntuale è un singolo valore. Un **intervallo di previsione** esprime invece un insieme di valori plausibili e dovrebbe allargarsi quando l'orizzonte aumenta. L'intervallo incorpora l'incertezza delle innovazioni future sotto il modello scelto, ma spesso non include pienamente incertezza sui parametri, scelta del modello o futuri cambiamenti strutturali.

4.8.1 Previsioni dal modello AR(1)

```
orizzonte <- 6
previsione_ar1 <- predict(
  modello_ar1,
  n.ahead = orizzonte
)

tempi_futuri <- 121:(120 + orizzonte)
limite_inferiore <- previsione_ar1$pred -
  1.96 * previsione_ar1$se
limite_superiore <- previsione_ar1$pred +
  1.96 * previsione_ar1$se

plot(
  scostamenti,
  type = "l",
  xlim = c(80, 126),
  ylim = range(
    scostamenti[80:120],
    limite_inferiore,
    limite_superiore
  ),
  xlab = "Mese",
  ylab = "Scostamento dalla media"
)
polygon(
  c(tempi_futuri, rev(tempi_futuri)),
  c(limite_inferiore, rev(limite_superiore)),
  col = adjustcolor("#9ECAE1", alpha.f = 0.5),
```

```
  border = NA
)
lines(
  tempi_futuri,
  previsione_ar1$pred,
  col = "#D95F02",
  lwd = 2
)
abline(h = coef(modello_ar1)["intercept"], lty = 2)
```

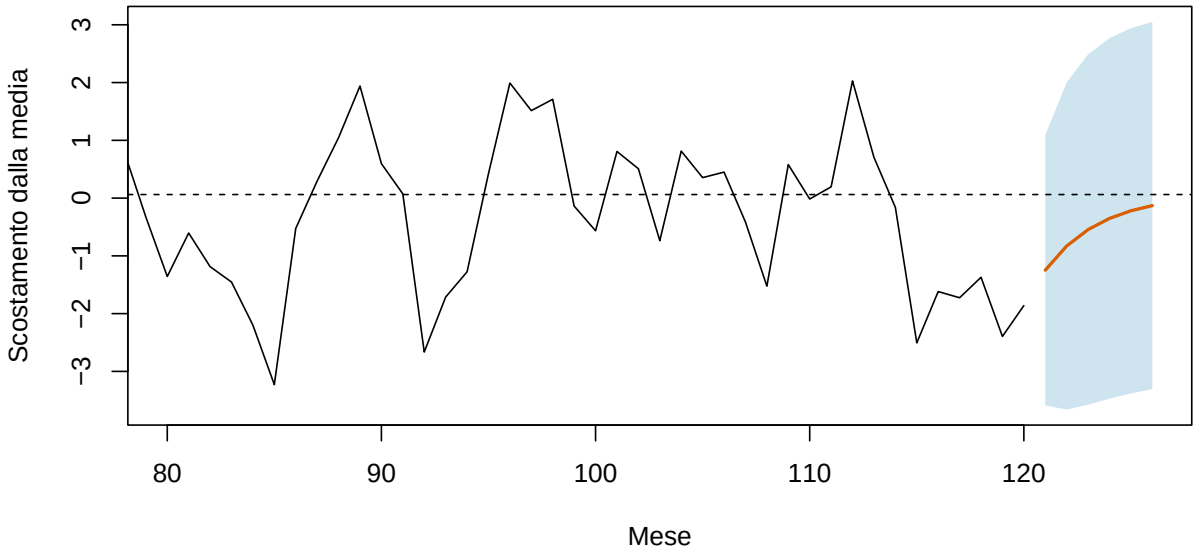


Figura 4.6: Previsioni a sei periodi del modello AR(1) e intervalli approssimativi al 95%.

La previsione per il primo mese è -1,25 punti e poi si avvicina progressivamente alla media stimata: l'effetto dell'ultimo scostamento si attenua perché $|\widehat{\phi}_1| < 1$. L'intervallo al 95% è circa da -3,59 a 1,09 al primo passo e diventa più ampio nei passi successivi. "95%" è una proprietà della procedura sotto le ipotesi del modello, non la garanzia che ogni singolo intervallo contenga il futuro.

4.8.2 Metodi di riferimento

Un modello elaborato deve essere confrontato con previsioni semplici. Il metodo **naïve** usa l'ultimo valore osservato per tutti gli orizzonti. Il metodo **stagionale naïve** usa il valore dell'ultima stagione corrispondente: per gennaio 2025, per esempio, usa gennaio 2024.

Separiamo il 2025 della serie degli accessi come insieme di test. I modelli vengono costruiti con i dati fino al 2024; solo dopo confrontiamo le previsioni con i valori realmente riservati al test.

```r
accessi_training <- window(
  accessi_ts,
  end = c(2024, 12)
)
accessi_test <- window(
  accessi_ts,
  start = c(2025, 1)
)

previsione_naive <- rep(
  tail(accessi_training, 1),
  12
)
previsione_stagionale <- as.numeric(
  window(
    accessi_training,
    start = c(2024, 1),
    end = c(2024, 12)
  )
)

mae <- function(errori) {
  mean(abs(errori))
}
rmse <- function(errori) {
  sqrt(mean(errori^2))
}

errori_naive <- as.numeric(accessi_test) - previsione_naive
errori_stagionali <- as.numeric(accessi_test) -
  previsione_stagionale

accuratezza <- rbind(
  naive = c(
    MAE = mae(errori_naive),
    RMSE = rmse(errori_naive)
  ),
  stagionale_naive = c(
    MAE = mae(errori_stagionali),
    RMSE = rmse(errori_stagionali)
  )
)
```

```
round(accuratezza, 2)
```

```
                   MAE  RMSE
naive            10.39 11.69
stagionale_naive  3.17  3.83
```

Il **MAE** è la media degli errori assoluti; il **RMSE** è la radice della media degli errori quadratici e penalizza maggiormente gli errori grandi. Nel test simulato, il metodo stagionale naïve ottiene MAE 3,17 e RMSE 3,83, nettamente inferiori a 10,39 e 11,69 del naïve non stagionale. La stagionalità contiene quindi informazione previsiva utile. Il risultato riguarda questo specifico periodo di test: un solo confronto non stabilisce quale metodo sia sempre migliore.

> ⚠ Errore frequente: valutare sul campione di stima
>
> Un modello flessibile può adattarsi molto bene ai dati usati per stimarlo e prevedere male nuovi periodi. Per confrontare metodi previsivi occorre preservare l'ordine temporale: si stima sul passato e si valuta su un blocco successivo, senza mescolare casualmente osservazioni future e passate.

4.9 Shock, valori anomali e cambiamenti strutturali

Un'osservazione insolita può avere significati diversi:

- un **outlier additivo** altera soprattutto un singolo periodo, per esempio un errore di registrazione;
- uno **shock temporaneo** produce un effetto che si esaurisce gradualmente;
- un **cambiamento di livello** sposta persistentemente la media della serie;
- un **break di tendenza** modifica la velocità o la direzione del trend;
- un **cambiamento stagionale** altera ampiezza o forma della stagione.

La distinzione è sostantiva prima che statistica. Una revisione della definizione di disoccupato, una riforma fiscale e un errore di battitura richiedono trattamenti differenti. Correggere un errore documentato è appropriato; cancellare una recessione perché peggiora il modello significa eliminare il fenomeno di interesse.

I modelli ARIMA assumono che la struttura stimata sia sufficientemente stabile nel periodo di previsione. Un break rende questa estrapolazione fragile. Si possono introdurre variabili di intervento, stimare modelli separati prima e dopo il cambiamento o accorciare il campione, ma ogni scelta richiede una giustificazione e riduce l'informazione disponibile.

4.10 Quando i dati non sono gaussiani

I modelli ARMA e ARIMA sono spesso presentati assumendo innovazioni gaussiane. L'ipotesi è comoda per costruire intervalli, ma non è sempre plausibile.

Una serie di conteggi, come il numero giornaliero di proteste o di accessi a un servizio, assume valori interi non negativi. Se i valori sono piccoli o presentano molti zeri, un modello lineare può produrre previsioni negative e intervalli poco credibili. Modelli log-lineari e modelli autoregressivi per conteggi, come gli INAR, rispettano meglio questa struttura.

Se l'esito è uno stato qualitativo, per esempio "recessione/espansione" oppure il partito al governo, l'oggetto di interesse può essere la probabilità di passare da uno stato all'altro. Le catene di Markov descrivono queste transizioni. In tutti questi casi la scelta del modello deve partire dal supporto della variabile e dalla domanda, non dalla disponibilità di una funzione software. Una trattazione formale di tali modelli va oltre gli obiettivi introduttivi del capitolo.

4.11 Una procedura per l'analisi delle serie storiche

Una sequenza di lavoro trasparente è la seguente:

1. definire fenomeno, unità, frequenza, calendario e periodo;
2. documentare fonte, revisioni, valori mancanti e trasformazioni già applicate;
3. rappresentare la serie e cercare trend, stagionalità, shock e break;
4. distinguere descrizione, previsione e valutazione causale;
5. verificare se la stazionarietà è un'approssimazione plausibile;
6. applicare differenze o trasformazioni soltanto quando interpretabili;
7. proporre pochi modelli e confrontarli con riferimenti semplici;
8. controllare residui e stabilità della struttura;
9. valutare le previsioni su periodi non usati nella stima;
10. comunicare previsioni puntuali, intervalli e limiti.

Un modello temporale sfrutta regolarità del passato. Può essere utile per programmare servizi, costruire scenari e quantificare l'incertezza, ma non trasforma automaticamente una successione temporale in un nesso causale. Se una politica viene introdotta nello stesso momento in cui un indicatore cambia, la coincidenza è un punto di partenza per l'analisi, non la sua conclusione.

5 Trasformazioni di serie storiche

Una spesa pubblica che passa da 420 a 450 milioni di euro è aumentata di 30 milioni. Questi valori presentati in questo modo forniscono un'informazione povera e piena di ambiguità. Ad esempio, è abbastanza natnaturale chiedersi tutta una serie di domande collaterali, come:

- Questo aumento è da considerarsi "grande" o "piccolo"?
- I prezzi sono cambiati?
- La popolazione servita è cresciuta a livello economico?
- Il benessere globale è migliorato?
- Il confronto riguarda due mesi con lo stesso numero di giorni lavorativi?
- Il livello osservato risente della normale stagionalità?

In pratica, le serie storiche "grezze", ovvero contenenti i dati così come sono state raccolti, sono spesso rielaborate per ottenere delle ifnormazioni più corpose e permettere così di rispondere a domande di questo tipo. Per fare questo si fa uso di una serie di **trasformazioni** matematiche, ovvero delle operazioni che cambiano la scala o la forma della serie. Non si tratta di operazioni puramente tecniche, ma tramite l'applicazione di funzioni che rispondono ad una serie di caratteristiche (es. continue e monotone), è possibile mettere in evidenza un aspetto del fenomeno e, allo stesso tempo, attenuarne altri.

Nell'analisi economica si fa uso di trasformazioni per preparare i dati e renderli più adatti all'analisi (Hyndman e Athanasopoulos 2014), e servono soprattutto a:

- confrontare grandezze con livelli o unità differenti;
- distinguere crescita nominale e crescita reale;
- tenere conto della dimensione della popolazione o del calendario;
- rendere più regolari trend, stagionalità e variabilità;
- preparare una serie per l'analisi e la previsione.

Una trasformazione appropriata dipende sempre dalla domanda empirica. La stessa serie può essere studiata in livello, in differenze assolute, in tassi di crescita o in termini reali. Nessuna di queste rappresentazioni è universalmente migliore, è il contesto di ricerca che indurrà a ferci preferire una trasformazione piuttosto che un'altra.

5.1 Dal livello alla variazione

Indichiamo con Y_t il valore di una grandezza al tempo t e con y_t il valore effettivamente osservato. Il livello conserva l'unità originaria: euro, occupati, tonnellate, voti o posti letto. È la rappresentazione naturale quando interessa la dimensione del fenomeno.

Per valutare la dinamica nel tempo confrontiamo y_t con un valore precedente. Se le osservazioni sono annuali, $y_t - y_{t-1}$ è il cambiamento rispetto all'anno precedente; se sono mensili, è il cambiamento rispetto al mese precedente.

5.1.1 Variazione assoluta

Detta anche **differenza prima**, esprime la variazione assoluta tra due periodi consecutivi:

$$\Delta y_t = y_t - y_{t-1},$$

dove il simbolo Δ indica l'operatore di differenza. La variazione è positiva se il fenomeno aumenta, nulla se rimane invariato e negativa se diminuisce. Mantiene la stessa unità di misura della serie.

> **Nota 3: Occupati**
>
> Se gli occupati passano da 80.000 a 82.400, la differenza è $82.400 - 80.000 = 2.400$: vi sono 2.400 occupati in più. Questa informazione è utile per programmare servizi o valutare la dimensione complessiva del mercato del lavoro, ma non dice se l'aumento sia "grande" o "piccolo" rispetto alla situazione iniziale.

Possiamo confrontare periodi distanti h intervalli:

$$\Delta_h y_t = y_t - y_{t-h},$$

dove h è il numero di periodi che separa le osservazioni. Con dati mensili, $h = 12$ confronta lo stesso mese di due anni consecutivi. La differenza stagionale è stata introdotta nel capitolo sulle serie storiche.

5.1.2 Variazione relativa e percentuale

La **variazione relativa** ha come riferimento una differenza prima, ma ne rapporta il cambiamento al livello iniziale:

$$g_t = \frac{y_t - y_{t-1}}{y_{t-1}} = \frac{y_t}{y_{t-1}} - 1.$$

Il simbolo g_t indica il tasso di variazione tra $t-1$ e t. In pratica si passa ad un valore relativo, ed infatti g_t è un numero puro: non dipende dall'unità in cui è espressa la grandezza. Moltiplicandolo per 100 otteniamo la variazione percentuale. Nell'esempio Esempio 3 si otterrebbe:

$$g_t = \frac{82.400 - 80.000}{80.000} = 0{,}03,$$

quindi gli occupati sono aumentati del 3%. Attenzione a come leggere il risultato! Ad essere precisi, per ottenere il valore percentuale occorre moltiplicare $0,03$ per 100, quindi il tasso di crescita è pari 3%. Dire "0,03%" sarebbe un errore: 0,03 è il tasso espresso in forma decimale, mentre 3 è lo stesso tasso espresso in percentuale.

Per un confronto a distanza di h periodi usiamo

$$g_t^{(h)} = \frac{y_t - y_{t-h}}{y_{t-h}}.$$

Il denominatore è il valore di partenza. Se il denominatore è uguale a zero, il tasso non è definito, mentre se è molto piccolo il risultato può essere enorme e poco informativo. In questi casi la variazione relativa non è un indicatore sufficientemente informativo. In alternativa, si può presentare la variazione assoluta e descrivere esplicitamente il cambiamento.

> **i** Nota 3: Percentuali e punti percentuali non sono la stessa cosa
>
> Se il tasso di disoccupazione passa dall'8% al 10%, l'aumento è di **2 punti percentuali**. In termini relativi, invece, è $(10-8)/8 = 0{,}25$, cioè il 25%. Le due affermazioni sono corrette, ma rispondono a domande diverse.

5.1.3 Crescite successive e crescita media

Attenzione a come gestire i tassi di crescita. Si noti che non è possibile sommare i tassi relativi di periodi successivi, perché ogni variazione si applica a una base diversa. Supponiamo che una spesa aumenti del 10% e poi diminuisca del 10%. In maniera (erroneamente) intuitiva, si potrebbe pensare che il livello finale sia uguale a quello iniziale. In realtà, la diminuzione del 10% si applica a un valore più alto di quello iniziale, quindi il risultato è sicuramente inferiore al punto di partenza. I valori sono $g_t = 1{,}10$ e $g_{t+1} = 0{,}90$. Se volessimo calcolare il tasso complessivo tra $t-1$ e $t+1$, dovremmo moltiplicare i fattori di crescita:

$$y_0 \times 1{,}10 \times 0{,}90 = 0{,}99 y_0,$$

quindi il tasso complessivo di crescita risulta essere inferiore dell'1% al valore iniziale!

L'aumento necessario per compensare una diminuzione percentuale è sempre più grande, in valore assoluto, della diminuzione stessa: dopo una perdita del 50% occorre una crescita del 100% per tornare al livello iniziale.

Tra il periodo 0 e il periodo T, definiamo il **tasso medio composto** come

$$\bar{g} = \left(\frac{y_T}{y_0} \right)^{1/T} - 1,$$

dove T è il numero di intervalli temporali e $\bar{g}$ è il tasso costante che produrrebbe lo stesso cambiamento complessivo. Non è la media aritmetica dei tassi annuali. Inoltre, descrive una traiettoria equivalente: non implica che il fenomeno sia realmente cresciuto allo stesso ritmo ogni anno.

> **Nota 3: Esempio simulato**
>
> Consideriamo dati didattici sulla spesa sociale di un territorio. I valori sono costruiti e non descrivono un ente reale. La spesa è espressa in milioni di euro; l'indice dei prezzi vale 100 nel 2019; la popolazione è il numero di residenti. Non vi è casualità nella costruzione, quindi non occorre fissare un seme.

```r
anno <- 2019:2025
spesa_nominale <- c(420, 438, 470, 492, 525, 557, 585)
indice_prezzi <- c(100.0, 101.2, 103.4, 110.2, 116.7, 123.0, 126.5)
popolazione <- c(500000, 498000, 496000, 493000, 491000, 488000, 486000)

dati_spesa <- data.frame(
  anno,
  spesa_nominale,
  indice_prezzi,
  popolazione
)

dati_spesa$variazione_milioni <- c(NA, diff(dati_spesa$spesa_nominale))
dati_spesa$crescita_percentuale <- c(
  NA,
  100 * diff(dati_spesa$spesa_nominale) /
    head(dati_spesa$spesa_nominale, -1)
)

risultati_variazioni <- data.frame(
  anno = dati_spesa$anno,
  spesa_milioni = dati_spesa$spesa_nominale,
  variazione_milioni = dati_spesa$variazione_milioni,
  crescita_percentuale = round(dati_spesa$crescita_percentuale, 2)
)

risultati_variazioni
```

```
  anno spesa_milioni variazione_milioni crescita_percentuale
1 2019           420                 NA                   NA
2 2020           438                 18                 4.29
3 2021           470                 32                 7.31
4 2022           492                 22                 4.68
5 2023           525                 33                 6.71
6 2024           557                 32                 6.10
7 2025           585                 28                 5.03
```

La prima riga contiene valori mancanti per le variazioni perché non disponiamo dei dati al 1018 perchè è precedente al 2019. Dal 2019 al 2020 la spesa cresce di 18 milioni, pari al 4,3% circa. Dal 2024 al 2025 aumenta invece di 28 milioni, ma il tasso è circa il 5,0% perché il livello di partenza è molto più alto. Differenza assoluta e variazione percentuale offrono quindi informazioni complementari.

5.2 Logaritmi e tassi di crescita

Quando le oscillazioni aumentano insieme al livello della serie, il logaritmo può rendere la variabilità più uniforme. È utile anche quando il processo è "naturalmente" moltiplicativo, come nel caso di diversi fenomeni finanziari (come redditi, prezzi, ammortamenti, interessi, etc.) i quali evolvono spesso attraverso fattori di crescita variabili e non necessariamente costanti. Per valori strettamente positivi definiamo

$$w_t = \log(y_t),$$

dove log indica il logaritmo naturale e w_t è la serie trasformata. Il logaritmo ha un effetto di "compressione" dei dati, trasformando quantità derivanti da prodotti in somme: detto in altri termini la trasformazione logaritmica "allontana osservazioni vicine mentre avvicina quelle lontane". Per esempio, se $y_t = y_{t-1}(1 + g_t)$, allora

$$\Delta \log(y_t) = \log(y_t) - \log(y_{t-1}) = \log\left(\frac{y_t}{y_{t-1}}\right) = \log(g_t + 1).$$

⚠ Quando non è possibile utilizzare il logaritmo

Si ricordino le carattersitiche del logaritmo. Il logaritmo naturale non è definito per zero o valori negativi., quindi nel caso in cui abbiamo valori di $y_t \leq 0$ non è possibile calcolare il logaritmo. In alcuni casi però si hanno a disposiozione dati non negativi, ovvero $y_t \geq 0$, dove però lo zero è compreso. In questi casi particolari, si pyò ricorrere ad una correzione ulteriore, ovvero aggiungere automaticamente una costante nell'argomento del logaritmo:

$$\log(y_t + 1)$$

Questo approccio aiuta a risolvere tecnicamente il problema nel caso in cui si presentino valori nulli di y_t. Il problema è che questo aggiustamento cambia totalmente il significato della trasformazione e non è trascurabile, soprattutto quando y_t sono valori piccoli tendenti a zero, in tal caso il risultato presenterebbe un errore di approssimazione non trascurabile. Quindi, la scelta si usare il logaritmo e di effettuare successive correzioni va motivata correttamente e nel caso in cui i dati presentano valori nulli è preferibile ricorrere ad altri metodi più specifici.

Il logaritmo non elimina necessariamente il trend o la stagionalità. Può stabilizzare l'ampiezza delle oscillazioni, mentre le differenze agiscono soprattutto sui cambiamenti di livello. Le due operazioni rispondono a problemi distinti e, quando necessario, possono essere combinate. Trasformazioni di potenza più generali, come la famiglia Box–Cox, esistono ma sono rinviate ai corsi di previsione più avanzati.

5.3 Correggere per gli effetti di calendario

I totali mensili possono variare solo perché i mesi hanno un numero diverso di giorni o di giornate lavorative. Se un servizio registra 3.100 accessi in un mese di 31 giorni e 2.800 in uno di 28, entrambi corrispondono a 100 accessi medi al giorno. Il totale è diverso, l'intensità giornaliera no.

Se y_t è il totale del mese e d_t il numero di giorni rilevanti, la media giornaliera è

$$y_t^{day} = \frac{y_t}{d_t}.$$

Per vendite o produzione si possono usare i giorni lavorativi; per pronto soccorso o trasporto pubblico possono essere rilevanti tutti i giorni oppure categorie separate di giorni. La scelta del denominatore deve riflettere il processo osservato.

Correggere per il calendario non significa eliminare la stagionalità. Festività mobili, chiusure scolastiche e comportamenti stagionali possono rimanere anche dopo avere tenuto conto della lunghezza del mese. Inoltre, il totale mensile resta la misura appropriata quando interessa il carico complessivo di lavoro o di spesa.

5.4 Stagionalità e destagionalizzazione

La stagionalità è una variazione che tende a ripetersi nello stesso periodo dell'anno. Può nascondere il movimento congiunturale: un calo dell'occupazione tra dicembre e gennaio potrebbe essere normale, mentre un calo più forte di quello abituale può segnalare un peggioramento.

La **destagionalizzazione** rimuove la componente stagionale stimata. Nel modello additivo,

$$y_t = T_t + S_t + R_t,$$

la serie destagionalizzata è $y_t - S_t = T_t + R_t$. I simboli T_t, S_t e R_t indicano rispettivamente trend-ciclo, stagionalità e resto al tempo t. Nel modello moltiplicativo $y_t = T_t S_t R_t$, la serie destagionalizzata è y_t / S_t.

La serie destagionalizzata non coincide con il trend. Contiene ancora il resto, gli shock e gli errori di misura. Inoltre, poiché la componente stagionale viene stimata, i valori destagionalizzati più recenti possono essere rivisti quando arrivano nuove osservazioni.

5.4.1 Differenza stagionale o destagionalizzazione?

La differenza stagionale

$$\Delta_m y_t = y_t - y_{t-m}$$

confronta la stessa stagione a distanza di un ciclo, dove $m = 12$ per dati mensili e $m = 4$ per dati trimestrali. Cambia l'oggetto di studio: produce una serie di variazioni annuali. La destagionalizzazione, invece, conserva una stima del livello al netto della stagione.

Per comunicare la dinamica economica sono comuni due confronti:

- la variazione **congiunturale**, tra periodi consecutivi, spesso calcolata su dati destagionalizzati;
- la variazione **tendenziale**, rispetto allo stesso periodo dell'anno precedente, che attenua una stagionalità stabile ma incorpora tutto ciò che è accaduto nei dodici mesi.

I due tassi non sono intercambiabili. Un indicatore può crescere rispetto al mese precedente e restare inferiore allo stesso mese dell'anno precedente.

5.5 Smussare una serie per leggere il segnale

Una **media mobile centrata** sostituisce ogni osservazione con la media di un intorno temporale. Se l'ampiezza della finestra è un numero dispari $m = 2k + 1$, possiamo scrivere

$$\tilde{y}_t = \frac{1}{m} \sum_{j=-k}^{k} y_{t+j},$$

dove $\tilde{y}_t$ è il valore smussato, m è il numero di osservazioni nella finestra e k è il numero di periodi considerati prima e dopo t. Una finestra più ampia produce una linea più regolare, ma può nascondere svolte importanti.

Costruiamo una serie mensile di richieste a un servizio comunale. I dati sono simulati, includono trend, stagionalità e rumore, e non rappresentano un comune reale.

```
set.seed(2028)

numero_mesi <- 72
tempo <- seq_len(numero_mesi)
stagione <- rep(c(8, 5, 2, -2, -5, -7, -9, -6, 0, 4, 9, 11), 6)

richieste <- 120 + 0.6 * tempo + stagione +
```

```
  rnorm(numero_mesi, mean = 0, sd = 5)

richieste_ts <- ts(
  round(richieste),
  start = c(2020, 1),
  frequency = 12
)

media_mobile_5 <- stats::filter(
  richieste_ts,
  filter = rep(1 / 5, 5),
  sides = 2
)
```

```
plot(
  richieste_ts,
  type = "l",
  col = "grey55",
  xlab = "Anno",
  ylab = "Numero di richieste"
)
lines(media_mobile_5, col = "#D95F02", lwd = 2)
legend(
  "topleft",
  legend = c("Serie mensile", "Media mobile a 5 termini"),
  col = c("grey55", "#D95F02"),
  lty = 1,
  lwd = c(1, 2),
  bty = "n"
)
```

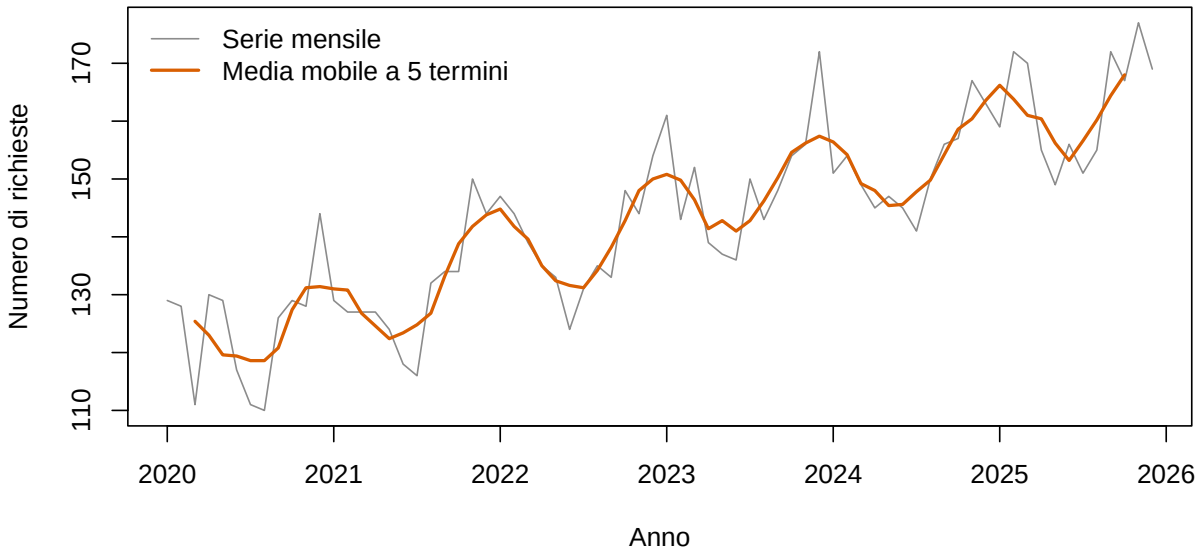


Figura 5.1: Richieste mensili simulate e media mobile centrata a cinque termini.

La linea smussata rende più visibile l'aumento di fondo, ma attenua i massimi e i minimi mensili. Mancano inoltre due valori a ciascuna estremità: una media centrata a cinque termini richiede due osservazioni passate e due future. Non può quindi essere calcolata in tempo reale per gli ultimi due mesi senza adottare una procedura diversa.

> **Smussare non significa correggere**
>
> La media mobile non dimostra che le oscillazioni eliminate siano errori. Può nascondere shock reali e non sostituisce una procedura di destagionalizzazione. Inoltre, la media mobile usata per smussare i dati non va confusa con il modello MA discusso nel capitolo sulle serie storiche.

Filtri come Hodrick–Prescott o Baxter–King cercano di separare trend e ciclo imponendo ipotesi specifiche sulle frequenze da conservare. Possono essere utili in analisi macroeconomiche avanzate, ma il risultato dipende dai parametri scelti e può cambiare sensibilmente agli estremi del campione. In un corso introduttivo è più importante comprendere questa dipendenza che applicare automaticamente un filtro.

5.6 Valori anomali e cambiamenti strutturali

Una trasformazione può mettere in evidenza osservazioni insolite, ma non decide come interpretarle. Nelle serie economiche è utile distinguere almeno:

- un **outlier additivo**, cioè un valore isolato eccezionalmente alto o basso;

- uno **shock temporaneo**, il cui effetto persiste per alcuni periodi e poi si attenua;
- un **cambiamento di livello**, dopo il quale la serie si stabilizza attorno a un nuovo livello;
- un **cambiamento di tendenza**, che modifica la velocità o la direzione dell'evoluzione;
- un **cambiamento stagionale**, che altera il profilo ricorrente durante l'anno.

Le possibili cause comprendono eventi reali, modifiche normative, crisi, riclassificazioni amministrative, cambiamenti nella rilevazione ed errori di registrazione. Prima di correggere un valore occorre quindi controllare metadati, definizioni e fonti. Un errore accertato può essere corretto documentando la procedura; uno shock reale deve normalmente restare nei dati ed essere spiegato o modellato.

Le differenze richiedono particolare cautela. Un singolo valore eccezionalmente alto al tempo t produce spesso una grande differenza positiva in t e una grande differenza negativa in $t+1$, anche se vi è stato un solo evento. Il grafico della serie originaria deve sempre accompagnare quello della serie trasformata.

> ⚠ Eliminare gli outlier può eliminare il fenomeno
>
> La caduta dell'occupazione durante una crisi o l'aumento della spesa sanitaria durante un'emergenza non sono automaticamente errori. Rimuoverli per rendere la serie più regolare può cancellare proprio l'evento che l'analisi dovrebbe comprendere.

5.7 Come scegliere una trasformazione

Una procedura essenziale può seguire questi passaggi:

1. **Chiarire la domanda.** Interessa il livello, il cambiamento, il potere d'acquisto, l'intensità pro capite o la dinamica al netto della stagione?
2. **Documentare la serie.** Verificare unità, frequenza, natura di stock o flusso, base dei prezzi, popolazione di riferimento, calendario e valori mancanti.
3. **Osservare i livelli.** Un grafico della serie originaria permette di riconoscere trend, stagionalità, shock e cambiamenti di variabilità.
4. **Applicare una trasformazione motivata.** Calcolare differenze, tassi, logaritmi o correzioni soltanto se rispondono alla domanda o a un problema diagnostico.
5. **Conservare entrambe le scale.** Confrontare sempre la serie trasformata con l'originale e mantenere i dati grezzi separati da quelli derivati.
6. **Interpretare nell'unità corretta.** Distinguere euro da percentuali, percentuali da punti percentuali, valori nominali da reali e totali da valori pro capite.
7. **Segnalare i limiti.** Una trasformazione può facilitare confronto e modellazione, ma non crea causalità, non corregge dati di cattiva qualità e non rende irrilevanti i cambiamenti strutturali.

La trasformazione migliore non è quella che produce il grafico più regolare. È quella che conserva un significato sostantivo chiaro e rende più trasparente la risposta alla domanda empirica.

6 Indici temporali

Dire "*il costo di un paniere è pari a 108*" non significa nulla! Di cosa stiamo parlando: 108 euro, 108 punti, 108 mele o il 108% di un valore? Un **numero indice** acquista significato soltanto quando conosciamo la grandezza misurata, il periodo di riferimento e il modo in cui sono state combinate le sue componenti.

Abbiamo visto che gli indici temporali sono in grado di trasformare l'evoluzione di una o più grandezze e di rapportare i valori iniziali in una scala relativa. Si fa uso di queste tecniche per seguire prezzi, produzione, salari, commercio, mercati finanziari, servizi pubblici e, generalmente, ogni qual volta vogliamo effettuare un confronto tra due gruppi di dati differenti (es. unità di misura, posizione geografica) che hanno delle affinità (es. stesso fenomeno). Gli indici sono quindi strumenti di sintesi e comparazione e consentono di rispondere a domande come:

- di quanto sono aumentati i prezzi rispetto all'anno base?
- la produzione ha recuperato il livello precedente a una crisi?
- come si confrontano serie espresse in unità o ordini di grandezza differenti?
- quanto della crescita della spesa dipende dai prezzi e quanto dalle quantità?

Il vantaggio della scala relativa è la comparabilità. Ottenere una serie di valori comparabili ha però un costo: passare ad una scala di valori relativa fa perdere l'aspetto legato all'unità di misura originaria e fornisce dei vaori che dipendono dalle scelte di base e dal paniere utilizzato. Per interpretarlo occorre quindi conoscere come è stato costruito.

6.1 Prima degli indici: scegliere il denominatore

Molti indicatori economici e sociali sono il risultato di **rapporti statistici**. In forma generale mettono una quantità A al numeratore e una quantità B al denominatore:

$$R = \frac{A}{B}.$$

Il simbolo R indica il rapporto. Il significato del rapporto dipende principalmente dal legame che intercorre tra A e B, ovvero dalle caratteristiche degli indici che stiamo confrontando tra loro. Un indicatore ha l'obiettivo di misurare un fenomeno e di rispondere a una domanda. In questo caso, stiamo costruendo degli indici "nuovi" effettuando delle trasformazioni di altri indici che abbiamo a disposizione. Questo tipo di operazione comporta che, se cambiamo il

"meccanismo matematico" (il rapporto) o gli elementi in gioco (il denominatore), ne consegue che cambiamo anche la domanda di ricerca a cui tale indicatore risponde.

Si possono costruire dei rapporti confrontando due serie di dati distinte per A e B, oppure confrontando due grandezze della stessa serie. Nel primo caso, il rapporto può essere interpretato come una misura di coesistenza (quante unità di A esistono per ogni unità di B?) mentre nel secondo caso il rapporto può essere interpretato come una misura di derivazione (quanto vale A rispetto a B?). Di seguito è riportato uno schema che sintetizza alcuni esempi di rapporti statistici comunemente utilizzati.

Tipo di rapporto	Domanda	Esempio e interpretazione
Composizione	Quale parte del totale?	120 studenti pendolari su 300 studenti: $120/300 = 40\%$ del totale.
Coesistenza	Come si confrontano due parti?	120 pendolari e 150 residenti: $120/150 = 0{,}8$, cioè 80 pendolari ogni 100 residenti.
Densità o intensità	Quanto fenomeno per unità di esposizione?	20.000 abitanti su 50 km^2: 400 abitanti per km^2.
Derivazione	Quanto vale un fenomeno rispetto a un altro logicamente collegato?	50 disoccupati su 1.000 persone nelle forze di lavoro: tasso di disoccupazione del 5%.
Durata media	Quanto tempo per episodio o unità?	1.200 giornate di degenza per 300 ricoveri: 4 giorni per ricovero.
Incremento	Quanto è cambiato rispetto al valore iniziale?	Da 100 a 110: $(110 - 100)/100 = 10\%$.

Generalmente, quando si costruisce un rapporto di composizione, si fa in modo che esso abbia valori tra 0 e 1: 0 significa che la parte è assente, 1 significa che la parte coincide con il totale. In altri casi, i limiti del rapposto possono cambiare, ad esempio un rapporto di coesistenza o di densità ossono superare il valore 1. Alcuni rapporti sono numeri puri (es. la quota) mentre altri generano un'unità composita, come gli abitanti per km^2 o euro per residente. Non sempre le quantità composite hanno un'interpretazione immediata.

Si noti però che non si tratta di una regola matematica: non necessariamente tutti i rapporti forniscono dei valori limitati. Il significato del rapporto dipende dalla domanda, dal contesto e dalle scelte del ricercatore. Un rapporto può essere espresso in percentuale, in unità per mille o in unità per anno, ma non cambia la sua interpretazione.

> **Un rapporto non dimostra una causa**
>
> La denominazione tradizionale “rapporto di derivazione” indica solo un legame logico tra numeratore e denominatore e on preclude nessun discorso legato alla “causalità” , ovvero non implica che il numeratore sia la causa del denominatore (o viceversa). Ad esempio, il rapporto spesa pubblica/PIL descrive una relazione di scala e non spiage l’effetto causale della spesa sul PIL.

I rapporti di incremento e le variazioni percentuali sono approfonditi nel capitolo sulle trasformazioni di serie storiche. Qui li colleghiamo alla costruzione dei numeri indice.

6.2 Numeri indice semplici

Un **numero indice semplice** confronta nel tempo una sola grandezza. Indichiamo con y_t il valore osservato al tempo t e con y_b il valore nel periodo scelto come base b. L’indice a base fissa 100 è

$$I_{b,t} = \frac{y_t}{y_b} \cdot 100,$$

dove $I_{b,t}$ è il valore dell’indice al tempo t con base b. Nel periodo base $I_{b,b} = 100$.

L’interpretazione è immediata:

- $I_{b,t} = 100$: il livello è uguale a quello della base;
- $I_{b,t} > 100$: il livello è maggiore di quello della base;
- $I_{b,t} < 100$: il livello è minore di quello della base.

La variazione percentuale tra la base e il periodo t può essere calcolata come

$$\left(\frac{y_t - y_b}{y_b}\right) \cdot 100 = \left(\frac{y_t}{y_b} - 1\right) \cdot 100 = I_{b,t} - 100.$$

Supponiamo che $I_{b,t} = 113,5$, esso segnale un livello superiore del 13,5% rispetto alla base, ma attenzione perchè non va interpretato come una crescita del 113,5%.

6.3 Base mobile

L'indice a base fissa confronta tutti i periodi con lo stesso riferimento b ed è utile per valutare il cambiamento cumulato e verificare se una serie abbia superato un livello storico di riferimento (es. superamento della soglia di inquinamento del 2020, recupero della capacità di spesa rispetto al periodo pre-crisi, etc.).

Però a volte risulta utile poter fare anche dei confronti rispetto al periodi contigui, come ad esempio rapportare il preiodo attuale con quello precedente, per valutare la crescita congiunturale di un fenomeno. Per fare questo si ricorre ad un altro indice, denominato a **base mobile**. Questo indice confronta appunto ciascun valore temporale con quello immediatamente precedente.

$$M_t = \frac{y_t}{y_{t-1}} \cdot 100,$$

dove M_t è l'indice mobile tra $t-1$ e t. La corrispondente variazione percentuale è $M_t - 100$. Rispetto all'indice precedente, questo "perde" il pedice b in quanto non esiste più un periodo di riferimento fisso.

Nota 4: Un esempio a base fissa

Consideriamo una serie fittizia costruita di viaggi annuali sul trasporto pubblico, espressi in milioni.

```
anno <- 2019:2025
viaggi_milioni <- c(80, 52, 61, 74, 82, 86, 91)

indice_base_2019 <- 100 * viaggi_milioni / viaggi_milioni[anno == 2019]
indice_base_mobile <- c(
  NA,
  100 * viaggi_milioni[-1] / head(viaggi_milioni, -1)
)

tabella_indici <- data.frame(
  anno,
  viaggi_milioni,
  indice_base_2019 = round(indice_base_2019, 2),
  indice_base_mobile = round(indice_base_mobile, 2)
)

tabella_indici
```

```
  anno viaggi_milioni indice_base_2019 indice_base_mobile
1 2019             80           100.00                 NA
2 2020             52            65.00              65.00
3 2021             61            76.25             117.31
4 2022             74            92.50             121.31
5 2023             82           102.50             110.81
6 2024             86           107.50             104.88
7 2025             91           113.75             105.81
```

Nel 2020 l'indice a base 2019 è 65: i viaggi sono inferiori del 35% rispetto al 2019. Nel 2023 l'indice raggiunge 102,5, quindi il livello supera del 2,5% quello della base. Nel 2025 arriva a 113,75: 91 milioni di viaggi sono il 13,75% in più degli 80 milioni del 2019.
La scala indice facilita il confronto relativo, ma non sostituisce il livello. Sapere che una serie vale 113,75 non rivela se si tratti di 91 milioni di viaggi o di 910 mila. Quando la dimensione assoluta è rilevante, livelli e indici devono essere presentati insieme.
Osserviamo adesso l'indice a base mobile. Nel 2020 il numero di viaggi passa da 52 a 61 milioni: la variazione percentuale è pari a 117,31. Questo risultato sigifica che i viaggi aumentano quindi del 17,31% rispetto al 2020. Ciò non significa però che si sia recuperato il livello del 2019: l'indice a base fissa è ancora 76,25 ed è maggiore di 61. Infatti, può succedere che si verifichi una forte crescita (indice con base mobile alto) dopo una caduta (indice a base fissa basso), un esempio comune di tali fenomeni è dato dai titoli azionari.

Si noti che, essendo taliindici il risultato di rapporti tra due valori, essi ne ereditano i pregi e difetti. Ad esempio, può accadere che si verifichi un tasso particolarmente elevato perchè abbiamo un denominatore eccezionalmente basso. Passare da 52 a 61 milioni produce una crescita del 17,31%, ma lascia la serie sotto il livello pre-crisi. Per leggere correttamente se c'è una ripresa occorre affiancare alla valutazione degli indici anche un confronto tra i valori originali.

6.4 Scegliere e cambiare la base

Il periodo base b non è scelto a caso, spesso segue delle regole e si ancora a dei riferimenti storico/politici, per ottenere una misurazione chiara e rappresentativa di un fenomeno. Il periodo base agisce come punto di riferimento, dal quale diramiamo tutti i confronti, quindi la potenziale presenza di eventi nuovi o non documentati che alterano le serie (es. break o temporary changes) possono rendere la base poco informativa. La scelta della base non altera i dati originari, ma cambia il focus dal quale vengono letti i confronti, per tale motivo si può pensare di effettuare un **cambio del periodo di riferimento** in base a nuove esigenze per rendere i confronti più chiari ed informativi. Ad esempio, se una serie è già espressa con base $b = 100$ e vogliamo porre uguale a 100 un nuovo periodo c, il **cambio di base** è effettuato come

$$I_{c,t} = \frac{I_{b,t}}{I_{b,c}} \cdot 100,$$

dove $I_{b,c}$ è il vecchio indice osservato nel nuovo periodo base. Il rapporto elimina la vecchia base e confronta ogni periodo direttamente con c.

Supponiamo di voler cambiare la base fissa nei dati dell'esempio Esempio 4, dal 2019 a 2022, si ottiene

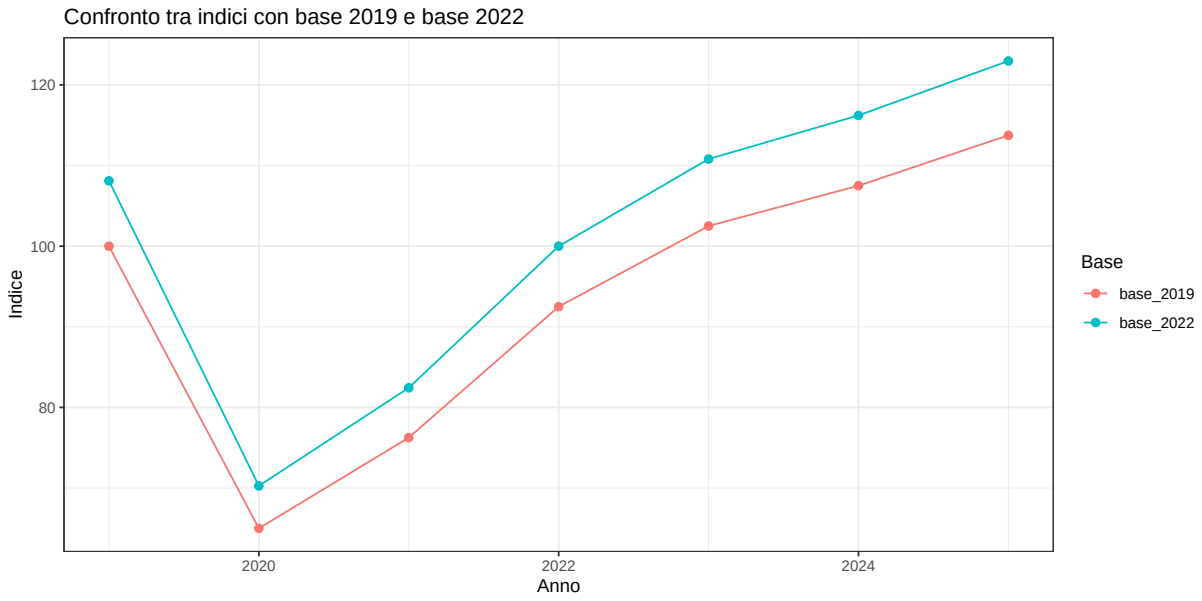
```
indice_base_2022 <-
  100 * indice_base_2019 / indice_base_2019[anno == 2022]

tabella_ribasamento <- data.frame(
  anno,
  base_2019 = round(indice_base_2019, 2),
  base_2022 = round(indice_base_2022, 2)
)

tabella_ribasamento
```

```
  anno base_2019 base_2022
1 2019    100.00    108.11
2 2020     65.00     70.27
3 2021     76.25     82.43
4 2022     92.50    100.00
5 2023    102.50    110.81
6 2024    107.50    116.22
7 2025    113.75    122.97
```

Con base 2022, il valore del 2025 è 122,97: i viaggi sono superiori del 22,97% rispetto al 2022. Con base 2019 lo stesso anno vale 113,75 (13,75%). Non c'è contraddizione, in quanto abbiamo cambiato il confronto utilizzando un nuovo denominatore e, di conseguenza, stiamo rispondendo ad una domanda di ricerca totalmente diversa.



Dato che il ribassamento moltiplica tutti gli indici per la stessa costante, di conseguenza non cambia i rapporti tra due periodi. Come ci aspettavamo otteniamo quindi gli stessi lavori, inclusi altri indici derivati come i tassi di variazione, i punti di massimo e minimo o la forma del grafico.

6.5 Concatenare gli indici

Quando pesi, panieri o classificazioni vengono aggiornati periodicamente, può essere necessario collegare segmenti costruiti con basi diverse. L'operazione è detta **concatenamento**.

Definiamo il coefficiente di collegamento tra due periodi consecutivi come

$$L_t = \frac{y_t}{y_{t-1}} = \frac{M_t}{100}.$$

Partendo da $I_{0,0} = 100$, un indice concatenato si ottiene moltiplicando progressivamente i coefficienti:

$$I^C_{0,t} = 100 \cdot \prod_{j=1}^{t} L_j = 100 \cdot \prod_{j=1}^{t} \frac{y_t}{y_{t-1}},$$

dove $I^C_{0,t}$ è l'indice concatenato. Per una singola serie omogenea e senza arrotondamenti, il prodotto si semplifica:

$$L_1 \cdot L_2 \cdots L_T \cdot 100 = \frac{y_1}{y_0}\frac{y_2}{y_1} \cdots \frac{y_t}{y_{t-1}} \cdot 100 = \frac{y_t}{y_0} \cdot 100.$$

Il concatenamento viene utilizzato principalmente quando non si hanno a disposizione i dati grezzi y_t, ma solo i risultati del calcolo degli indici base mobile.

```
coefficienti_collegamento <- c(1, indice_base_mobile[-1] / 100)
indice_concatenato <- 100 * cumprod(coefficienti_collegamento)

verifica_concatenamento <- data.frame(
  anno,
  indice_diretto = round(indice_base_2019, 2),
  indice_concatenato = round(indice_concatenato, 2)
)

verifica_concatenamento
```

```
  anno indice_diretto indice_concatenato
1 2019         100.00              100.00
2 2020          65.00               65.00
3 2021          76.25               76.25
4 2022          92.50               92.50
5 2023         102.50              102.50
6 2024         107.50              107.50
7 2025         113.75              113.75
```

Si può notare che le due colonne coincidono. Nei dati ufficiali complessi, tuttavia, concatenare consente di aggiornare i pesi e il paniere. Una serie concatenata non equivale necessariamente a un indice diretto calcolato sull'intero intervallo con un unico paniere. Anche gli arrotondamenti dei collegamenti possono produrre piccole discrepanze.

6.6 Caso reale: indici sintetici di prezzi, quantità e valori

Un indice viene detto semplice quando esso riguarda il confronto di una sola grandezza. L'inflazione o il volume della produzione richiedono invece di sintetizzare molti beni e servizi. Non possiamo effettuare la media dei prezzi in euro, euro per chilogrammo ed euro per chilowattora come se fossero tutte misure omogenee. Occorre trovare una soluzione di "compromesso", ovvero ponderare ogni variazione in base alla sua "importanza" economica.

Supponiamo che il paniere contenga n beni. Per il bene i indichiamo con:

- p_{ib} il prezzo nel periodo base b;
- p_{it} il prezzo nel periodo corrente t;
- q_{ib} la quantità nel periodo base;
- q_{it} la quantità nel periodo corrente.

L'indice dei prezzi di **Laspeyres** valuta il paniere della base ai prezzi correnti e lo confronta con il suo costo nella base:

$$P_{b,t}^{L} = 100 \cdot \frac{\sum_{i=1}^{n} p_{it} q_{ib}}{\sum_{i=1}^{n} p_{ib} q_{ib}}.$$

Le quantità q_{ib} restano fisse e funzionano da pesi. L'indice risponde alla domanda "*quanto costerebbe oggi il paniere acquistato nel periodo base?*".

L'indice dei prezzi di **Paasche** usa invece le quantità correnti:

$$P_{b,t}^{P} = 100 \cdot \frac{\sum_{i=1}^{n} p_{it} q_{it}}{\sum_{i=1}^{n} p_{ib} q_{it}}.$$

Risponde alla domanda "*quanto costa oggi il paniere corrente rispetto a quanto sarebbe costato ai prezzi della base?*". Laspeyres è più semplice da aggiornare perché non richiede continuamente nuove quantità, mentre Paasche incorpora più rapidamente i cambiamenti nei comportamenti di acquisto, ma richiede informazioni correnti.

> **Nota 5: Un paniere didattico**
>
> Consideriamo un paniere di esempio costruito con dati fittizi relativi a pane (Euro al chilo), biglietti del trasporto pubblico (costo unitario) ed energia elettrica (euro per kilowatt-ora).

```r
paniere <- data.frame(
  bene = c("Pane", "Biglietti", "Energia"),
  prezzo_base = c(2.50, 1.50, 0.25),
  quantita_base = c(40, 30, 800),
  prezzo_corrente = c(2.80, 1.60, 0.30),
  quantita_corrente = c(38, 35, 760)
)

costo_base <- with(
  paniere,
  sum(prezzo_base * quantita_base)
)
costo_paniere_base_a_prezzi_correnti <- with(
  paniere,
  sum(prezzo_corrente * quantita_base)
)
costo_paniere_corrente <- with(
  paniere,
  sum(prezzo_corrente * quantita_corrente)
)
costo_paniere_corrente_a_prezzi_base <- with(
  paniere,
  sum(prezzo_base * quantita_corrente)
)

indice_prezzi_laspeyres <-
  100 * costo_paniere_base_a_prezzi_correnti / costo_base
indice_prezzi_paasche <-
  100 * costo_paniere_corrente / costo_paniere_corrente_a_prezzi_base
indice_quantita_laspeyres <-
  100 * costo_paniere_corrente_a_prezzi_base / costo_base
indice_valore <-
  100 * costo_paniere_corrente / costo_base

data.frame(
  indice = c(
    "Prezzi di Laspeyres",
    "Prezzi di Paasche",
    "Quantità di Laspeyres",
    "Valore"
  ),
  valore = round(c(
    indice_prezzi_laspeyres,
    indice_prezzi_paasche,
    indice_quantita_laspeyres,
    indice_valore
  ), 2)
)
```

```
                  indice valore
1   Prezzi di Laspeyres 115.94
2     Prezzi di Paasche 115.67
3 Quantità di Laspeyres  97.83
4                Valore 113.16
```

L'indice di Laspeyres è 115,94: acquistare ai prezzi correnti le quantità costa il 15,94% in più rispetto al prezzo base. L'indice di Paasche è 115,67: il paniere corrente costa il 15,67% in più rispetto a quanto sarebbe costato ai prezzi della base. La differenza è piccola in questo esempio, ma mostra che la misura della variazione dei prezzi dipende dalle quantità usate come pesi.
Il fatto che Laspeyres sia qui più alto di Paasche non è una legge matematica. Può accadere quando le quantità si spostano verso beni diventati relativamente meno costosi, ma la relazione dipende dai dati. Per ottenere un'informazione che sia da "compromesso" rispetto a quelle elencate si usano altri indici in alcuni contesti, come l'indice di Fisher che è pari alla media geometrica dei due indici, ma non elimina però la necessità di conoscere le informazioni inerenti a dati, pesi e definizioni.

6.6.1 Indici delle quantità e dei valori

Per misurare la variazione delle quantità possiamo mantenere fissi i prezzi della base. L'indice delle quantità di Laspeyres è

$$Q_{b,t}^{L} = \frac{\sum_{i=1}^{n} q_{it} p_{ib}}{\sum_{i=1}^{n} q_{ib} p_{ib}} \cdot 100.$$

Riprendendo i dati dell'esempio Esempio 5 si ottiene che nel panierel'indice delle quantità è pari a 97,83. Questo risultato significa che le quantità correnti, valutate ai prezzi della base, sono inferiori del 2,17% rispetto alla base.

L'indice del valore confronta invece la spesa complessiva corrente con quella della base:

$$V_{b,t} = \frac{\sum_{i=1}^{n} p_{it} q_{it}}{\sum_{i=1}^{n} p_{ib} q_{ib}} \cdot 100.$$

Facendo sempre riferimento all'esempio Esempio 5, la spesa passa da 345 a 390,4 Euro e l'indice del valore è 113,16. La spesa aumenta quindi del 13,16%, pur in presenza di prezzi più alti e quantità aggregate leggermente più basse. Un indice di valore non separa i due effetti, questo risultato evidenzia il motivo per il quale fatturato e spesa nominale non devono essere interpretati automaticamente come misure di volume.

Example-box 6: Dall'indice dei prezzi all'inflazione

Proviamo ad applicare la teoria degli indici appena introdotta in una comune applicazione in campo reale. Un indice dei prezzi misura un livello relativo, in tal senso l'**inflazione** misura la sua variazione nel tempo. Se P_t e P_{t-1} sono i valori dello stesso indice nei due periodi, il tasso di inflazione è

$$\pi_t = \left(\frac{P_t - P_{t-1}}{P_{t-1}}\right) \cdot 100 = \left(\frac{P_t}{P_{t-1}} - 1\right) \cdot 100,$$

dove π_t indica la variazione percentuale dei prezzi tra $t-1$ e t. Un indice pari a 108 con base 100 indica prezzi superiori dell'8% rispetto alla base, non necessariamente un'inflazione dell'8% nell'ultimo anno.
Se l'indice passa da 108 a 111, l'inflazione diventa

$$\left(\frac{111}{108} - 1\right) \cdot 100 = 2{,}78\%.$$

Una diminuzione dell'inflazione non implica una diminuzione dei prezzi. Se l'inflazione passa dal 6% al 2%, i prezzi continuano ad aumentare, ma più lentamente. Una riduzione del livello generale dei prezzi è detta **deflazione**.

Si noti che le variazioni annuali vanno confrontate facendo molta attenzione! La variazione rispetto al *mese precedente* e quella rispetto allo stesso *mese dell'anno precedente* usano denominatori diversi e quindi è scorretto confrontarle senza specificare l'orizzonte.

6.7 Pesi, panieri e rappresentatività

Un indice sintetico non è una fotografia neutrale del fenomeno, in quanto dipende da una serie di decisioni metodologiche fatte dal ricercatore in base alle sue conoscenze personali, alla letteratura di riferimento e al contesto. Alcuni aspetti da tenere in considerazione che influiscono profondamente sui risultati finali sono ad esempio:

- quali beni, territori o gruppi includere
- quali prezzi o quantità osservare
- quali pesi assegnare alle componenti
- con quale frequenza aggiornare paniere e pesi
- come trattare nuovi prodotti, cambiamenti di qualità e dati mancanti
- come collegare le serie prima e dopo un aggiornamento

Un indice medio dei prezzi non coincide con la percezione del costo della vita di ogni famiglia, ma in qualche modo ne coglie alcuni aspetti essenziali (come ad esemio il costo dell'energia o degli alimenti). Due nuclei con quote di spesa diverse per affitto, energia, alimentari e trasporti

possono subire variazioni differenti. Analogamente, un indice territoriale può nascondere forti eterogeneità tra aree.

Nonostante questo ultimo effetto possa essere voluto, in quanto l'obiettivo di ricerca ad esempio può richiedere proprio il confronto tra aree, occorre sempre ricordare che un indice sintetico deve essere il più possibile "epurato" da ogni effetto secondario che possa in qualche modo fuorviare la stima finale dal misurare l'effetto desiderato. La stessa cautela vale per gli indicatori sociali compositi. Ad esempio, combinare istruzione, salute, reddito e partecipazione politica richiede normalizzazione e pesi. Queste scelte incorporano una concezione di ciò che conta e devono essere rese trasparenti. Un indice sintetico facilita la comunicazione, ma non sostituisce l'esame delle singole componenti.

Example-box 7: Ranking della qualità della vita nelle città

Quante volte leggiamo che una città è al primo posto in un ranking di qualità della vita? E come mai, al variare del tipo di ricerca, si ottengono spesso dei ranking totalmente diversi tra loro? Ci aspettiamo che, se stiamo in qualche modo misurando la qualità della vita, le città che si posizionano in alto in una classifica dovrebbero essere le stesse che si posizionano in alto in un'altra classifica.
In realtà, non è così. Un indice sintetico (composito, in questo caso) può essere costruito combinando variabili come reddito, occupazione, istruzione, salute, sicurezza, ambiente e servizi. La scelta delle variabili e dei pesi determina il risultato finale. Due classifiche diverse possono dare risultati opposti se cambiano le componenti in gioco o i pesi. Due esempi pratici: - escludere degli aspetti legati alla salute può far salire una città in classifica, mentre includerli può farla scendere; - dare più peso alla sicurezza può far salire una città con bassi tassi di criminalità, mentre dare più peso all'istruzione può farla scendere se i livelli di istruzione sono bassi; - lavorare in modo congiunto sui pesi di due variabili può far salire una città in classifica. Ad esempio se aumento il peso della componente sicurezza e diminuisco quello sull'istruzione, sto dicendo che l'istruzione darà un contributo inferiore nella scelta della posizione in classifica mentre la sicurezza rivestirà un ruolo maggiore
Per questo motivo un aspetto fondamentale della lettura di un qualsiasi indice è dato dalla capacità di saper leggere ed interpretare la documentazione metodologica e non limitarsi al solo posizionamento nella classifica.

6.8 Errori frequenti nella lettura degli indici

1. **Confondere indice e percentuale di crescita.** Un indice 125 significa +25% rispetto alla base, non +125%.
2. **Dimenticare la base.** Lo stesso valore numerico può avere significati diversi con basi diverse.

3. **Confrontare serie con basi diverse.** Per effettuare confronti, occorre prima portare le serie alla stessa base comune, verificando che definizioni e copertura siano compatibili.
4. **Sommare tassi successivi.** Le variazioni si concatenano moltiplicando i coefficienti, non sommando le percentuali.
5. **Interpretare un indice dei prezzi come costo universale.** Il risultato dipende dal paniere e dai pesi medi.
6. **Scambiare valore nominale e volume.** Un aumento della spesa o del fatturato può dipendere dai prezzi, dalle quantità o da entrambi.
7. **Ignorare rotture metodologiche.** Un cambio di classificazione, fonte o copertura non viene risolto con un semplice cambio di base.
8. **Attribuire causalità a un indicatore.** Un indice descrive un aspetto legato ad una dinamica più complessa, da solo non identifica le cause del cambiamento.

6.9 Attualizzare valori monetari rispetto all'inflazione

Un importo espresso in euro non ha lo stesso potere d'acquisto in anni diversi. Se i prezzi aumentano, 1.000 euro del 2020 permettono di acquistare più beni e servizi di 1.000 euro del 2025. Confrontare direttamente importi **nominali** può quindi attribuire a una crescita reale ciò che dipende soltanto dall'inflazione.

Per rendere confrontabili gli importi si sceglie un anno di riferimento e si usa un indice dei prezzi coerente con la grandezza analizzata. Indichiamo con:

- y_t^N il valore nominale osservato nell'anno t;
- P_t il valore dell'indice dei prezzi nell'anno t;
- P_r il valore dello stesso indice nell'anno di riferimento r;
- $y_t^{(r)}$ il valore dell'anno t espresso ai prezzi dell'anno r.

La conversione è

$$y_t^{(r)} = y_t^N \frac{P_r}{P_t}.$$

Il rapporto P_r/P_t è il **coefficiente di rivalutazione**. Se l'anno di riferimento è successivo a t e nel frattempo i prezzi sono aumentati, il coefficiente è maggiore di uno: l'importo passato viene tradotto negli euro, meno potenti, dell'anno più recente. Se invece scegliamo come riferimento un anno precedente, il coefficiente è normalmente minore di uno e otteniamo una serie a prezzi costanti di quell'anno.

Riprendiamo i dati simulati sulla spesa sociale introdotti all'inizio del capitolo. L'indice dei prezzi vale 100 nel 2019 e 126,5 nel 2025. Vogliamo esprimere tutti gli importi in milioni di euro attualizzati al 2025.

```r
anno <- 2019:2025
spesa_nominale <- c(420, 438, 470, 492, 525, 557, 585)
indice_prezzi <- c(100.0, 101.2, 103.4, 110.2, 116.7, 123.0, 126.5)
popolazione <- c(500000, 498000, 496000, 493000, 491000, 488000, 486000)

dati_spesa <- data.frame(
  anno,
  spesa_nominale,
  indice_prezzi,
  popolazione
)

dati_spesa$variazione_milioni <- c(NA, diff(dati_spesa$spesa_nominale))
dati_spesa$crescita_percentuale <- c(
  NA,
  100 * diff(dati_spesa$spesa_nominale) /
    head(dati_spesa$spesa_nominale, -1)
)

indice_riferimento_2025 <- dati_spesa$indice_prezzi[
  dati_spesa$anno == 2025
]

dati_spesa$coefficiente_attualizzazione <-
  indice_riferimento_2025 / dati_spesa$indice_prezzi

dati_spesa$spesa_a_prezzi_2025 <-
  dati_spesa$spesa_nominale *
  dati_spesa$coefficiente_attualizzazione

tabella_attualizzazione <- data.frame(
  anno = dati_spesa$anno,
  indice_prezzi = dati_spesa$indice_prezzi,
  spesa_nominale_milioni = dati_spesa$spesa_nominale,
  coefficiente = round(
    dati_spesa$coefficiente_attualizzazione,
    3
  ),
  spesa_milioni_a_prezzi_2025 = round(
    dati_spesa$spesa_a_prezzi_2025,
    1
  )
```

```
)

tabella_attualizzazione
```

```
  anno indice_prezzi spesa_nominale_milioni coefficiente
1 2019         100.0                    420        1.265
2 2020         101.2                    438        1.250
3 2021         103.4                    470        1.223
4 2022         110.2                    492        1.148
5 2023         116.7                    525        1.084
6 2024         123.0                    557        1.028
7 2025         126.5                    585        1.000
  spesa_milioni_a_prezzi_2025
1                       531.3
2                       547.5
3                       575.0
4                       564.8
5                       569.1
6                       572.8
7                       585.0
```

Per il 2019 il coefficiente è 126,5/100 = 1,265. I 420 milioni di euro spesi nel 2019 equivalgono quindi a 420 × 1,265 = 531,3 milioni di euro del 2025. Nel 2025 il coefficiente è uno, perché l'importo è già espresso nei prezzi dell'anno scelto come riferimento.

Il confronto cambia sensibilmente dopo la trasformazione. La spesa nominale cresce da 420 a 585 milioni, pari al 39,3%. A prezzi del 2025 cresce invece da 531,3 a 585 milioni, cioè di circa il 10,1%. Nel nostro esempio costruito, gran parte dell'aumento nominale riflette dunque la crescita dei prezzi, non un aumento equivalente delle risorse reali.

Lo stesso calcolo permette di tradurre un singolo importo. Con gli indici dell'esempio, 1.000 euro del 2020 corrispondono a

$$1.000 \times \frac{126{,}5}{101{,}2} = 1.250$$

euro del 2025. I due importi hanno lo stesso potere d'acquisto rispetto al paniere rappresentato dall'indice, non lo stesso valore nominale.

> **Scegliere il deflatore appropriato**
>
> Il risultato dipende dall'indice utilizzato. Un indice dei prezzi al consumo può essere adatto per studiare il potere d'acquisto delle famiglie, ma non necessariamente per una spesa sanitaria, un investimento pubblico o il PIL. L'indice deve riferirsi a un paniere e a un ambito coerenti con la variabile monetaria. La costruzione, il ribasamento e l'interpretazione degli indici sono approfonditi nel capitolo sugli indici temporali.

Questa operazione è spesso chiamata **deflazione** di una serie monetaria, anche quando l'anno di riferimento è successivo. Non va confusa con la *deflazione* intesa come diminuzione generale dei prezzi. Inoltre, non coincide con l'**attualizzazione finanziaria**, che converte un valore futuro nel suo valore presente mediante un tasso di interesse o di sconto. Qui stiamo correggendo esclusivamente per la variazione del livello dei prezzi.

La trasformazione non misura la qualità, l'efficienza o l'effetto causale della spesa. Stabilisce soltanto quanti euro dell'anno di riferimento hanno un potere d'acquisto comparabile a ciascun importo osservato.

6.10 Una procedura per lavorare con gli indici

Prima di calcolare o commentare un indice è utile seguire una sequenza essenziale:

1. definire il fenomeno e la domanda di confronto;
2. identificare numeratore, denominatore, unità di analisi e periodo;
3. scegliere una base documentata e sostantivamente interpretabile;
4. distinguere indice semplice, indice sintetico, valore, prezzo e quantità;
5. controllare paniere, pesi, copertura e aggiornamenti metodologici;
6. calcolare il confronto evitando arrotondamenti intermedi;
7. tradurre il risultato in una frase con base e orizzonte espliciti;
8. affiancare, quando utile, livelli originari, componenti e metadati.

Un buon commento non si limita a dire "l'indice è salito", bisogna specificare rispetto a quando, di quanto, per quale popolazione o paniere e quali aspetti del fenomeno rimangono fuori dalla misura.

7 Modelli di regressione

Nei comuni con una quota più elevata di laureati il tasso di disoccupazione tende a essere più basso? Quanto cambia questa associazione quando confrontiamo comuni della stessa area territoriale? Possiamo prevedere il tasso di disoccupazione di un comune non ancora osservato? Queste domande sembrano simili, ma riguardano descrizione, previsione e spiegazione causale: tre obiettivi che non devono essere confusi.

La **regressione** descrive come il valore medio di una variabile cambia al variare di una o più caratteristiche osservate. È uno degli strumenti più usati nell'analisi economica e sociale perché permette di quantificare associazioni, confrontare gruppi, formulare previsioni e rappresentare esplicitamente l'incertezza.

Un modello è però una semplificazione. Il suo risultato dipende dalla qualità dei dati, dalle variabili incluse, dalla forma funzionale e dalle ipotesi adottate. Una regressione calcolata correttamente non rende automaticamente causale l'associazione stimata.

7.1 Dallo scatterplot a un modello

Il capitolo sulla statistica descrittiva ha introdotto scatterplot e correlazione. La correlazione riassume direzione e intensità di un'associazione lineare tra due variabili, ma tratta le variabili in modo simmetrico. La regressione assegna invece ruoli diversi:

- la **variabile dipendente** o risposta, indicata con Y, è il fenomeno che vogliamo descrivere o prevedere;
- la **variabile esplicativa**, regressore o predittore, indicata con X, è la caratteristica usata per studiare come varia la risposta.

La scelta di questi ruoli deriva dalla domanda di ricerca, non dal software. Chiamare X "variabile indipendente" non garantisce che sia statisticamente indipendente da altre variabili o dal termine di errore.

Costruiamo un campione simulato di 120 comuni. Per ogni comune osserviamo l'area territoriale, la percentuale di residenti adulti laureati e il tasso di disoccupazione. I dati non rappresentano comuni reali. Usiamo un seme per rendere la simulazione riproducibile.

```r
set.seed(2030)

numero_comuni <- 120

area <- factor(
  sample(
    c("Nord", "Centro", "Sud"),
    size = numero_comuni,
    replace = TRUE,
    prob = c(0.35, 0.25, 0.40)
  ),
  levels = c("Nord", "Centro", "Sud")
)

media_laureati_area <- c(
  Nord = 28,
  Centro = 25,
  Sud = 20
)

laureati <- round(
  rnorm(
    numero_comuni,
    mean = media_laureati_area[as.character(area)],
    sd = 3.5
  ),
  1
)

disoccupazione <- round(
  16 - 0.30 * laureati +
    ifelse(area == "Centro", 1.5, ifelse(area == "Sud", 4, 0)) +
    rnorm(numero_comuni, mean = 0, sd = 1.5),
  1
)

comuni_reg <- data.frame(
  area,
  laureati,
  disoccupazione
)
```

```r
medie_per_area <- aggregate(
  cbind(laureati, disoccupazione) ~ area,
  data = comuni_reg,
  FUN = mean
)

medie_per_area$laureati <- round(medie_per_area$laureati, 2)
medie_per_area$disoccupazione <- round(
  medie_per_area$disoccupazione,
  2
)

medie_per_area
```

```
    area laureati disoccupazione
1   Nord    28.52           7.18
2 Centro    23.91          10.59
3    Sud    20.29          13.95
```

Nel campione simulato i comuni del Nord hanno in media il 28,52% di laureati e una disoccupazione del 7,18%; quelli del Sud hanno rispettivamente il 20,29% e il 13,95%. Queste differenze sono state incorporate nella simulazione e non sono stime di divari territoriali reali.

```r
colori_area_reg <- c(
  Nord = "#1B9E77",
  Centro = "#7570B3",
  Sud = "#D95F02"
)

plot(
  comuni_reg$laureati,
  comuni_reg$disoccupazione,
  pch = 19,
  col = colori_area_reg[comuni_reg$area],
  xlab = "Adulti laureati (%)",
  ylab = "Tasso di disoccupazione (%)"
)
legend(
  "topright",
  legend = names(colori_area_reg),
  col = colori_area_reg,
```

```
  pch = 19,
  bty = "n"
)
```

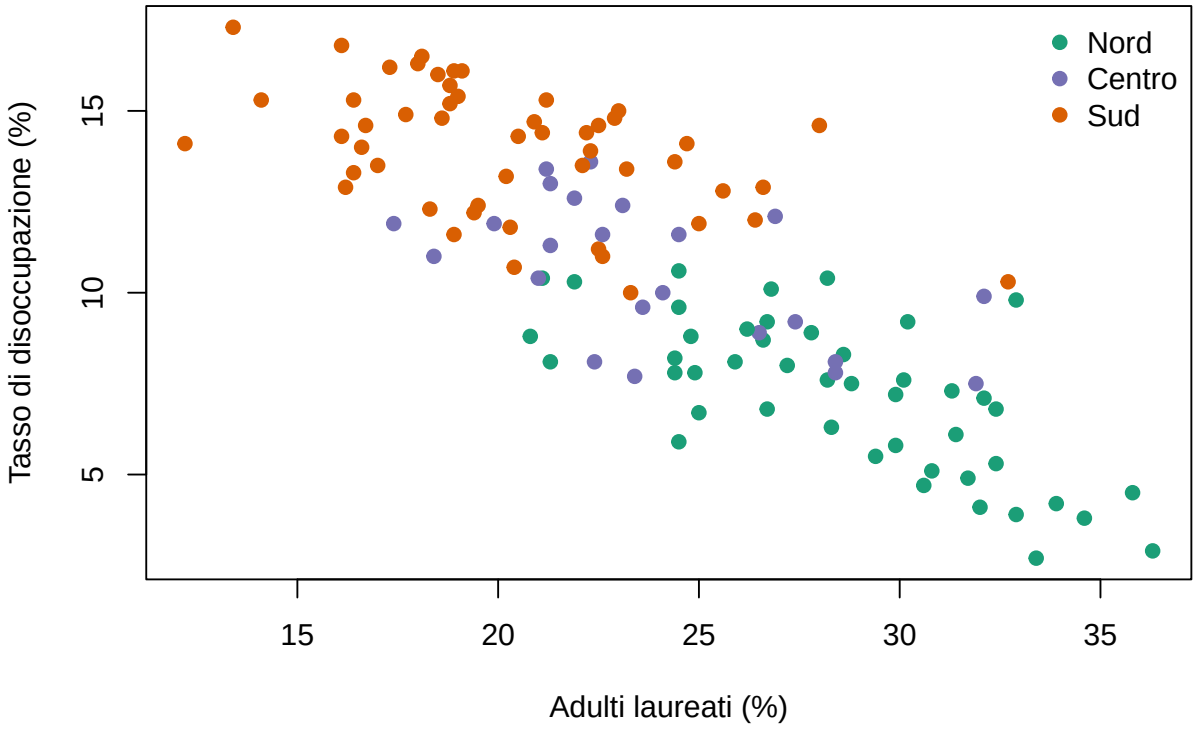


Figura 7.1: Laureati e disoccupazione nei 120 comuni simulati, distinti per area.

Lo scatterplot mostra un'associazione negativa: nei dati simulati, quote più alte di laureati tendono ad accompagnarsi a tassi di disoccupazione più bassi. I colori rivelano però anche una struttura territoriale. Una sola retta potrebbe confondere il confronto tra comuni con le differenze medie tra aree.

7.2 La regressione lineare semplice

Per l'unità i, il modello di regressione lineare semplice è

$$Y_i = \beta_0 + \beta_1 X_i + \varepsilon_i,$$

dove:

- Y_i è la variabile dipendente per l'unità i;
- X_i è il valore della variabile esplicativa;
- β_0 è l'intercetta;
- β_1 è la pendenza;
- ε_i è il termine di errore, che raccoglie la parte di Y_i non rappresentata dalla relazione lineare;
- $i = 1, \dots, n$ identifica le n unità osservate.

Se il termine di errore ha media condizionata nulla, cioè $E(\varepsilon_i \mid X_i) = 0$, allora

$$E(Y_i \mid X_i) = \beta_0 + \beta_1 X_i.$$

Il simbolo $E(Y_i \mid X_i)$ indica il valore medio di Y tra unità con lo stesso valore di X. La retta descrive quindi una **media condizionata**, non il valore esatto di ogni unità.

La pendenza β_1 indica di quanto varia in media Y quando X aumenta di un'unità. L'intercetta β_0 è il valore medio previsto di Y quando $X = 0$. Questa interpretazione può essere priva di interesse se zero è impossibile o lontano dai dati osservati.

7.2.1 Stima con i minimi quadrati

I parametri β_0 e β_1 descrivono la popolazione e sono ignoti. Nel campione li stimiamo con $\hat{\beta}_0$ e $\hat{\beta}_1$. Per ogni osservazione otteniamo un valore adattato

$$\hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_i$$

e un **residuo**

$$e_i = y_i - \hat{y}_i.$$

Il residuo è la distanza verticale tra il valore osservato e la retta stimata. Non coincide con il termine teorico ε_i: il primo è calcolabile dopo la stima, il secondo non è direttamente osservabile.

Il metodo dei **minimi quadrati ordinari** sceglie i coefficienti che rendono minima la somma dei residui al quadrato:

$$\sum_{i=1}^{n} (y_i - b_0 - b_1 x_i)^2 .$$

I simboli b_0 e b_1 rappresentano qui valori possibili tra i quali il metodo cerca il minimo. Elevare al quadrato impedisce che residui positivi e negativi si annullino e penalizza maggiormente gli scarti grandi. Proprio per questo, osservazioni estreme possono influenzare molto la retta.

```
modello_semplice <- lm(
  disoccupazione ~ laureati,
  data = comuni_reg
)

tabella_coefficienti <- function(modello) {
  coefficienti <- coef(summary(modello))

  data.frame(
    termine = rownames(coefficienti),
    stima = round(coefficienti[, "Estimate"], 3),
    errore_standard = round(coefficienti[, "Std. Error"], 3),
    p_value = format.pval(
      coefficienti[, "Pr(>|t|)"],
      digits = 3,
      eps = 0.001
    ),
    row.names = NULL
  )
}

tabella_coefficienti(modello_semplice)
```

```
      termine  stima errore_standard p_value
1 (Intercept) 23.937           0.889  <0.001
2    laureati -0.548           0.036  <0.001
```

```
data.frame(
  R2 = round(summary(modello_semplice)$r.squared, 3),
  R2_corretto = round(summary(modello_semplice)$adj.r.squared, 3)
)
```

```
     R2 R2_corretto
1 0.663        0.66
```

La retta stimata è

$$\widehat{disoccupazione} = 23{,}94 - 0{,}548\, laureati.$$

Nel campione, un punto percentuale in più nella quota di laureati è associato in media a circa 0,55 punti percentuali in meno nel tasso di disoccupazione. Il coefficiente riguarda **punti percentuali**, non una diminuzione dello 0,55%.

L'intercetta 23,94 corrisponde alla previsione quando la quota di laureati è zero. Poiché il campione non contiene comuni vicini a zero, è soprattutto un parametro necessario a posizionare la retta e non un risultato da interpretare sostantivamente.

```
plot(
  comuni_reg$laureati,
  comuni_reg$disoccupazione,
  pch = 19,
  col = "grey55",
  xlab = "Adulti laureati (%)",
  ylab = "Tasso di disoccupazione (%)"
)
abline(modello_semplice, col = "#2C7FB8", lwd = 2)
```

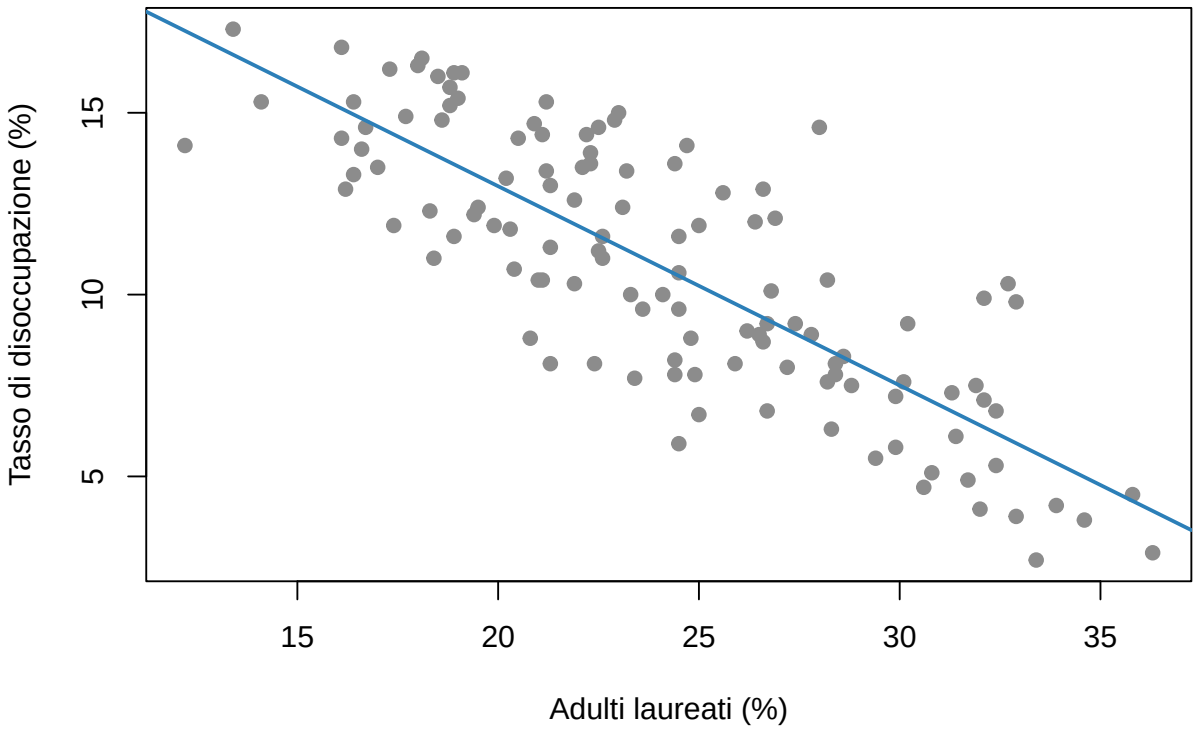


Figura 7.2: Retta di regressione semplice per i comuni simulati.

La retta riassume la tendenza complessiva, ma non mostra che una parte dell'associazione coincide con differenze territoriali. Per affrontare questo problema occorrono più regressori.

7.3 Adattamento e incertezza

Una stima puntuale non è una certezza. Un campione diverso produrrebbe coefficienti diversi. L'**errore standard** misura quanto la stima tenderebbe a variare tra campioni ripetuti sotto le ipotesi del modello. Un errore standard piccolo indica una stima relativamente precisa, non necessariamente importante sul piano sostantivo.

7.3.1 Il coefficiente di determinazione

L'indice R^2 confronta i residui della regressione con gli scarti dalla media:

$$R^2 = 1 - \frac{\sum_{i=1}^{n}(y_i - \hat{y}_i)^2}{\sum_{i=1}^{n}(y_i - \overline{y})^2},$$

dove $\overline{y}$ è la media campionaria della risposta. Con un'intercetta, R^2 è compreso tra 0 e 1 e rappresenta la quota della variabilità campionaria di Y associata ai valori adattati dal modello.

Per il modello semplice, R^2 è 0,663: circa il 66,3% della variabilità della disoccupazione nel campione simulato è rappresentato dalla relazione lineare con la quota di laureati. Non significa che l'istruzione "causi il 66,3%" della disoccupazione, né che il modello preveda correttamente altri territori o periodi.

Non esiste una soglia universale che renda un R^2 buono. Nei fenomeni sociali una parte ampia della variabilità individuale può essere intrinsecamente difficile da prevedere; un valore elevato può invece derivare da trend comuni, sovradattamento o regressioni spurie.

7.3.2 Intervalli e test

Un intervallo di confidenza al 95% fornisce un insieme di valori compatibili con i dati e le ipotesi del modello. Il *p-value* per il test $H_0 : \beta_j = 0$ misura quanto i dati sarebbero incompatibili con un coefficiente nullo, se l'ipotesi nulla e le altre assunzioni fossero valide.

Un piccolo *p-value* non misura la grandezza dell'associazione, non indica la probabilità che l'ipotesi nulla sia vera e non dimostra causalità. Per interpretare un risultato occorre riportare almeno stima, unità di misura, intervallo di confidenza e rilevanza sostantiva.

7.4 Regressione lineare multipla

I fenomeni economici dipendono raramente da una sola caratteristica. Con p regressori, il modello lineare multiplo è

$$Y_i = \beta_0 + \beta_1 X_{i1} + \beta_2 X_{i2} + \cdots + \beta_p X_{ip} + \varepsilon_i,$$

dove X_{ij} è il valore del regressore j per l'unità i e β_j è il relativo coefficiente. Ogni β_j descrive la variazione media di Y associata a un aumento unitario di X_j, **a parità degli altri regressori inclusi nel modello**.

Questa espressione significa che confrontiamo unità simili rispetto alle altre variabili osservate. Non significa che tutte le altre caratteristiche, comprese quelle non misurate, siano realmente costanti.

7.4.1 Variabili qualitative e categoria di riferimento

L'area territoriale è qualitativa. R la rappresenta mediante variabili indicatrici, dette anche **dummy**, che valgono 1 quando l'unità appartiene a una categoria e 0 altrimenti. Con tre aree e un'intercetta servono due dummy; la categoria esclusa diventa il riferimento.

Poiché abbiamo ordinato i livelli come Nord, Centro e Sud, il Nord è la categoria di riferimento. Il modello è

$$Y_i = \beta_0 + \beta_1 X_i + \beta_2 D_{Centro,i} + \beta_3 D_{Sud,i} + \varepsilon_i,$$

dove $D_{Centro,i}$ vale 1 per i comuni del Centro e $D_{Sud,i}$ vale 1 per quelli del Sud. I coefficienti β_2 e β_3 confrontano ciascuna area con il Nord a parità di X.

```
modello_multiplo <- lm(
  disoccupazione ~ laureati + area,
  data = comuni_reg
)

tabella_coefficienti(modello_multiplo)
```

```
      termine  stima errore_standard p_value
1 (Intercept) 15.663           1.084  <0.001
2    laureati -0.297           0.037  <0.001
3  areaCentro  2.038           0.436  <0.001
4     areaSud  4.320           0.442  <0.001
```

```r
data.frame(
  R2 = round(summary(modello_multiplo)$r.squared, 3),
  R2_corretto = round(summary(modello_multiplo)$adj.r.squared, 3)
)
```

```
     R2 R2_corretto
1 0.816       0.811
```

Nel modello multiplo, il coefficiente dei laureati è -0,297. Tra comuni della stessa area, un punto percentuale in più di laureati è associato in media a circa 0,30 punti percentuali in meno di disoccupazione. La stima è meno negativa di quella semplice, pari a -0,548: una parte dell'associazione iniziale rifletteva la diversa composizione territoriale.

A parità della quota di laureati, il Centro presenta in media 2,04 punti percentuali di disoccupazione in più rispetto al Nord e il Sud 4,32 punti in più. Questi coefficienti descrivono i dati simulati. L'area può riassumere molte caratteristiche non osservate e non deve essere interpretata come una causa autonoma.

L'R^2 del modello multiplo è 0,816 e quello corretto è 0,811. L'R^2 **corretto** penalizza, in parte, l'aggiunta di regressori che migliorano poco l'adattamento. Anche questo indicatore non garantisce validità fuori campione o corretta specificazione.

```r
round(confint(modello_multiplo, level = 0.95), 3)
```

```
              2.5 % 97.5 %
(Intercept) 13.516 17.811
laureati    -0.371 -0.224
areaCentro   1.174  2.902
areaSud      3.444  5.196
```

L'intervallo al 95% per il coefficiente dei laureati va circa da -0,371 a -0,224 punti percentuali. Sotto le ipotesi del modello, i dati sono quindi compatibili con un'associazione negativa di questa ampiezza. L'intervallo non trasforma l'associazione in un effetto causale.

> **La trappola delle dummy**
>
> Con un'intercetta e K categorie si includono $K - 1$ dummy. Inserirle tutte crea collinearità perfetta: per ogni osservazione la loro somma è sempre 1, esattamente come la colonna dell'intercetta. Occorre omettere una categoria di riferimento oppure rimuovere consapevolmente l'intercetta e cambiare l'interpretazione del modello.

7.4.2 Quando le pendenze differiscono tra gruppi

Il modello appena stimato consente intercette diverse ma impone la stessa pendenza in tutte le aree. Se la relazione tra istruzione e disoccupazione può cambiare territorialmente, si introduce un'**interazione** tra variabile quantitativa e area. Per due gruppi, una forma semplice è

$$Y_i = \beta_0 + \beta_1 X_i + \beta_2 D_i + \beta_3 X_i D_i + \varepsilon_i.$$

Il coefficiente β_3 misura la differenza tra le pendenze dei due gruppi. Un'interazione va motivata dalla domanda e interpretata insieme ai termini principali; non è un espediente per cercare significatività.

7.5 Prevedere con la regressione

Per valori specifici dei regressori, il modello produce una previsione puntuale. Consideriamo un comune del Sud con il 25% di laureati.

```
nuovo_comune <- data.frame(
  laureati = 25,
  area = factor("Sud", levels = levels(comuni_reg$area))
)

intervallo_media <- predict(
  modello_multiplo,
  newdata = nuovo_comune,
  interval = "confidence",
  level = 0.95
)

intervallo_individuale <- predict(
  modello_multiplo,
  newdata = nuovo_comune,
  interval = "prediction",
  level = 0.95
)

round(intervallo_media, 2)
```

```
    fit   lwr   upr
1 12.55 11.99 13.11
```

```r
round(intervallo_individuale, 2)
```

```
    fit  lwr   upr
1 12.55 9.39 15.71
```

La previsione puntuale è un tasso di disoccupazione del 12,55%. L'intervallo al 95% per la **media** dei comuni con quelle caratteristiche va da 11,99% a 13,11%. L'intervallo di previsione per un **singolo comune** è più ampio, da 9,39% a 15,71%, perché include sia l'incertezza sulla retta sia l'eterogeneità tra comuni.

Una previsione è particolarmente fragile quando richiede **estrapolazione**, cioè valori dei regressori lontani dall'intervallo osservato. La retta può essere adeguata nel campione ma irrealistica fuori da esso. Per valutare la capacità predittiva occorre inoltre usare dati non impiegati nella stima o una procedura di validazione appropriata.

7.6 Trasformazioni e interpretazione dei coefficienti

Le trasformazioni introdotte nel capitolo precedente possono rappresentare relazioni proporzionali o stabilizzare la variabilità. Con variabili positive, le interpretazioni più comuni sono:

Modello	Interpretazione approssimata di β_1
$Y = \beta_0 + \beta_1 X + \varepsilon$	una unità in più di X è associata a β_1 unità in più di Y
$\log(Y) = \beta_0 + \beta_1 X + \varepsilon$	una unità in più di X è associata a circa $100\beta_1\%$ di variazione in Y
$Y = \beta_0 + \beta_1 \log(X) + \varepsilon$	un aumento dell'1% di X è associato a circa $\beta_1/100$ unità di variazione in Y
$\log(Y) = \beta_0 + \beta_1 \log(X) + \varepsilon$	un aumento dell'1% di X è associato a circa $\beta_1\%$ di variazione in Y

Nel modello log-log, β_1 è un'**elasticità**. Le approssimazioni sono più accurate per variazioni piccole; per un modello log-livello la variazione percentuale esatta associata a un aumento unitario di X è $100[\exp(\beta_1) - 1]$. Il logaritmo richiede valori strettamente positivi e non va applicato automaticamente.

7.7 Ipotesi e diagnostica essenziale

Le ipotesi non sono formalità necessarie soltanto per "far funzionare R". Collegano il modello alla domanda e determinano quali conclusioni siano affidabili.

1. **Forma della media condizionata.** La parte sistematica deve rappresentare adeguatamente la relazione. Curve o interazioni ignorate producono residui strutturati.
2. **Media condizionata nulla dell'errore.** L'ipotesi $E(\varepsilon_i \mid X_i) = 0$ esclude legami sistematici tra regressori e fattori omessi. È cruciale per interpretare correttamente i coefficienti.
3. **Assenza di collinearità perfetta.** Nessun regressore deve essere una combinazione esatta degli altri. Una collinearità forte, anche non perfetta, rende difficile separare i coefficienti e aumenta gli errori standard.
4. **Varianza costante.** L'omoschedasticità richiede $Var(\varepsilon_i \mid X_i) = \sigma^2$. Se la dispersione cambia, i coefficienti OLS possono rimanere utili sotto altre ipotesi, ma gli errori standard usuali possono essere inaffidabili.
5. **Indipendenza o struttura della dipendenza correttamente trattata.** Comuni vicini, individui della stessa famiglia e osservazioni successive nel tempo possono avere errori correlati.
6. **Normalità degli errori.** Non è necessaria per calcolare la retta OLS. È utile per test e intervalli esatti nei piccoli campioni; con campioni grandi entrano in gioco approssimazioni, purché le altre condizioni siano plausibili.

I residui permettono di cercare violazioni visibili, ma non possono dimostrare che tutte le ipotesi siano vere.

```
residui_multiplo <- residuals(modello_multiplo)
valori_adattati <- fitted(modello_multiplo)

par(mfrow = c(1, 2), mar = c(4, 4, 2, 1))

plot(
  valori_adattati,
  residui_multiplo,
  pch = 19,
  col = "grey45",
  xlab = "Valori adattati",
  ylab = "Residui",
  main = "Residui e adattati"
)
abline(h = 0, lty = 2, col = "#2C7FB8")
lines(
  lowess(valori_adattati, residui_multiplo),
```

```
  col = "#D95F02",
  lwd = 2
)

qqnorm(
  residui_multiplo,
  pch = 19,
  col = "grey45",
  main = "Quantili normali"
)
qqline(residui_multiplo, col = "#2C7FB8", lwd = 2)
```

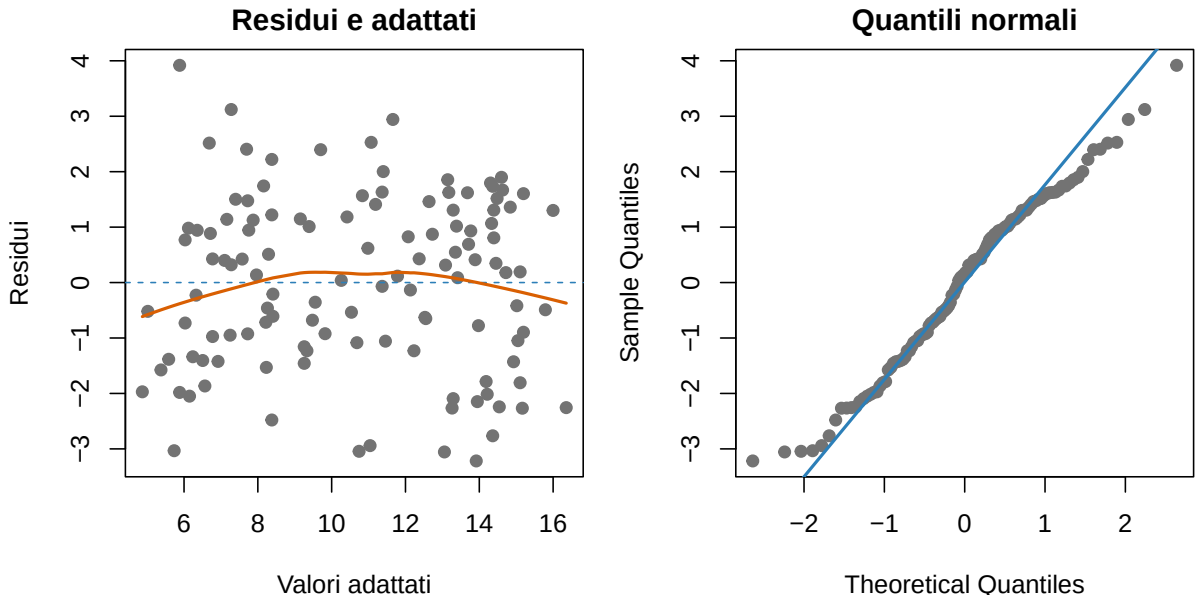


Figura 7.3: Diagnostica essenziale del modello multiplo: residui rispetto ai valori adattati e grafico quantile-quantile.

```
par(mfrow = c(1, 1))
```

Nel grafico residui-adattati i punti oscillano attorno a zero senza una curva o un ventaglio evidenti. Nel grafico quantile-quantile sono abbastanza vicini alla retta, con scostamenti moderati alle estremità. Per questi dati simulati non emergono problemi forti, ma la diagnostica non sostituisce la conoscenza del processo che ha generato i dati.

Occorre controllare anche osservazioni influenti. Un punto con valori insoliti dei regressori ha elevata **leva**; se modifica sensibilmente le stime quando viene incluso, è influente. Un residuo

piccolo non esclude alta influenza. Prima di rimuovere un'osservazione bisogna verificare se sia un errore o un caso reale rilevante.

> ⚠ Correggere l'inferenza non corregge il modello
>
> Errori standard robusti o raggruppati possono rendere l'inferenza più adeguata in presenza di eteroschedasticità o dipendenza entro gruppi. Non correggono però una relazione non lineare, una variabile omessa, un errore di misura o una strategia causale inadeguata.

7.8 Selezione delle variabili e sovradattamento

Aggiungere regressori riduce sempre, o lascia invariata, la somma dei residui al quadrato nel campione. Questo non significa che ogni modello più grande sia migliore. Troppe variabili possono produrre **sovradattamento**: il modello impara oscillazioni specifiche del campione e prevede male nuovi dati.

La scelta dei regressori dovrebbe partire da domanda, teoria, disegno della raccolta e conoscenza istituzionale. Eliminare automaticamente tutte le variabili con *p-value* elevato e ripetere la procedura rende i *p-value* finali difficili da interpretare e può escludere importanti variabili di controllo. Inoltre, due regressori correlati possono avere singoli *p-value* elevati pur contenendo informazione congiunta.

Per un obiettivo descrittivo o causale conta la corretta specificazione sostantiva. Per la previsione contano soprattutto prestazioni fuori campione, confrontate con modelli di riferimento. R^2 corretto, criteri informativi e validazione possono aiutare, ma nessun indicatore sostituisce il ragionamento sulla domanda.

7.9 Associazione, previsione e causalità

È utile distinguere esplicitamente tre usi della regressione:

- **associazione:** quantificare come Y varia con X nel campione o nella popolazione di interesse;
- **previsione:** ottenere valori accurati di Y per nuove osservazioni;
- **causalità:** stimare come cambierebbe Y se intervenissimo su X, mantenendo appropriato il confronto controfattuale.

Un buon modello predittivo può usare variabili che non causano l'esito. Un modello con coefficienti facilmente interpretabili può prevedere poco. Una regressione osservazionale con molti controlli non identifica automaticamente un effetto causale.

Le minacce principali all'interpretazione causale comprendono variabili omesse, causalità inversa, selezione nel campione ed errori di misura. Per sostenere una conclusione causale serve un disegno credibile, come randomizzazione o una strategia quasi-sperimentale con ipotesi difendibili. La regressione è lo strumento di stima, non il disegno di identificazione.

7.10 Quando il modello lineare richiede un'estensione

La natura dei dati può richiedere strumenti differenti.

- Se la risposta è binaria, come partecipazione o astensione, una regressione logistica può modellare probabilità comprese tra 0 e 1. Il modello Logit richiede una trattazione specifica e non viene sviluppato qui.
- Se le osservazioni sono temporali, trend comuni possono produrre regressioni spurie e i residui possono essere autocorrelati. Occorre esaminare stazionarietà, trasformazioni e struttura temporale, come discusso nel capitolo sulle serie storiche (Hyndman e Athanasopoulos 2014).
- Se le unità sono territoriali, gli errori possono essere spazialmente dipendenti. I metodi appropriati saranno introdotti nel capitolo sui dati spaziali.
- Se la variabilità cambia nel tempo, possono servire modelli specifici. I modelli GARCH, citati nella scaletta originaria, sono avanzati e non necessari per l'obiettivo introduttivo di questo capitolo.

Cambiare metodo non significa "rimuovere" un'ipotesi senza conseguenze. Ogni estensione sostituisce alcune ipotesi con altre e richiede una nuova interpretazione.

7.11 Una procedura per l'analisi di regressione

1. **Formulare la domanda.** Stabilire se l'obiettivo è descrittivo, predittivo o causale.
2. **Definire unità e variabili.** Documentare risposta, regressori, popolazione, periodo, unità di misura e valori mancanti.
3. **Esplorare i dati.** Usare grafici, distribuzioni e correlazioni per riconoscere forma, gruppi e valori influenti.
4. **Specificare un modello motivato.** Scegliere regressori, trasformazioni, dummy e interazioni sulla base della domanda.
5. **Stimare e interpretare.** Tradurre coefficienti e intervalli nelle unità sostantive corrette.
6. **Esaminare i residui.** Cercare non linearità, varianza non costante, dipendenza e osservazioni influenti.
7. **Valutare l'obiettivo.** Per la previsione usare dati non impiegati nella stima; per la causalità discutere il disegno di identificazione.
8. **Comunicare limiti e incertezza.** Evitare conclusioni più forti di quelle consentite dai dati e dalle ipotesi.

Una regressione utile non è quella con il maggior numero di asterischi. È quella che collega in modo trasparente una domanda, una struttura dei dati, un insieme di ipotesi e un'interpretazione sostantiva verificabile.

8 Analisi multivariata

Un territorio non può essere descritto adeguatamente da un solo numero. Reddito, occupazione, istruzione, povertà, accesso ai servizi e struttura demografica misurano aspetti diversi, ma spesso collegati. Osservare una variabile alla volta può far perdere la struttura complessiva; sommarle senza criterio può invece produrre un indicatore privo di significato.

L'**analisi multivariata** studia simultaneamente più variabili osservate sulle stesse unità. In questo capitolo ci concentreremo sull'**analisi in componenti principali** (ACP, o PCA dall'inglese *principal component analysis*), uno strumento descrittivo per sintetizzare variabili quantitative correlate. Introdurremo inoltre l'analisi delle corrispondenze multiple per variabili qualitative.

Questi metodi aiutano a:

- riconoscere gruppi di indicatori che si muovono insieme;
- ridurre molte variabili a poche dimensioni sintetiche;
- rappresentare unità e variabili in grafici più leggibili;
- costruire indicatori sintetici trasparenti, discutendone i limiti.

L'ACP non distingue una variabile dipendente da variabili esplicative. Diversamente dalla regressione, non cerca di prevedere un esito specifico e non identifica relazioni causali. Cerca una rappresentazione compatta della variabilità presente nei dati.

8.1 Dalle variabili alla struttura multivariata

Supponiamo di osservare n territori e p indicatori quantitativi. I dati possono essere organizzati in una tabella con n righe e p colonne. Indichiamo con x_{ij} il valore dell'indicatore j nel territorio i.

Prima di sintetizzare occorre chiarire:

- che cosa rappresenta ogni riga e ogni colonna;
- unità di misura, periodo e fonte degli indicatori;
- direzione sostantiva di ciascuna variabile;
- presenza di valori mancanti, errori o osservazioni influenti;
- popolazione alla quale si vogliono estendere le conclusioni.

L'ACP richiede variabili quantitative. Inserire codici numerici arbitrari per categorie, come Nord = 1, Centro = 2 e Sud = 3, imporrebbe distanze che non hanno significato.

8.1.1 Un esempio territoriale simulato

Costruiamo dati per 40 territori fittizi. Gli indicatori sono reddito medio in migliaia di euro, tasso di occupazione, quota di laureati, copertura della banda larga, disoccupazione, povertà e quota di residenti anziani. I valori sono simulati, non provengono da fonti ufficiali e non descrivono territori reali.

```
set.seed(2040)

numero_territori <- 40
territorio <- sprintf("T%02d", seq_len(numero_territori))

sviluppo_latente <- rnorm(numero_territori)
invecchiamento_latente <-
  0.2 * sviluppo_latente +
  sqrt(1 - 0.2^2) * rnorm(numero_territori)

indicatori_territoriali <- data.frame(
  reddito = 24 + 3.5 * sviluppo_latente +
    rnorm(numero_territori, 0, 0.8),
  occupazione = 61 + 4.5 * sviluppo_latente -
    invecchiamento_latente + rnorm(numero_territori, 0, 1.5),
  laureati = 23 + 4 * sviluppo_latente -
    0.5 * invecchiamento_latente + rnorm(numero_territori, 0, 1.8),
  banda_larga = 78 + 7 * sviluppo_latente -
    0.5 * invecchiamento_latente + rnorm(numero_territori, 0, 3),
  disoccupazione = 11 - 3.2 * sviluppo_latente +
    invecchiamento_latente + rnorm(numero_territori, 0, 1),
  poverta = 15 - 3.5 * sviluppo_latente +
    0.7 * invecchiamento_latente + rnorm(numero_territori, 0, 1.2),
  anziani = 23 + 3 * invecchiamento_latente +
    rnorm(numero_territori, 0, 0.8)
)

dati_territori <- data.frame(
  territorio,
  indicatori_territoriali
)
```

```r
anteprima_territori <- head(dati_territori)
anteprima_territori[-1] <- round(anteprima_territori[-1], 1)

anteprima_territori
```

```
  territorio reddito occupazione laureati banda_larga disoccupazione poverta
1        T01    20.6        58.3     18.2        71.7           14.1    18.0
2        T02    26.4        63.5     26.8        79.5           11.8    13.4
3        T03    27.6        66.1     26.8        85.6            7.8    12.3
4        T04    23.7        55.1     22.0        75.9           13.7    17.6
5        T05    26.5        62.1     24.0        77.6           10.1    15.3
6        T06    25.1        61.8     22.5        78.0           12.0    16.0
  anziani
1    19.0
2    24.1
3    20.5
4    29.2
5    22.3
6    23.2
```

Il codice usa due dimensioni non osservate per generare correlazioni: una legata allo sviluppo e una alla struttura demografica. Questa costruzione rende l'esempio interpretabile, ma l'ACP non conosce tali dimensioni e utilizza soltanto i sette indicatori osservati.

8.2 Correlazioni e ridondanza informativa

L'ACP è utile quando più indicatori contengono informazione in parte sovrapposta. Nel capitolo descrittivo abbiamo definito la correlazione come misura dell'associazione lineare tra due variabili. La matrice di correlazione raccoglie tutti i confronti a coppie.

```r
matrice_correlazioni <- cor(indicatori_territoriali)
round(matrice_correlazioni, 2)
```

```
              reddito occupazione laureati banda_larga disoccupazione poverta
reddito          1.00        0.91     0.90        0.92          -0.88   -
0.92
occupazione      0.91        1.00     0.88        0.91          -0.93   -
0.93
laureati         0.90        0.88     1.00        0.88          -0.84   -
0.87
```

```
banda_larga       0.92        0.91     0.88        1.00          -0.90   -
0.91
disoccupazione   -0.88       -0.93    -0.84       -0.90           1.00    0.93
poverta          -0.92       -0.93    -0.87       -0.91           0.93    1.00
anziani           0.26       -0.03     0.18        0.13           0.11    0.00
                anziani
reddito           0.26
occupazione      -0.03
laureati          0.18
banda_larga       0.13
disoccupazione    0.11
poverta           0.00
anziani           1.00
```

Reddito, occupazione, laureati e banda larga hanno correlazioni positive elevate. Disoccupazione e povertà sono associate negativamente ai primi quattro indicatori e positivamente tra loro. La quota di anziani presenta invece legami più deboli con questo gruppo. Ci aspettiamo quindi una dimensione dominante legata alle condizioni socioeconomiche e una seconda dimensione più demografica.

> ⚠ La correlazione non rende intercambiabili gli indicatori
>
> Due variabili fortemente correlate possono avere significati politici differenti. Reddito e occupazione non diventano lo stesso fenomeno solo perché si muovono insieme. La riduzione dimensionale sintetizza l'informazione statistica, non elimina la necessità di interpretare le singole misure.

8.3 Perché standardizzare

Gli indicatori hanno unità e dispersioni diverse. Senza correzioni, una variabile misurata su una scala numericamente ampia può dominare l'ACP anche se non è sostantivamente più importante.

Per ogni indicatore j standardizziamo il valore del territorio i:

$$z_{ij} = \frac{x_{ij} - \bar{x}_j}{s_j},$$

dove $\bar{x}_j$ è la media campionaria e s_j la deviazione standard dell'indicatore j. Ogni variabile standardizzata ha media zero e deviazione standard uno. L'operazione è stata introdotta nel capitolo sulla statistica descrittiva.

Applicare l'ACP alle variabili standardizzate equivale a lavorare sulla matrice di correlazione. Se tutte le variabili sono espresse nella stessa unità e le differenze di varianza hanno un significato sostantivo, si può usare la matrice di covarianza. La scelta deve essere dichiarata.

> ⚠ Standardizzare non risolve ogni problema
>
> La standardizzazione non corregge valori errati, asimmetrie estreme o indicatori concettualmente inappropriati. Inoltre, assegna inizialmente a ogni variabile la stessa varianza: questa è già una scelta di ponderazione, non un'operazione neutrale.

8.4 L'intuizione dell'ACP

Immaginiamo una nuvola di punti descritta da molte coordinate. L'ACP cerca la direzione lungo la quale i punti sono più dispersi. Questa è la prima componente principale. Cerca poi una seconda direzione, perpendicolare alla prima, che conservi quanta più variabilità possibile tra quella rimasta. La procedura continua fino a ottenere al massimo p componenti.

La componente k per il territorio i è una combinazione lineare delle variabili standardizzate:

$$C_{ik} = a_{1k}z_{i1} + a_{2k}z_{i2} + \cdots + a_{pk}z_{ip},$$

dove:

- C_{ik} è il punteggio, o **score**, del territorio i sulla componente k;
- z_{ij} è il valore standardizzato dell'indicatore j;
- a_{jk} è il peso, spesso chiamato **loading**, dell'indicatore j sulla componente k;
- p è il numero di indicatori.

I pesi sono scelti in modo che la prima componente abbia la massima varianza possibile, con la condizione $\sum_{j=1}^{p} a_{jk}^2 = 1$. Le componenti successive massimizzano la varianza residua e sono tra loro non correlate. L'ACP non sceglie i pesi per massimizzare una relazione causale o la previsione di un esito.

8.5 Calcolare l'ACP con R

La funzione `prcomp()` è inclusa in R. Impostiamo `center = TRUE` e `scale. = TRUE` per centrare e standardizzare gli indicatori. La funzione usa una decomposizione numericamente stabile e restituisce, tra gli altri elementi, deviazioni standard delle componenti, pesi e scores.

```r
acp_territori <- prcomp(
  indicatori_territoriali,
  center = TRUE,
  scale. = TRUE
)

# Orientiamo i segni per facilitare la lettura sostantiva.
if (acp_territori$rotation["reddito", 1] < 0) {
  acp_territori$rotation[, 1] <- -acp_territori$rotation[, 1]
  acp_territori$x[, 1] <- -acp_territori$x[, 1]
}
if (acp_territori$rotation["anziani", 2] < 0) {
  acp_territori$rotation[, 2] <- -acp_territori$rotation[, 2]
  acp_territori$x[, 2] <- -acp_territori$x[, 2]
}
```

Il cambio di segno non modifica distanze, varianze o qualità della soluzione. In un'ACP il segno di ogni componente è arbitrario: moltiplicare contemporaneamente pesi e scores per -1 descrive lo stesso asse. Qui scegliamo che la prima componente aumenti con il reddito e la seconda con la quota di anziani, così le frasi interpretative rimangono stabili.

8.6 Quanta informazione conserva ogni componente

Indichiamo con λ_k la varianza della componente k. La quota di varianza spiegata è

$$v_k = \frac{\lambda_k}{\sum_{j=1}^{p} \lambda_j},$$

dove v_k è compreso tra 0 e 1. Moltiplicandolo per 100 otteniamo la percentuale di varianza spiegata. Con dati standardizzati, la varianza totale è pari al numero p di variabili.

In `prcomp()`, l'elemento `sdev` contiene le deviazioni standard delle componenti; elevandole al quadrato otteniamo le varianze λ_k.

```r
varianza_componenti <- acp_territori$sdev^2
quota_varianza <- varianza_componenti / sum(varianza_componenti)

tabella_varianza <- data.frame(
  componente = paste0("CP", seq_along(quota_varianza)),
  varianza_percentuale = round(100 * quota_varianza, 1),
  cumulata_percentuale = round(100 * cumsum(quota_varianza), 1)
```

```
)

tabella_varianza
```

```
  componente varianza_percentuale cumulata_percentuale
1        CP1                78.8                 78.8
2        CP2                15.7                 94.4
3        CP3                 1.9                 96.4
4        CP4                 1.3                 97.6
5        CP5                 1.0                 98.6
6        CP6                 0.8                 99.4
7        CP7                 0.6                100.0
```

La prima componente spiega il 78,8% della variabilità complessiva e la seconda il 15,7%. Insieme conservano il 94,4% della varianza dei sette indicatori standardizzati. Le componenti successive aggiungono ciascuna una quota molto piccola in questi dati simulati.

```
par(mfrow = c(1, 2), mar = c(4, 4, 2, 1))

barplot(
  100 * quota_varianza,
  names.arg = seq_along(quota_varianza),
  col = "#2C7FB8",
  xlab = "Componente",
  ylab = "Varianza spiegata (%)",
  main = "Contributo di ogni componente"
)

plot(
  seq_along(quota_varianza),
  100 * cumsum(quota_varianza),
  type = "b",
  pch = 19,
  col = "#D95F02",
  ylim = c(0, 100),
  xlab = "Numero di componenti",
  ylab = "Varianza cumulata (%)",
  main = "Informazione cumulata"
)
abline(h = 90, lty = 2, col = "grey50")
```

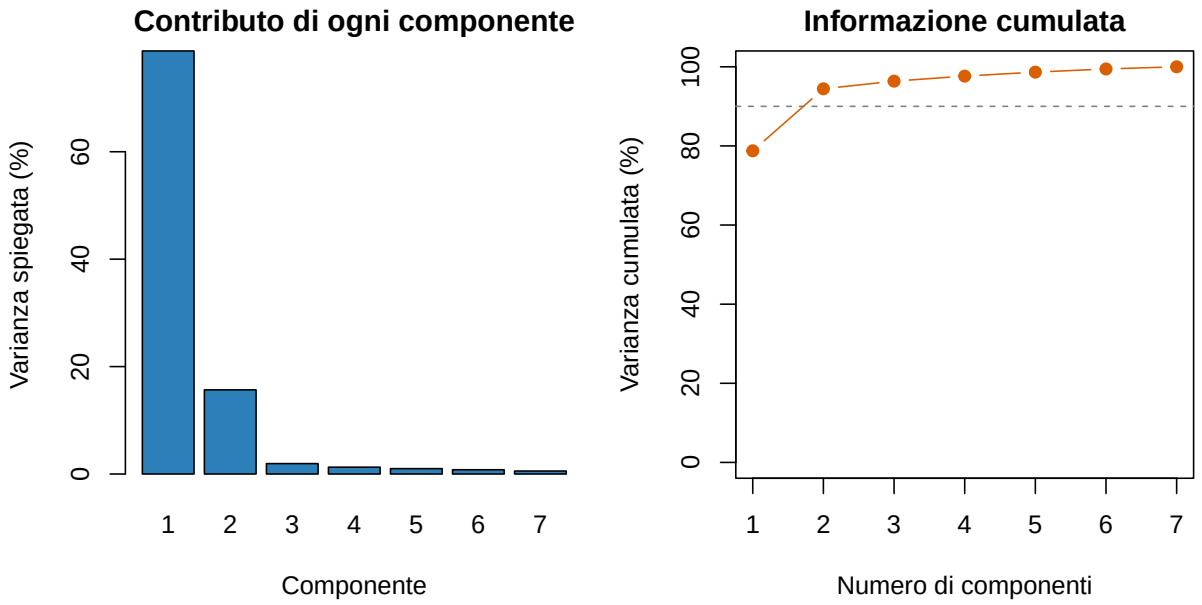


Figura 8.1: Varianza spiegata e varianza cumulata dalle componenti principali.

```
par(mfrow = c(1, 1))
```

Il grafico di sinistra è chiamato spesso **scree plot**. Il gomito dopo la seconda componente suggerisce che due dimensioni offrano una sintesi efficace. La soglia del 90% nel grafico cumulato è soltanto un riferimento visivo: il numero di componenti va scelto considerando obiettivo, interpretabilità e stabilità, non applicando meccanicamente una percentuale.

8.7 Leggere i loadings

I loadings indicano come gli indicatori contribuiscono alla direzione di ciascuna componente. Valori grandi in valore assoluto segnalano un contributo importante; segni uguali indicano che le variabili entrano nella stessa direzione, segni opposti che entrano in direzioni opposte.

```
loadings_principali <- round(
  acp_territori$rotation[, 1:2],
  3
)

loadings_principali
```

```
                PC1    PC2
```

```
reddito          0.411  0.166
occupazione      0.411 -0.116
laureati         0.399  0.111
banda_larga      0.409  0.038
disoccupazione -0.406  0.196
poverta        -0.411  0.091
anziani          0.039  0.948
```

Nella prima componente, reddito, occupazione, laureati e banda larga hanno pesi positivi vicini a 0,4; disoccupazione e povertà hanno pesi negativi di ampiezza simile. La componente contrappone quindi condizioni economiche favorevoli e disagio socioeconomico. La quota di anziani pesa poco sulla prima componente.

La seconda componente è dominata dalla quota di anziani, con loading 0,948. Può essere letta come una dimensione demografica distinta. Le altre variabili vi contribuiscono molto meno.

Il nome di una componente non è prodotto dall'algoritmo. È un'interpretazione proposta dall'analista sulla base dei loadings e del significato degli indicatori. Chiamare la prima componente "sviluppo" non dimostra l'esistenza di un unico concetto oggettivo di sviluppo.

> **i** Pesi, loadings e correlazioni
>
> In `prcomp()`, la matrice `rotation` contiene i coefficienti usati per costruire le componenti. Questi vengono spesso chiamati loadings. Non coincidono necessariamente con le correlazioni tra variabili e componenti; per variabili standardizzate, tali correlazioni dipendono anche dalla deviazione standard della componente.

8.8 Leggere gli scores

Gli scores collocano ogni territorio lungo gli assi sintetici. Uno score positivo sulla prima componente indica valori relativamente alti per gli indicatori con loading positivo e relativamente bassi per quelli con loading negativo. Lo zero rappresenta una posizione vicina al profilo medio standardizzato.

```r
scores_territori <- acp_territori$x[, 1:2]

da_etichettare <- unique(c(
  order(abs(scores_territori[, 1]), decreasing = TRUE)[1:4],
  order(abs(scores_territori[, 2]), decreasing = TRUE)[1:4]
))

plot(
```

```
  scores_territori,
  pch = 19,
  col = "grey45",
  xlim = range(scores_territori[, 1]) + c(-0.5, 0.5),
  ylim = range(scores_territori[, 2]) + c(-0.5, 0.5),
  xlab = "CP1: condizioni socioeconomiche (78,8%)",
  ylab = "CP2: struttura demografica (15,7%)"
)
abline(h = 0, v = 0, lty = 2, col = "grey70")
text(
  scores_territori[da_etichettare, ],
  labels = territorio[da_etichettare],
  pos = 3,
  cex = 0.8
)
```

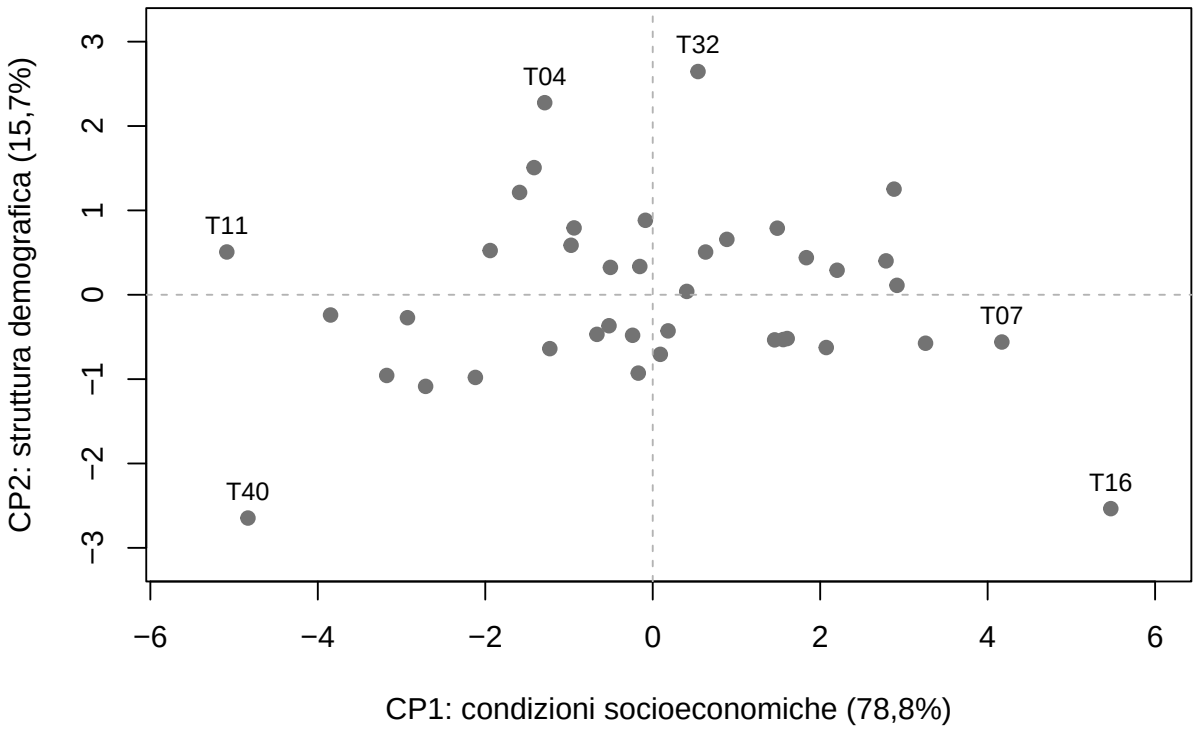


Figura 8.2: Scores dei territori simulati sulle prime due componenti principali.

T16 e T07 hanno scores elevati sulla prima componente e combinano valori relativamente favorevoli degli indicatori socioeconomici simulati. T11 e T40 si trovano all'estremo opposto.

T32 e T04 hanno scores alti soprattutto sulla seconda componente, quindi si distinguono più per la struttura demografica che per la prima dimensione.

La vicinanza tra due punti indica profili simili rispetto alle componenti rappresentate, non identità su tutti gli indicatori. Inoltre, il grafico conserva il 94,4% e non il 100% della variabilità: una parte delle differenze resta fuori dal piano.

8.9 Costruire un indicatore sintetico

Lo score della prima componente può essere usato come indicatore sintetico se la componente ha un significato coerente con l'obiettivo. Per renderlo più leggibile, trasformiamo lo score in una scala con media 100 e deviazione standard 10:

$$S_i = 100 + 10\frac{C_{i1}}{s_C},$$

dove C_{i1} è lo score del territorio i sulla prima componente e s_C è la deviazione standard campionaria degli scores della prima componente. Poiché gli scores hanno media zero, l'indice S_i ha media 100.

```
indice_socioeconomico <-
  100 + 10 * scores_territori[, 1] / sd(scores_territori[, 1])

graduatoria_indice <- data.frame(
  territorio,
  score_CP1 = round(scores_territori[, 1], 2),
  indice = round(indice_socioeconomico, 1)
)

graduatoria_indice <- graduatoria_indice[
  order(graduatoria_indice$indice),
]

rbind(
  head(graduatoria_indice, 3),
  tail(graduatoria_indice, 3)
)
```

```
   territorio score_CP1 indice
11        T11     -5.09   78.3
40        T40     -4.83   79.4
```

```
27        T27     -3.85   83.6
10        T10      3.26  113.9
7         T07      4.17  117.8
16        T16      5.47  123.3
```

T11 e T40 hanno gli indici più bassi, rispettivamente 78,3 e 79,4; T07 e T16 i più alti, 117,8 e 123,3. Un valore di 120 non significa "20% di sviluppo in più". Significa che il territorio si trova due deviazioni standard sopra la media dell'indicatore costruito in questo campione.

La graduatoria è descrittiva e dipende da variabili, periodo, standardizzazione e unità incluse. Aggiungere altri territori può cambiare medie, deviazioni standard, loadings, scores e posizioni. L'indice non misura incertezza campionaria e non dimostra che una politica abbia causato le differenze osservate.

> ⚠ Un indicatore data-driven non è privo di valori
>
> L'ACP sceglie i pesi per rappresentare la varianza, non l'importanza sociale. Indicatori molto variabili o ridondanti possono dominare la prima componente. La scelta di includere reddito, banda larga o povertà rimane una decisione teorica e politica che deve essere documentata.

8.10 Quante componenti conservare

Non esiste una regola unica. Sono utili almeno quattro criteri:

1. **Varianza spiegata:** le componenti conservate dovrebbero rappresentare una quota adeguata dell'informazione per l'obiettivo.
2. **Scree plot:** un gomito può indicare dove le componenti successive aggiungono poco.
3. **Interpretabilità:** una componente deve avere loadings leggibili e un significato sostantivo difendibile.
4. **Stabilità:** risultati che cambiano molto eliminando poche unità o aggiornando il periodo sono fragili.

Conservare una sola componente è attraente per creare una graduatoria, ma può cancellare dimensioni rilevanti. Nel nostro esempio la seconda componente separa la struttura demografica dalle condizioni socioeconomiche. Ridurla a rumore priverebbe l'analisi di un'informazione sostantiva.

8.11 Valori mancanti, outlier e qualità dei dati

`prcomp()` non accetta valori mancanti nella matrice utilizzata. Eliminare tutte le righe incomplete può cambiare la popolazione analizzata; sostituire i dati mancanti con la media riduce artificialmente la variabilità. La strategia deve dipendere dal meccanismo di mancanza e deve essere documentata.

L'ACP basata su medie, varianze e correlazioni è sensibile agli outlier. Un territorio estremo può modificare la direzione delle componenti e apparire poi molto distante proprio perché ha contribuito a definirle. È necessario esaminare distribuzioni e metadati prima dell'analisi, senza cancellare automaticamente casi sostantivamente importanti.

Variabili quasi duplicate possono inoltre ricevere peso complessivo elevato. Inserire tre misure molto simili del reddito e una sola misura dell'istruzione attribuisce implicitamente maggiore importanza alla dimensione economica. La selezione degli indicatori precede il calcolo.

8.12 Analisi delle corrispondenze multiple

L'ACP è adatta a variabili quantitative. Se vogliamo studiare congiuntamente variabili qualitative, come condizione occupazionale, titolo di studio, tipo di abitazione e accesso digitale, possiamo usare l'**analisi delle corrispondenze multiple** (ACM).

L'ACM trasforma ogni modalità in una colonna indicatrice: per esempio, la variabile condizione occupazionale genera colonne come occupato, disoccupato e inattivo. Ogni unità ha valore 1 nella modalità osservata e 0 nelle altre. A partire da questa matrice, il metodo costruisce assi che sintetizzano le associazioni tra profili di modalità.

I risultati principali sono:

- le **coordinate delle modalità**, che indicano dove ciascuna categoria si colloca sugli assi;
- gli **scores delle unità**, che riassumono il loro profilo di risposte;
- l'**inerzia**, una misura della dispersione rappresentata da ciascun asse;
- i **contributi**, che aiutano a riconoscere quali modalità definiscono maggiormente un asse.

Modalità vicine possono caratterizzare profili simili; modalità lontane dall'origine contribuiscono spesso a distinguere le unità. Questa lettura richiede cautela: la distanza va interpretata nel contesto del metodo e delle qualità di rappresentazione, non come correlazione ordinaria.

Le modalità rare possono apparire molto lontane e dominare un asse pur riguardando poche osservazioni. Prima dell'ACM occorre controllare frequenze, categorie quasi vuote e modalità definite in modo ambiguo. Loadings dell'ACP e coordinate o contributi dell'ACM non sono oggetti perfettamente equivalenti, anche se entrambi aiutano a interpretare le dimensioni.

Non aggiungiamo un esempio R perché il progetto non usa ancora un pacchetto per l'ACM e una sua introduzione responsabile richiederebbe anche diagnostica e grafici specifici. Il punto

essenziale è scegliere il metodo in base al tipo di variabili, non convertire arbitrariamente categorie in numeri.

8.13 Errori interpretativi frequenti

1. **Interpretare la prima componente come verità sostantiva.** È la direzione di massima varianza, non necessariamente la dimensione politicamente più importante.
2. **Dimenticare la standardizzazione.** Con scale diverse, l'ACP sulla covarianza può essere dominata dalle unità di misura.
3. **Leggere il segno come assoluto.** Il segno di una componente può essere invertito senza cambiare la soluzione.
4. **Confondere loadings e scores.** I primi descrivono il ruolo delle variabili; i secondi collocano le unità.
5. **Trattare la varianza spiegata come qualità causale.** Una componente che spiega molta varianza non identifica cause o effetti.
6. **Trasformare un indice in una graduatoria definitiva.** Piccole differenze possono essere instabili e non misurano automaticamente differenze di benessere.
7. **Ignorare indicatori esclusi e dati mancanti.** La sintesi riguarda soltanto l'informazione effettivamente inserita nell'analisi.

8.14 Una procedura per l'analisi multivariata

1. **Definire la domanda e le unità.** Chiarire che cosa si vuole sintetizzare e su quale popolazione.
2. **Selezionare indicatori motivati.** Evitare duplicazioni e documentare direzione, fonte, periodo e unità.
3. **Controllare i dati.** Esaminare distribuzioni, valori mancanti, outlier e correlazioni.
4. **Scegliere il metodo.** Usare ACP per variabili quantitative e ACM per profili qualitativi; i dati misti richiedono metodi specifici.
5. **Decidere la scala.** Motivare l'uso di covarianze o correlazioni e ogni trasformazione preliminare.
6. **Valutare le dimensioni.** Combinare varianza spiegata, scree plot, interpretabilità e stabilità.
7. **Leggere loadings e scores insieme.** Assegnare nomi alle componenti soltanto dopo avere esaminato i contributi.
8. **Comunicare i limiti.** Affiancare all'indicatore sintetico le variabili originarie e dichiarare che la sintesi non implica causalità.

La riduzione dimensionale è utile quando rende visibile una struttura complessa senza nasconderne le scelte. Un buon indicatore sintetico non è soltanto facile da ordinare: deve essere riproducibile, interpretabile e accompagnato dalle sue componenti.

9 Modelli per dati spaziali

La disoccupazione di un comune può essere collegata a quella dei comuni vicini. Le persone attraversano i confini amministrativi per lavorare, le imprese condividono infrastrutture e mercati, una politica locale può produrre effetti oltre il territorio che l'ha adottata. Per questo, due unità geograficamente prossime non sono sempre osservazioni indipendenti.

I **dati spaziali** associano informazioni statistiche a una posizione o a una geometria. In questo capitolo considereremo soprattutto dati areali: comuni, province o regioni osservati nello stesso periodo. L'obiettivo è imparare a:

- definire quali territori sono vicini;
- descrivere la somiglianza spaziale con l'indice di Moran;
- riconoscere dipendenza spaziale nei residui di una regressione;
- distinguere un modello con interazioni tra esiti, SAR, da un modello con errori spazialmente correlati, SEM;
- interpretare con cautela coefficienti e ricadute territoriali.

Una mappa è un utile punto di partenza, ma non è un modello. Mostra dove si concentra un fenomeno; da sola non stabilisce perché i territori vicini si somiglino, né dimostra che uno influenzi l'altro.

9.1 Dalla tabella alla struttura spaziale

In una normale tabella ogni riga rappresenta un'unità e ogni colonna una variabile. Un dato spaziale aggiunge una **geometria**: un punto per la sede di un servizio, una linea per una strada o un poligono per il confine di un comune. La geometria permette di calcolare distanze, contiguità e relazioni di vicinato.

Prima dell'analisi occorre documentare almeno:

- l'unità territoriale e il periodo di riferimento;
- il sistema di coordinate e la qualità dei confini;
- la definizione e l'unità di misura delle variabili;
- eventuali cambiamenti amministrativi avvenuti nel tempo;
- i territori privi di vicini o con dati mancanti;
- il denominatore di tassi, quote e valori pro capite.

Come discusso nei capitoli sulle rappresentazioni grafiche e sulla statistica descrittiva, per confrontare territori di popolazione diversa sono spesso più informativi un tasso di disoccupazione o una spesa pro capite che i rispettivi conteggi. Questa scelta non elimina però l'incertezza: un tasso calcolato su una popolazione molto piccola può essere instabile.

> ⚠ Territori e persone non sono la stessa unità
>
> Una relazione tra reddito e voto osservata tra comuni non implica che le persone con reddito più alto votino in un certo modo. Il passaggio indebito dal livello territoriale a quello individuale è la **fallacia ecologica**. I modelli spaziali trattano la dipendenza tra aree, ma non risolvono questo errore di interpretazione.

9.2 Definire i vicini

La dipendenza spaziale non è contenuta automaticamente nelle coordinate. Deve essere rappresentata mediante una regola di vicinato coerente con il processo studiato. Alcune possibilità sono:

- **contiguità a torre** (*rook*): due aree sono vicine se condividono un tratto di confine;
- **contiguità a regina** (*queen*): basta condividere un confine o un vertice;
- **distanza**: sono vicine le unità entro una soglia prefissata;
- k vicini più prossimi: ogni unità è collegata alle k unità più vicine;
- **legami sostantivi**: pendolarismo, scambi commerciali o collegamenti di trasporto possono essere più pertinenti della distanza fisica.

Se osserviamo n territori, raccogliamo le relazioni in una matrice dei pesi spaziali W di dimensione $n \times n$. L'elemento w_{ij} misura il legame tra il territorio i e il territorio j. In una matrice binaria di contiguità, $w_{ij} = 1$ se i due territori sono vicini e $w_{ij} = 0$ altrimenti; di norma $w_{ii} = 0$, perché un territorio non è considerato vicino di se stesso.

È comune **standardizzare per riga** la matrice, dividendo ogni peso per la somma della propria riga. In questo modo i pesi dei vicini di ciascun territorio sommano a uno. Se y_j è il valore osservato nel territorio j, il ritardo spaziale

$$(Wy)_i = \sum_{j=1}^{n} w_{ij} y_j$$

è allora la media ponderata dei valori nei territori vicini a i. Il simbolo $(Wy)_i$ non indica il valore passato di y: a differenza di un ritardo temporale, descrive ciò che accade **altrove nello stesso periodo**.

> **La matrice dei pesi è un'ipotesi**
>
> Contiguità, distanza e pendolarismo descrivono meccanismi differenti e possono produrre risultati differenti. W non va scelta provando molte alternative e mostrando soltanto quella che conferma una tesi. La regola deve essere motivata, documentata e sottoposta a controlli di sensibilità.

9.2.1 Un territorio simulato

Costruiamo 36 comuni fittizi disposti in una griglia di sei righe e sei colonne. Due comuni sono vicini quando condividono un lato. Per ogni comune simuliamo la quota percentuale di residenti adulti laureati e il tasso percentuale di disoccupazione. I dati sono esclusivamente didattici: non rappresentano comuni reali e le relazioni osservate sono incorporate nel processo di simulazione.

```
pacchetti_necessari <- c("spdep", "spatialreg")
pacchetti_mancanti <- pacchetti_necessari[
  !vapply(pacchetti_necessari, requireNamespace, logical(1), quietly = TRUE)
]

if (length(pacchetti_mancanti) > 0) {
  stop(
    "Per riprodurre il capitolo installare: ",
    paste(pacchetti_mancanti, collapse = ", ")
  )
}

set.seed(2045)

numero_righe <- 6
numero_colonne <- 6
numero_comuni <- numero_righe * numero_colonne

vicini_comuni <- spdep::cell2nb(
  numero_righe,
  numero_colonne,
  type = "rook"
)

pesi_comuni <- spdep::nb2listw(
  vicini_comuni,
```

```
  style = "W",
  zero.policy = TRUE
)

matrice_pesi <- spdep::listw2mat(pesi_comuni)
griglia_comuni <- expand.grid(
  riga = seq_len(numero_righe),
  colonna = seq_len(numero_colonne)
)

laureati <- 22 +
  1.8 * (griglia_comuni$colonna - 3.5) +
  0.8 * (griglia_comuni$riga - 3.5) +
  rnorm(numero_comuni, 0, 1.2)

errore_casuale <- rnorm(numero_comuni, 0, 0.8)
rho_simulato <- 0.55
parte_locale <- 11 - 0.28 * (laureati - mean(laureati)) +
  errore_casuale

disoccupazione <- as.numeric(
  solve(
    diag(numero_comuni) - rho_simulato * matrice_pesi,
    parte_locale
  )
)

dati_spaziali <- data.frame(
  comune = sprintf("C%02d", seq_len(numero_comuni)),
  griglia_comuni,
  laureati,
  disoccupazione
)

anteprima_spaziale <- head(dati_spaziali)
anteprima_spaziale[c("laureati", "disoccupazione")] <- round(
  anteprima_spaziale[c("laureati", "disoccupazione")],
  1
)
anteprima_spaziale
```

```
  comune riga colonna laureati disoccupazione
```

```
1    C01    1       1     16.4          28.6
2    C02    2       1     16.2          29.3
3    C03    3       1     17.5          27.4
4    C04    4       1     19.2          26.8
5    C05    5       1     17.9          25.7
6    C06    6       1     21.0          24.2
```

La matrice è standardizzata per riga: un comune con due vicini attribuisce peso 1/2 a ciascuno, mentre un comune con quattro vicini attribuisce peso 1/4. I pesi sono quindi direzionali dopo la standardizzazione, anche se la contiguità originaria è reciproca.

```r
valori_mappa <- matrix(
  dati_spaziali$disoccupazione,
  nrow = numero_righe,
  ncol = numero_colonne
)

colori_mappa <- hcl.colors(9, palette = "YlOrRd", rev = TRUE)

image(
  x = seq_len(numero_colonne),
  y = seq_len(numero_righe),
  z = t(valori_mappa),
  col = colori_mappa,
  axes = FALSE,
  xlab = "Colonna della griglia",
  ylab = "Riga della griglia"
)
axis(1, at = seq_len(numero_colonne))
axis(2, at = seq_len(numero_righe))
box()
text(
  dati_spaziali$colonna,
  dati_spaziali$riga,
  labels = dati_spaziali$comune,
  cex = 0.75
)
```

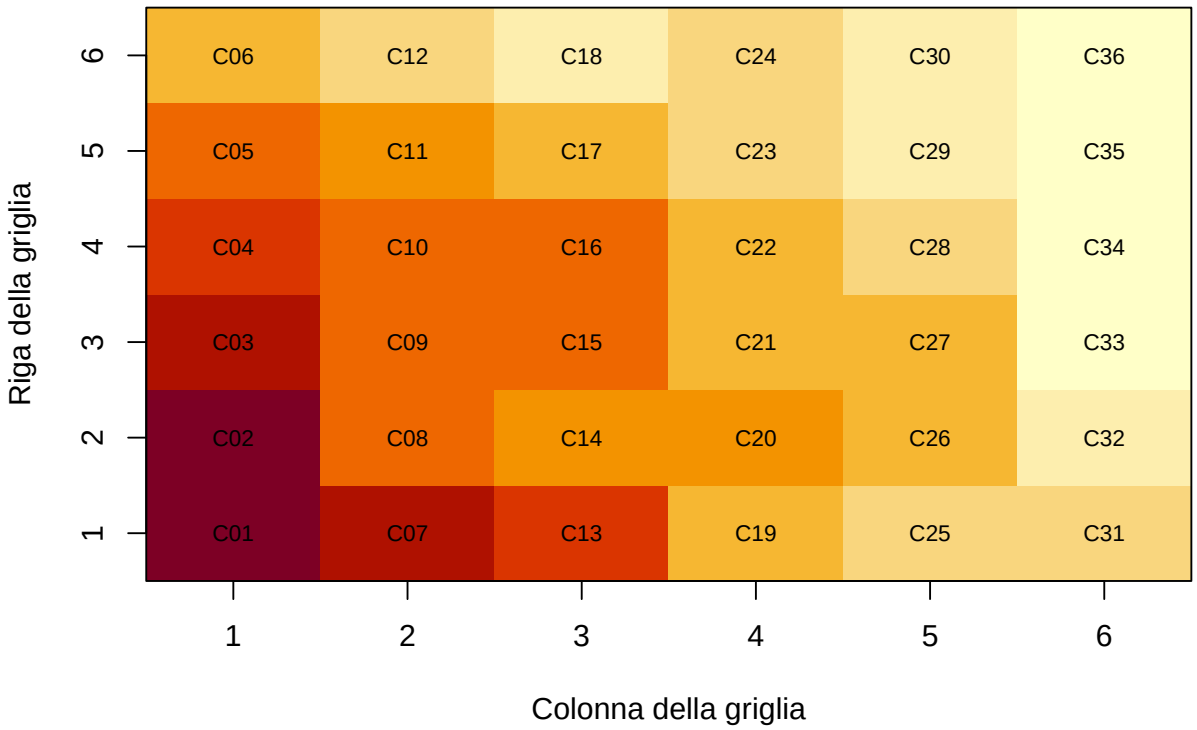


Figura 9.1: Tasso di disoccupazione nei 36 comuni simulati. Le celle rappresentano aree fittizie contigue.

La carta mostra una fascia di valori elevati sul lato sinistro e valori più bassi sul lato destro. Questa continuità suggerisce autocorrelazione spaziale positiva, ma la percezione visiva dipende da colori e classi. Serve una misura esplicita.

9.3 Autocorrelazione spaziale e indice di Moran

L'**autocorrelazione spaziale** indica se valori osservati in luoghi collegati tendono a essere più simili o più diversi di quanto previsto da un riferimento privo di struttura spaziale.

- È **positiva** quando valori alti sono vicini ad altri valori alti e valori bassi ad altri valori bassi.
- È **negativa** quando valori alti tendono a essere circondati da valori bassi, e viceversa.
- È debole quando la disposizione dei valori non mostra una regolarità globale rispetto a W.

L'indice globale di Moran per una variabile y è

$$I = \frac{n}{S_0} \frac{\sum_{i=1}^{n} \sum_{j=1}^{n} w_{ij}(y_i - \bar{y})(y_j - \bar{y})}{\sum_{i=1}^{n} (y_i - \bar{y})^2},$$

dove n è il numero di territori, $\bar{y}$ è la media di y, w_{ij} è l'elemento della matrice dei pesi e $S_0 = \sum_i \sum_j w_{ij}$ è la somma di tutti i pesi. Valori positivi indicano prevalentemente vicinanze tra scostamenti dello stesso segno; valori negativi indicano vicinanze tra scostamenti di segno opposto.

L'indice non è in generale confinato esattamente tra -1 e 1, e sotto un'ipotesi di disposizione casuale il suo valore atteso non è esattamente zero. Per valutarlo useremo un **test di permutazione**: manteniamo fissi i territori e W, rimescoliamo molte volte i valori osservati e confrontiamo l'indice reale con quelli ottenuti casualmente.

```
set.seed(2046)

test_moran_disoccupazione <- spdep::moran.mc(
  dati_spaziali$disoccupazione,
  pesi_comuni,
  nsim = 999,
  zero.policy = TRUE
)

data.frame(
  Moran_I = round(unname(test_moran_disoccupazione$statistic), 3),
  p_value_permutazione = round(test_moran_disoccupazione$p.value, 3)
)
```

```
  Moran_I p_value_permutazione
1   0.803                0.001
```

L'indice di Moran è 0,803 e il *p-value* di permutazione è 0,001. Nei dati simulati, una configurazione con un indice almeno così elevato è rara tra le 999 disposizioni casuali usate come riferimento. Esiste quindi una marcata aggregazione spaziale globale rispetto alla contiguità scelta.

Il *p-value* non misura la grandezza dell'autocorrelazione e non dimostra un processo causale tra comuni. Inoltre, il minimo *p-value* ottenibile con 999 permutazioni è 0,001: riportare più cifre suggerirebbe una precisione inesistente.

9.3.1 Il diagramma di Moran

Il diagramma di Moran mette sull'asse orizzontale il valore standardizzato $z_i = (y_i - \bar{y})/s_y$ e su quello verticale il ritardo spaziale $(Wz)_i$. Con pesi standardizzati per riga, la pendenza della retta passante per l'origine coincide con l'indice globale di Moran.

```
disoccupazione_standardizzata <- as.numeric(
  scale(dati_spaziali$disoccupazione)
)
ritardo_spaziale <- spdep::lag.listw(
  pesi_comuni,
  disoccupazione_standardizzata,
  zero.policy = TRUE
)

plot(
  disoccupazione_standardizzata,
  ritardo_spaziale,
  pch = 19,
  col = "#2C7FB8",
  xlab = "Disoccupazione standardizzata",
  ylab = "Media standardizzata nei comuni vicini"
)
abline(h = 0, v = 0, lty = 3, col = "grey55")
abline(
  a = 0,
  b = unname(test_moran_disoccupazione$statistic),
  col = "#D95F02",
  lwd = 2
)
```

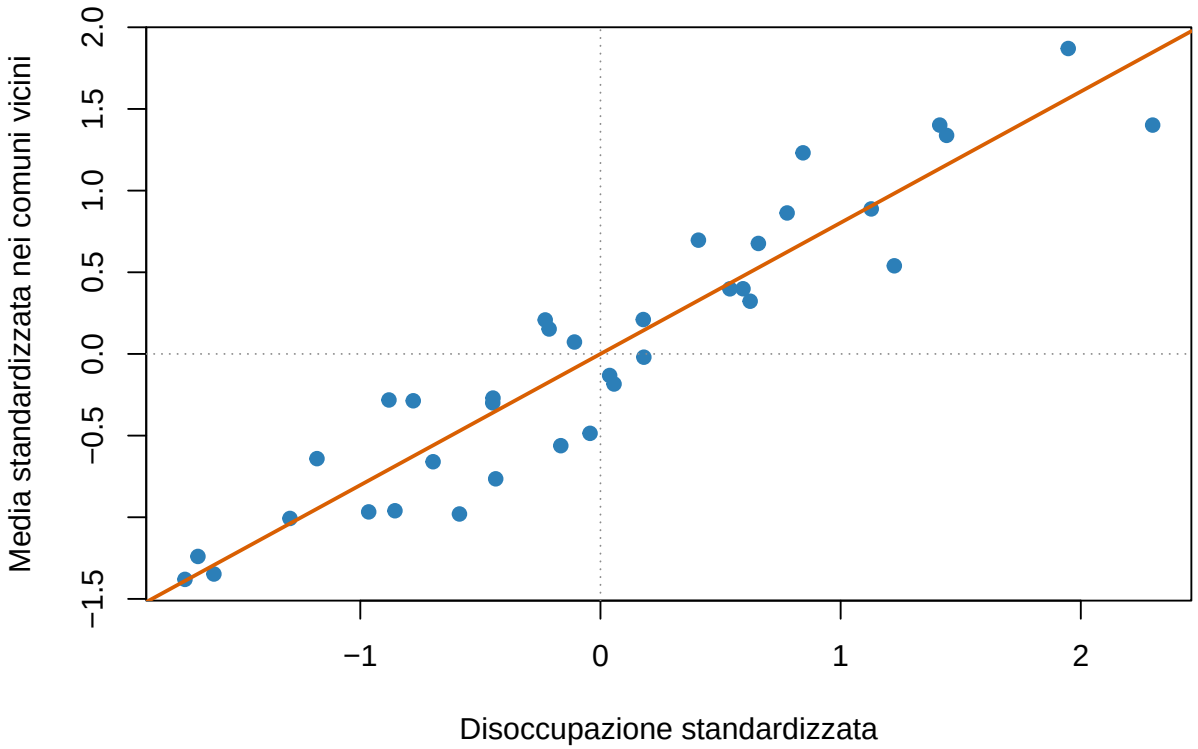


Figura 9.2: Diagramma di Moran per la disoccupazione simulata. La pendenza positiva segnala somiglianza tra comuni vicini.

I quadranti alto–alto e basso–basso contribuiscono positivamente all'indice; i quadranti alto–basso e basso–alto contribuiscono negativamente. Il grafico aiuta a individuare osservazioni interessanti, ma non sostituisce un'analisi locale corretta per confronti multipli.

9.4 Dalla descrizione alla regressione spaziale

Un Moran elevato per y non implica automaticamente che serva un modello SAR. L'aggregazione potrebbe essere spiegata da variabili osservate anch'esse distribuite nello spazio. Una procedura più informativa consiste nello specificare una regressione motivata e verificare se i suoi residui conservano struttura spaziale.

```
modello_ols_spaziale <- lm(
  disoccupazione ~ laureati,
  data = dati_spaziali
)
```

```r
set.seed(2047)
test_moran_residui_ols <- spdep::moran.mc(
  residuals(modello_ols_spaziale),
  pesi_comuni,
  nsim = 999,
  zero.policy = TRUE
)

data.frame(
  intercetta = round(unname(coef(modello_ols_spaziale)[1]), 3),
  coefficiente_laureati = round(
    unname(coef(modello_ols_spaziale)[2]),
    3
  ),
  R2 = round(summary(modello_ols_spaziale)$r.squared, 3),
  Moran_residui = round(unname(test_moran_residui_ols$statistic), 3),
  p_value_Moran = round(test_moran_residui_ols$p.value, 3)
)
```

```
  intercetta coefficiente_laureati    R2 Moran_residui p_value_Moran
1     36.876                -0.569 0.809         0.342         0.003
```

La regressione OLS stima un'associazione di $-0,569$: un punto percentuale in più di laureati è associato in media a 0,569 punti percentuali in meno di disoccupazione. Tuttavia, i residui hanno Moran pari a 0,342 con *p-value* 0,003. Il modello lineare rappresenta gran parte della variabilità, con $R^2 = 0,809$, ma lascia una dipendenza spaziale sistematica. Un R^2 elevato non garantisce quindi che le ipotesi sui residui siano adeguate.

L'autocorrelazione residua può rendere inaffidabile l'inferenza OLS usuale e segnala che il processo è specificato in modo incompleto. Non indica da sola quale modello spaziale sia corretto: la scelta richiede una spiegazione sostantiva del meccanismo.

9.5 Il modello autoregressivo spaziale SAR

Il **modello autoregressivo spaziale**, detto SAR o *spatial lag model*, è appropriato quando l'esito di un territorio può dipendere dagli esiti dei territori collegati. Per il territorio i:

$$y_i = \rho \sum_{j=1}^{n} w_{ij} y_j + \beta_0 + \beta_1 x_i + \varepsilon_i.$$

In questa espressione:

- y_i è l'esito nel territorio i, qui il tasso di disoccupazione;
- $\sum_j w_{ij} y_j = (Wy)_i$ è il ritardo spaziale dell'esito;
- x_i è un regressore, qui la quota di laureati;
- β_0 è l'intercetta e β_1 il coefficiente di x_i;
- ρ misura l'intensità della dipendenza spaziale nell'esito;
- ε_i è un errore privo della struttura spaziale rappresentata dal modello.

In forma compatta, $y = \rho W y + X\beta + \varepsilon$. Poiché ogni valore di y può dipendere dagli altri simultaneamente, il ritardo Wy non è un normale regressore esogeno e il modello non va stimato aggiungendolo semplicemente a `lm()`. Si usano metodi specifici, come la massima verosimiglianza.

La forma ridotta

$$y = (I_n - \rho W)^{-1}(X\beta + \varepsilon)$$

chiarisce il meccanismo di propagazione. I_n è la matrice identità di dimensione n. Una variazione locale di x_i può modificare y_i, influenzare i vicini attraverso W e tornare indirettamente al territorio di partenza. Per questo β_1 non coincide, in generale, con l'effetto marginale complessivo.

```
modello_sar <- spatialreg::lagsarlm(
  disoccupazione ~ laureati,
  data = dati_spaziali,
  listw = pesi_comuni,
  method = "eigen",
  zero.policy = TRUE
)

impatti_sar <- spatialreg::impacts(
  modello_sar,
  listw = pesi_comuni
)

tabella_parametri_sar <- data.frame(
  parametro = c("rho", "intercetta", "laureati"),
  stima = round(
    c(
      unname(modello_sar$rho),
      unname(coef(modello_sar)["(Intercept)"]),
      unname(coef(modello_sar)["laureati"])
    ),
    3
```

```
  )
)

tabella_impatti_sar <- data.frame(
  impatto = c("diretto", "indiretto", "totale"),
  stima = round(
    c(
      unname(impatti_sar$direct),
      unname(impatti_sar$indirect),
      unname(impatti_sar$total)
    ),
    3
  )
)

tabella_parametri_sar
```

```
   parametro  stima
1        rho  0.623
2 intercetta 15.107
3   laureati -0.270
```

```
tabella_impatti_sar
```

```
    impatto  stima
1   diretto -0.313
2 indiretto -0.403
3    totale -0.716
```

La stima di ρ è 0,623: a parità della quota di laureati, la disoccupazione presenta una dipendenza spaziale positiva. Il coefficiente grezzo dei laureati è $-0,270$, ma la misura più utile è la sua propagazione:

- l'**impatto diretto medio** è $-0,313$ punti percentuali nel territorio in cui il regressore cambia, includendo i ritorni attraverso i vicini;
- l'**impatto indiretto medio** è $-0,403$ punti percentuali, sommati sugli altri territori collegati;
- l'**impatto totale medio** è $-0,716$, somma delle due componenti.

Questi risultati descrivono il campione e il modello simulato. Non autorizzano una conclusione causale del tipo "aumentare i laureati riduce la disoccupazione": istruzione e occupazione

potrebbero dipendere da altre caratteristiche territoriali, e la struttura di W è stata imposta dall'analista.

```
set.seed(2048)

test_moran_residui_sar <- spdep::moran.mc(
  residuals(modello_sar),
  pesi_comuni,
  nsim = 999,
  zero.policy = TRUE
)

data.frame(
  Moran_residui_SAR = round(
    unname(test_moran_residui_sar$statistic),
    3
  ),
  p_value_permutazione = round(test_moran_residui_sar$p.value, 3)
)
```

```
  Moran_residui_SAR p_value_permutazione
1             0.003                   0.4
```

Nei residui del SAR l'indice scende a 0,003 e il *p-value* è 0,400. Per questi dati non rimane evidenza di autocorrelazione globale secondo la matrice scelta. È un controllo utile, non una prova che il modello sia vero: devono essere esaminati anche forma funzionale, osservazioni influenti, eteroschedasticità e plausibilità del meccanismo.

9.6 Il modello spaziale degli errori SEM

Nel **modello spaziale degli errori**, o SEM (*spatial error model*), la dipendenza non opera direttamente tra gli esiti. Riguarda fattori non osservati che si distribuiscono nello spazio:

$$y = X\beta + u,$$
$$u = \lambda W u + \varepsilon.$$

Il vettore u raccoglie gli errori spazialmente correlati, λ ne misura la dipendenza e ε contiene le innovazioni non spaziali. Un esempio è la qualità delle infrastrutture non osservata: può influenzare la disoccupazione ed essere simile in comuni confinanti.

In un SEM, β_1 conserva l'interpretazione di associazione parziale della regressione lineare: non genera la catena di impatti diretti e indiretti tipica del SAR. Il parametro λ non misura invece "l'effetto della disoccupazione dei vicini"; segnala struttura spaziale nella componente non osservata.

> **i** Due significati diversi della sigla SEM
>
> In questo capitolo SEM significa **Spatial Error Model**. In altri ambiti la stessa sigla indica *Structural Equation Model*, cioè modello di equazioni strutturali. Sono famiglie di modelli differenti.

Possiamo stimare anche il SEM sugli stessi dati per mostrare che i due modelli non sono intercambiabili.

```
modello_sem <- spatialreg::errorsarlm(
  disoccupazione ~ laureati,
  data = dati_spaziali,
  listw = pesi_comuni,
  method = "eigen",
  zero.policy = TRUE
)

data.frame(
  modello = c("OLS", "SAR", "SEM"),
  parametro_spaziale = c(
    NA,
    round(unname(modello_sar$rho), 3),
    round(unname(modello_sem$lambda), 3)
  ),
  coefficiente_laureati = round(
    c(
      unname(coef(modello_ols_spaziale)["laureati"]),
      unname(coef(modello_sar)["laureati"]),
      unname(coef(modello_sem)["laureati"])
    ),
    3
  ),
  AIC = round(
    c(
      AIC(modello_ols_spaziale),
      AIC(modello_sar),
      AIC(modello_sem)
    ),
```

```
    1
  )
)
```

```
  modello parametro_spaziale coefficiente_laureati   AIC
1     OLS                 NA                -0.569 102.1
2     SAR              0.623                -0.270  85.5
3     SEM              0.788                -0.340  94.5
```

Il SEM stima $\lambda = 0,788$ e un coefficiente dei laureati pari a $-0,340$. Il SAR ha AIC 85,5, inferiore a 94,5 del SEM e 102,1 dell'OLS. Nel processo simulato la dipendenza è stata effettivamente generata nell'esito, quindi è ragionevole che il SAR rappresenti meglio i dati. In un'applicazione reale non conosciamo il processo generatore: AIC e diagnostica aiutano, ma la scelta deve partire dalla teoria e dalla domanda empirica.

9.7 SAR o SEM?

La differenza principale è sostantiva, non soltanto statistica.

Domanda	SAR	SEM
Dove si trova la dipendenza?	Nell'esito y	Nell'errore u
Interpretazione tipica	Interazione o propagazione tra territori	Fattori omessi spazialmente correlati
Il cambiamento di x_i si propaga?	Sì, secondo $(I_n - \rho W)^{-1}$	Non attraverso il meccanismo del modello
Quantità sostantive	Impatti diretti, indiretti e totali	Coefficienti β e dipendenza residua λ

Un mercato del lavoro integrato può motivare un SAR: una variazione dell'occupazione in un comune modifica opportunità e flussi nei comuni vicini. Un contesto istituzionale non misurato ma condiviso tra aree può motivare un SEM. Nella pratica possono esistere entrambi i meccanismi o può mancare una variabile spaziale rilevante. Non si dovrebbe scegliere il modello soltanto in base al parametro con il *p-value* più piccolo.

9.8 Indicatori sintetici e dipendenza spaziale

Nel capitolo sull'analisi multivariata abbiamo costruito un indicatore sintetico territoriale mediante ACP. Anche uno score sintetico può essere mappato e sottoposto a un'analisi di autocorrelazione spaziale. Occorre però distinguere due tipi di pesi:

- i pesi dell'ACP combinano **variabili** in una componente;
- i pesi di W collegano **territori** tra loro.

Un indice elevato di Moran per l'indicatore sintetico mostra che scores simili sono territorialmente vicini rispetto alla W scelta. Non prova che un territorio causi lo sviluppo del vicino e non rende l'indicatore valido sul piano concettuale. La qualità dipende ancora dalla selezione e dalla misurazione delle variabili originarie.

9.9 Problemi specifici dei dati territoriali

9.9.1 Unità territoriali modificabili

Risultati ottenuti sui comuni possono cambiare aggregando gli stessi dati in province o regioni. È il **problema dell'unità areale modificabile**: confini e scala di aggregazione influenzano medie, correlazioni e vicinati. Non esiste una scala universalmente corretta; va scelta in relazione al processo economico e alla disponibilità dei dati.

9.9.2 Eterogeneità spaziale

Dipendenza ed eterogeneità sono differenti. La prima riguarda legami tra territori; la seconda indica che la relazione può cambiare nello spazio. Il coefficiente tra istruzione e disoccupazione potrebbe, per esempio, essere diverso nelle aree urbane e rurali. Inserire un termine SAR non rende automaticamente costanti e corrette tutte le relazioni locali.

9.9.3 Isole, bordi e distanze

Un'isola geografica o amministrativa può non avere vicini secondo la contiguità. Occorre dichiarare se viene esclusa, collegata per distanza o trattata con una regola specifica. Anche i territori sul bordo dell'area di studio hanno vicini esterni non osservati. Infine, distanze calcolate su coordinate geografiche devono rispettare il sistema di riferimento: trattare gradi di longitudine e latitudine come chilometri può produrre vicinati errati.

9.9.4 Tempi e confini

Con dati territoriali ripetuti nel tempo, confini e definizioni possono cambiare. Confrontare direttamente unità non omogenee crea variazioni artificiali. Inoltre, un modello puramente spaziale su un singolo anno non rappresenta dinamiche temporali; dati spazio-temporali richiedono metodi e ipotesi ulteriori.

9.10 Errori interpretativi frequenti

1. **Confondere vicinanza e causalità.** Un cluster territoriale non identifica il meccanismo che lo ha prodotto.
2. **Trattare** W come un dato naturale. La matrice traduce una teoria dei collegamenti e deve essere motivata.
3. **Leggere** β del SAR come in OLS. La retroazione spaziale richiede impatti diretti, indiretti e totali.
4. **Interpretare** ρ come correlazione. È un parametro condizionato dal modello e da W, non il Moran di y.
5. **Interpretare** λ come spillover dell'esito. Nel SEM la dipendenza riguarda gli errori.
6. **Usare Moran solo sulla variabile dipendente.** Per la specificazione della regressione sono particolarmente informativi i residui.
7. **Ignorare denominatori e popolazioni.** Un valore comunale non rappresenta automaticamente il residente medio.
8. **Concludere a livello individuale.** I risultati territoriali restano riferiti alle unità territoriali.
9. **Cercare significatività provando molte matrici.** La selezione opportunistica rende l'inferenza difficile da interpretare.
10. **Pensare che un modello spaziale garantisca causalità.** Rimangono variabili omesse, causalità inversa, selezione e problemi di misurazione.

9.11 Una procedura per l'analisi spaziale

1. **Formulare la domanda.** Chiarire se interessa descrivere cluster, spiegare un'associazione o studiare possibili ricadute.
2. **Definire unità e periodo.** Controllare confini, denominatori, valori mancanti e comparabilità.
3. **Esplorare tabella e carta.** Cercare errori, valori instabili e discontinuità, senza attribuire subito una causa.
4. **Motivare il vicinato.** Costruire W, documentarne regola e standardizzazione, controllare isole e numero di vicini.
5. **Misurare la struttura globale.** Calcolare Moran con un riferimento inferenziale appropriato e verificarne la sensibilità a scelte plausibili di W.
6. **Specificare una regressione sostantiva.** Iniziare dalle variabili richieste dalla domanda, non dal solo pattern della mappa.
7. **Controllare i residui.** Cercare dipendenza rimasta e altri problemi di specificazione.
8. **Scegliere il meccanismo.** Distinguere interazione nell'esito, errori correlati e possibili variabili spaziali omesse.
9. **Interpretare le quantità corrette.** Per il SAR riportare impatti diretti, indiretti e totali; per il SEM non inventare spillover.

10. **Comunicare limiti e incertezza.** Separare associazione, previsione e causalità e dichiarare la dipendenza dei risultati da scala e W.

L'analisi spaziale rende esplicito ciò che una normale regressione spesso lascia implicito: i territori fanno parte di sistemi di relazioni. Il vantaggio non consiste nell'aggiungere una mappa o un parametro, ma nel collegare la domanda economica a una definizione trasparente dei legami territoriali e a un'interpretazione coerente del modello.

10 Case Studies

Work in Progress

Riferimenti Bibliografici

Hyndman, Rob J., e George Athanasopoulos. 2014. *Forecasting: Principles and Practice*. OTexts. http://otexts.com/fpp/.